

Mes Notes de Lecture

Introduction à la Probabilité

LOU BRUNET

27 octobre 2025

Table des matières

1	Probabilités et Dénombrement	3
1.1	Concepts fondamentaux	3
1.2	Définition Naïve de la Probabilité	3
1.3	Permutations (Arrangements)	4
1.4	Le Coefficient Binomial	4
1.5	Identité de Vandermonde	6
1.6	Bose-Einstein (Étoiles et Bâtons)	7
1.7	Principe d'Inclusion-Exclusion	7
1.8	Exercices	10
1.9	Corrections des Exercices	12
1.10	Exercices Pratiques (Python)	15
2	Probabilité conditionnelle	16
2.1	Définition de la Probabilité Conditionnelle	16
2.2	Règle du Produit (Intersection de deux événements)	16
2.3	Règle de la Chaîne (Intersection de n événements)	17
2.4	Règle de Bayes	18
2.5	Formule des Probabilités Totales	18
2.6	Règle de Bayes avec Conditionnement Additionnel	19
2.7	Formule des Probabilités Totales avec Conditionnement Additionnel	20
2.8	Indépendance de Deux Événements	22
2.9	Indépendance Conditionnelle	22
2.10	Le Problème de Monty Hall	22
2.11	Exercices	24
2.12	Corrections des Exercices	26
2.13	Exercices Pratiques (Python)	29
3	Variables Aléatoires Discrètes	33
3.1	Variable Aléatoire	33
3.2	Variable Aléatoire Discrète	33
3.3	Fonction de Masse (PMF)	33
3.4	Loi de Bernoulli	34
3.5	Loi Binomiale	34
3.6	Loi Hypergéométrique	35
3.7	Loi Géométrique	36
3.8	Loi de Poisson	37
3.9	Fonction de Répartition (CDF)	39
3.10	Variable Aléatoire Indicatrice	40
3.11	Exercices	40
3.12	Corrections des Exercices	43
3.13	Exercices Pratiques (Python)	45
4	Espérance et Variance	49
4.1	Espérance d'une variable aléatoire discrète	49
4.2	Linéarité de l'espérance	49
4.3	Espérance de la loi binomiale	50
4.4	Espérance de la loi géométrique	51
4.5	Loi du statisticien inconscient (LOTUS)	52
4.6	Variance	53
4.7	Exercices	54
4.8	Corrections des Exercices	55
4.9	Exercices Pratiques (Python)	58
5	Distributions Multivariées et Concepts Associés	62
5.1	Distributions Jointes et Marginales	62
5.2	Espérance d'une fonction de deux variables	63
5.3	Covariance et Corrélation	63

5.4	Linéarité de la Covariance	65
5.5	Résultats sur la Corrélation	65
5.6	Standardisation et Non-Corrélation	66
5.7	Variance d'une Somme de Variables Aléatoires	68
5.8	Théorème sur la somme de lois de Poisson	69
5.9	Exercices	70
5.10	Corrections des Exercices	72
5.11	Exercices Pratiques (Python)	75
6	Variables Aléatoires Continues	79
6.1	Fonction de Densité de Probabilité (PDF)	79
6.2	Fonction de Répartition (CDF)	79
6.3	Espérance et Variance (Cas Continu)	80
6.4	Loi Uniforme	82
6.5	Loi Exponentielle	83
6.6	Distributions Conjointes (Cas Continu)	85
6.7	Espérance, Indépendance et Covariance (Cas Conjoint)	86
6.8	Exercices	87
6.9	Corrections des Exercices	89
6.10	Exercices Pratiques (Python)	92
7	La Loi Normale (ou Gaussienne)	95
7.1	Introduction et Fonction de Densité (PDF)	95
7.2	La Loi Normale Centrée Réduite $\mathcal{N}(0, 1)$	98
7.3	Standardisation : Le Score Z	98
7.4	Propriétés Importantes de la Loi Normale	100
7.5	La Règle Empirique (68-95-99.7)	101
7.6	Calcul de Probabilités Normales	102
7.7	Exercices	102
7.8	Corrections des Exercices	104
7.9	Exercices Pratiques (Python)	106
8	Moments d'une distribution	110
8.1	Définitions fondamentales des moments	110
8.2	Asymétrie (Skewness)	110
8.3	Propriétés de symétrie	111
8.4	Aplatissement (Kurtosis)	111
8.5	Exemples de distributions	112
8.6	Exercices	114
8.7	Corrections des Exercices	116
8.8	Exercices Pratiques (Python)	118
9	Appendice A : Séries de Taylor et Maclaurin	121
9.1	Construction pas à pas d'une série de Taylor	121
9.2	Intuition de la série de Taylor en un point quelconque a	122
9.3	La Fonction Exponentielle (e^x)	123
9.4	La Fonction Sinus ($\sin(x)$)	124
9.5	La Fonction Cosinus ($\cos(x)$)	125
9.6	Le Logarithme Népérien ($\ln(1 + x)$)	126
9.7	La Série Géométrique ($\frac{1}{1-x}$)	127
10	Tests	128

1 Probabilités et Dénombrement

1.1 Concepts fondamentaux

Avant de pouvoir calculer des probabilités, il est essentiel d'établir un vocabulaire commun pour décrire les expériences aléatoires.

Intuition : Nécessité d'un Cadre Formel

Avant de calculer des probabilités, il est crucial de définir les règles du jeu :

Qu'est-ce qui peut arriver ?

On définit l'ensemble de tous les résultats possibles de l'expérience.

À quoi s'intéresse-t-on ?

On identifie les sous-ensembles de résultats spécifiques qui nous intéressent.

Ces deux idées nous conduisent aux notions d'Univers et d'Événement, qui sont les piliers de toute théorie des probabilités.

Cette intuition se traduit formellement par deux définitions clés :

Définition : Concepts Fondamentaux

Univers (ou Espace Échantillon), S :

L'ensemble de tous les résultats possibles d'une expérience aléatoire.

Événement, A :

Un sous-ensemble de l'univers ($A \subseteq S$). C'est un ensemble de résultats auxquels on s'intéresse.

Un exemple simple permet de solidifier ces concepts :

Exemple : Univers et Événement

Pour l'expérience du "lancer d'un dé à six faces" :

L'univers est $S = \{1, 2, 3, 4, 5, 6\}$.

"Obtenir un nombre impair" est un événement, représenté par le sous-ensemble $A = \{1, 3, 5\}$.

1.2 Définition Naïve de la Probabilité

Pour de nombreuses expériences simples, comme lancer un dé non pipé, chaque résultat possible est "équiprobable". Cette hypothèse est la base de la première définition formelle de la probabilité.

Définition : Probabilité Naïve

Pour une expérience où chaque issue dans un espace échantillon fini S est équiprobable, la probabilité d'un événement A est le rapport du nombre d'issues favorables à A sur le nombre total d'issues :

$$P(A) = \frac{\text{Nombre d'issues favorables}}{\text{Nombre total d'issues}} = \frac{|A|}{|S|}$$

Appliquons cette formule à quelques cas classiques :

Exemple : Applications de la définition naïve

1. **Lancer une pièce équilibrée** : L'espace échantillon est $S = \{\text{Pile}, \text{Face}\}$, donc $|S| = 2$. Si l'événement A est "obtenir Pile", alors $A = \{\text{Pile}\}$ et $|A| = 1$. La probabilité est $P(A) = \frac{1}{2}$.
2. **Lancer un dé à six faces non pipé** : L'espace échantillon est $S = \{1, 2, 3, 4, 5, 6\}$, donc $|S| = 6$. Si l'événement B est "obtenir un nombre pair", alors $B = \{2, 4, 6\}$ et $|B| = 3$. La probabilité est $P(B) = \frac{3}{6} = \frac{1}{2}$.
3. **Tirer une carte d'un jeu de 52 cartes** : L'espace échantillon S contient 52 cartes, donc $|S| = 52$. Si l'événement C est "tirer un Roi", il y a 4 Rois dans le jeu, donc $|C| = 4$. La probabilité est $P(C) = \frac{4}{52} = \frac{1}{13}$.

1.3 Permutations (Arrangements)

Le dénombrement, qui est l'art de compter les tailles $|A|$ et $|S|$, est fondamental pour appliquer la définition naïve. Le premier outil que nous verrons est la permutation, qui compte les arrangements ordonnés.

Définition : Permutation de k objets parmi n

Le nombre de façons d'arranger k objets choisis parmi n objets distincts (où l'ordre compte et il n'y a pas de répétition) est noté $P(n, k)$ ou A_n^k et est défini par :

$$P(n, k) = \frac{n!}{(n-k)!}$$

où $n!$ est la factorielle de n , et par convention $0! = 1$.

Cette formule peut sembler abstraite, mais elle provient d'un raisonnement logique simple par "cases" :

Intuition : Permutations de k parmi n

Pour placer k objets dans un ordre spécifique en les choisissant parmi n objets disponibles, on a n choix pour la première position, $(n-1)$ choix pour la deuxième, ..., et $(n-k+1)$ choix pour la k -ième position. Cela donne $n \times (n-1) \times \dots \times (n-k+1)$ arrangements. Ce produit contient k termes. Il est égal à $\frac{n!}{(n-k)!}$, car cela revient à diviser la suite complète $n!$ par les facteurs non utilisés $(n-k) \times (n-k-1) \times \dots \times 1$.

Voyons une application classique de ce principe :

Exemple : Permutations de k parmi n

Podium d'une course : Une course réunit 8 coureurs. Combien y a-t-il de podiums (1er, 2e, 3e) possibles ?

On cherche le nombre de façons d'ordonner 3 coureurs parmi 8 : $P(8, 3)$.

$$P(8, 3) = \frac{8!}{(8-3)!} = \frac{8!}{5!} = 8 \times 7 \times 6 = 336$$

Il y a 336 podiums possibles.

1.4 Le Coefficient Binomial

Que se passe-t-il si l'ordre ne compte pas ? Au lieu de compter des podiums, nous voulons compter des comités. C'est le rôle du coefficient binomial.

Théorème : Formule du Coefficient Binomial

Le nombre de façons de choisir k objets parmi un ensemble de n objets distincts (sans remise et sans ordre) est donné par le coefficient binomial :

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

La preuve de cette formule repose sur un argument combinatoire élégant : nous allons compter la même chose (les permutations) de deux façons différentes.

Preuve

Considérons le nombre de permutations de k objets parmi n , noté $P(n, k)$.

1. **Méthode 1** : Par définition (vue ci-dessus), nous savons que $P(n, k) = \frac{n!}{(n-k)!}$.
2. **Méthode 2** : Nous pouvons construire une telle permutation en deux étapes successives :
 - D'abord, **choisir un sous-ensemble** de k objets parmi n (l'ordre ne compte pas). C'est le nombre que nous cherchons, notons-le $\binom{n}{k}$.
 - Ensuite, **ordonner** ces k objets choisis. Il y a $k!$ façons de les arranger.

Le nombre total de permutations est donc le produit de ces étapes : $P(n, k) = \binom{n}{k} \times k!$.

En égalisant les deux méthodes, on obtient :

$$\binom{n}{k} \cdot k! = \frac{n!}{(n-k)!}$$

En divisant par $k!$, on trouve bien la formule :

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

L'intuition visuelle derrière cette preuve est de voir comment chaque "choix" (une colonne du tableau) génère $k!$ "ordres" (les lignes de cette colonne).

Intuition

Pour rendre cela concret, voici le cas $\binom{5}{3}$. Il y a 10 sous-ensembles de 3 éléments parmi $\{a, b, c, d, e\}$. Chacun donne lieu à $3! = 6$ permutations. Le tableau ci-dessous montre **toutes les 60 permutations**, regroupées par sous-ensemble :

$\{a, b, c\}$	$\{a, b, d\}$	$\{a, b, e\}$	$\{a, c, d\}$	$\{a, c, e\}$	$\{a, d, e\}$	$\{b, c, d\}$	$\{b, c, e\}$	$\{b, d, e\}$	$\{c, d, e\}$
abc	abd	abe	acd	ace	ade	bcd	bce	bde	cde
acb	adb	aeb	adc	aec	aed	bdc	bec	bed	ced
bac	bad	bae	cad	cae	dae	cbd	ceb	dbe	dce
bca	bda	bea	cda	cea	dea	cdb	ceb	deb	dec
cab	dab	eab	dac	eac	ead	dbc	ebc	edb	ecd
cba	dba	eba	dca	eca	eda	dcb	ebc	edb	edc

Chaque colonne correspond à **un seul et même choix non ordonné** (par exemple $\{a, b, c\}$), mais à 6 listes différentes selon l'ordre. Ainsi, pour obtenir le nombre de *choix non ordonnés*, on divise le nombre total de listes (60) par le nombre d'ordres par groupe (6) :

$$\binom{5}{3} = \frac{60}{6} = 10.$$

L'application la plus directe est le tirage d'un groupe où l'ordre n'importe pas :

Exemple : Utilisation du Coefficient Binomial

Comité d'étudiants : De combien de manières peut-on former un comité de 3 étudiants à partir d'une classe de 10 ? L'ordre ne compte pas.

$$\binom{10}{3} = \frac{10!}{3!(10-3)!} = \frac{10 \times 9 \times 8}{3 \times 2 \times 1} = 120 \text{ comités possibles.}$$

1.5 Identité de Vandermonde

Les coefficients binomiaux obéissent à de nombreuses identités. L'identité de Vandermonde est l'une des plus utiles, car elle montre comment décomposer un problème de comptage complexe en sous-problèmes.

Théorème : Identité de Vandermonde

Cette identité offre une relation remarquable entre les coefficients binomiaux. Pour des entiers non négatifs m, n et k , on a :

$$\binom{m+n}{k} = \sum_{j=0}^k \binom{m}{j} \binom{n}{k-j}$$

La preuve la plus intuitive est une "preuve par l'histoire" (proof by story), qui consiste à trouver un scénario de dénombrement que les deux côtés de l'équation résolvent.

Preuve : Preuve combinatoire

Imaginons un groupe composé de m hommes et n femmes. Nous souhaitons former un comité de k personnes. Nous allons compter le nombre de comités possibles de deux façons.

Côté gauche : $\binom{m+n}{k}$ Le groupe total contient $m+n$ personnes. Le nombre de façons de choisir un comité de k personnes parmi ce total est, par définition, $\binom{m+n}{k}$.

Côté droit : $\sum_{j=0}^k \binom{m}{j} \binom{n}{k-j}$ Nous pouvons compter le même nombre en conditionnant sur le nombre d'hommes (noté j) dans le comité. Un comité de k personnes doit contenir j hommes ET $k-j$ femmes, où j peut aller de 0 à k .

- Pour $j = 0$: Choisir 0 homme ($\binom{m}{0}$) ET k femmes ($\binom{n}{k}$).
- Pour $j = 1$: Choisir 1 homme ($\binom{m}{1}$) ET $k-1$ femmes ($\binom{n}{k-1}$).
- ...
- Pour $j = k$: Choisir k hommes ($\binom{m}{k}$) ET 0 femme ($\binom{n}{0}$).

Puisque ces cas (0 homme, 1 homme, etc.) sont mutuellement exclusifs, le nombre total de comités est la somme de toutes ces possibilités :

$$\sum_{j=0}^k \binom{m}{j} \binom{n}{k-j}$$

Puisque les deux côtés comptent exactement la même chose (le nombre total de comités), ils doivent être égaux.

Vérifions cette identité avec un exemple numérique concret, en reprenant l'analogie du comité :

Exemple : Application de l'Identité de Vandermonde

On veut former un comité de 3 personnes ($k = 3$) à partir d'un groupe de 5 hommes ($m = 5$) et 4 femmes ($n = 4$).

Méthode directe (côté gauche) : On choisit 3 personnes parmi les $5 + 4 = 9$ au total.

$$\binom{9}{3} = \frac{9 \times 8 \times 7}{3 \times 2 \times 1} = 84$$

Méthode par cas (côté droit) : La somme est $\binom{5}{0}\binom{4}{3} + \binom{5}{1}\binom{4}{2} + \binom{5}{2}\binom{4}{1} + \binom{5}{3}\binom{4}{0} = 84$. Les deux méthodes donnent bien le même résultat.

1.6 Bose-Einstein (Étoiles et Bâtons)

Jusqu'à présent, nous avons supposé un "tirage sans remise". La statistique de Bose-Einstein, ou plus visuellement la méthode des "étoiles et bâtons", s'attaque au problème du **tirage avec remise** où l'ordre ne compte pas.

Théorème : Combinaisons avec répétition

Le nombre de façons de distribuer k objets indiscernables dans n boîtes discernables (ou de choisir k objets parmi n avec remise, où l'ordre ne compte pas) est donné par la formule :

$$\binom{n+k-1}{k} = \binom{n+k-1}{n-1}$$

La preuve de cette formule est l'un des résultats les plus élégants du dénombrement. L'astuce consiste à transformer le problème de distribution en un problème d'arrangement de symboles.

Preuve : Par les "Étoiles et Bâtons"

Nous cherchons à distribuer k objets indiscernables (\star) dans n boîtes discernables. Nous pouvons représenter n'importe quelle distribution comme une séquence de symboles. Nous avons besoin de k étoiles (les objets) et de $n-1$ bâtons ($|$) pour servir de séparateurs entre les n boîtes.

Par exemple, pour distribuer $k=7$ étoiles dans $n=4$ boîtes, la séquence :

$$\star\star\star | \star || \star\star\star$$

correspond à : 3 étoiles dans la boîte 1, 1 étoile dans la boîte 2, 0 étoile dans la boîte 3 (l'espace entre deux bâtons), et 3 étoiles dans la boîte 4.

Chaque arrangement unique de ces symboles correspond à une distribution unique. Le problème revient donc à trouver le nombre de façons d'arranger ces k étoiles et ces $n-1$ bâtons.

Nous avons un total de $n+k-1$ positions à remplir. Le nombre de façons de le faire est simplement le nombre de manières de choisir les k positions pour les étoiles (les autres positions étant automatiquement remplies par des bâtons). C'est exactement :

$$\binom{n+k-1}{k}$$

(Ce qui est aussi égal à $\binom{n+k-1}{n-1}$, le nombre de façons de choisir les positions des $n-1$ bâtons).

C'est la méthode parfaite pour tout problème de distribution d'objets identiques :

Exemple : Distribution de biens identiques

De combien de manières peut-on distribuer 10 croissants identiques à 4 enfants ?

Ici, $k=10$ (les croissants, objets indiscernables) et $n=4$ (les enfants, boîtes discernables). Le nombre de distributions possibles est :

$$\binom{4+10-1}{10} = \binom{13}{10} = \binom{13}{3} = \frac{13 \times 12 \times 11}{3 \times 2 \times 1} = 13 \times 2 \times 11 = 286$$

Il y a 286 façons de distribuer les croissants.

1.7 Principe d'Inclusion-Exclusion

Comment compter le nombre d'éléments dans l'union de plusieurs ensembles ? Si on additionne simplement leurs tailles, on compte les intersections plusieurs fois. Le principe d'inclusion-exclusion corrige systématiquement ce sur-comptage.

Théorème : Principe d'Inclusion-Exclusion pour 3 ensembles

Pour trois ensembles finis A , B et C , le nombre d'éléments dans leur union est donné par :

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$$

La preuve pour 3 ensembles se fait en appliquant la formule pour 2 ensembles de manière répétée.

Preuve

Nous utilisons la formule pour deux ensembles, $|X \cup Y| = |X| + |Y| - |X \cap Y|$, de manière imbriquée. Posons $X = A \cup B$ et $Y = C$.

$$\begin{aligned} |A \cup B \cup C| &= |(A \cup B) \cup C| \\ &= |A \cup B| + |C| - |(A \cup B) \cap C| \end{aligned}$$

Nous devons maintenant développer les deux termes compliqués :

1. $|A \cup B| = |A| + |B| - |A \cap B|$
2. Par distributivité de l'intersection sur l'union, $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$.

Appliquons la formule pour 2 ensembles à ce deuxième terme :

$$|(A \cap C) \cup (B \cap C)| = |A \cap C| + |B \cap C| - |(A \cap C) \cap (B \cap C)|$$

Ce qui se simplifie en $|A \cap C| + |B \cap C| - |A \cap B \cap C|$.

Finalement, en substituant tout dans l'équation de départ :

$$\begin{aligned} |A \cup B \cup C| &= \underbrace{(|A| + |B| - |A \cap B|)}_{|A \cup B|} + |C| \\ &\quad - \underbrace{(|A \cap C| + |B \cap C| - |A \cap B \cap C|)}_{|(A \cup B) \cap C|} \end{aligned}$$


En réarrangeant les termes, on obtient la formule voulue :

$$|A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$$

La formule devient évidente lorsque l'on utilise un diagramme de Venn pour visualiser le sur-comptage et sa correction.

Intuition : Visualisation avec 3 ensembles

Le principe d'inclusion-exclusion permet de compter le nombre d'éléments dans une union d'ensembles sans double-comptage. Pour comprendre intuitivement pourquoi on ajoute et soustrait alternativement, considérons trois ensembles A , B et C :



Le problème : Si on additionne simplement $|A| + |B| + |C|$, on compte certaines zones plusieurs fois :

- Les intersections deux à deux (X, Y, Z) sont comptées **deux fois**
- L'intersection triple (T) est comptée **trois fois**

La solution : On corrige en soustrayant les intersections deux à deux, mais alors l'intersection triple est comptée :

- +3 fois dans la somme initiale
- -3 fois dans la soustraction des intersections deux à deux (car elle appartient à chacune)
- Donc 0 fois au total ! Il faut la rajouter.

D'où la formule : $|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$

Ce que nous avons fait visuellement pour 3 ensembles peut être généralisé par récurrence à n ensembles. La formule générale suit le même principe d'alternance des signes :

Théorème : Principe d'Inclusion-Exclusion généralisé

Pour n ensembles finis A_1, A_2, \dots, A_n , on a :

$$\begin{aligned} |A_1 \cup A_2 \cup \dots \cup A_n| &= \sum_{i=1}^n |A_i| \\ &\quad - \sum_{1 \leq i < j \leq n} |A_i \cap A_j| \\ &\quad + \sum_{1 \leq i < j < k \leq n} |A_i \cap A_j \cap A_k| \\ &\quad - \dots \\ &\quad + (-1)^{n+1} |A_1 \cap A_2 \cap \dots \cap A_n| \end{aligned}$$

Ce qui s'écrit plus compactement :

$$\left| \bigcup_{i=1}^n A_i \right| = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} |A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}|$$

La preuve formelle que cette formule gigantesque fonctionne est fascinante. Il suffit de montrer que n'importe quel élément x de l'union, peu importe à combien d'ensembles il appartient, est compté **exactement une fois** au final.

Preuve : Preuve par comptage d'un élément

Considérons un élément x qui appartient à exactement k ensembles parmi les n ensembles A_1, \dots, A_n (où $k \geq 1$). Nous devons montrer que x est compté exactement 1 fois par la formule.

Analysons combien de fois x est compté dans chaque somme de la formule :

- **Première somme** ($\sum |A_i|$) : x est dans k ensembles, donc il est ajouté k fois. Le nombre de fois est $\binom{k}{1}$.
- **Deuxième somme** ($-\sum |A_i \cap A_j|$) : x est compté (et soustrait) pour chaque *paire* d'ensembles auxquels il appartient. Comme il appartient à k ensembles, il y a $\binom{k}{2}$ telles paires.
- **Troisième somme** ($+\sum |A_i \cap A_j \cap A_k|$) : x est ajouté pour chaque *triplet* d'ensembles auxquels il appartient. Il y en a $\binom{k}{3}$.
- **Et ainsi de suite...**

Au total, l'élément x est compté :

$$\text{Total} = \binom{k}{1} - \binom{k}{2} + \binom{k}{3} - \dots + (-1)^{k-1} \binom{k}{k} \text{ fois.}$$

Pour évaluer cette somme, rappelons l'identité fondamentale du binôme de Newton :

$$(1+x)^k = \sum_{j=0}^k \binom{k}{j} x^j = \binom{k}{0} + \binom{k}{1}x + \binom{k}{2}x^2 + \dots$$

Si nous posons $x = -1$, nous obtenons :

$$(1-1)^k = 0 = \binom{k}{0} - \binom{k}{1} + \binom{k}{2} - \binom{k}{3} + \dots + (-1)^k \binom{k}{k}$$

Sachant que $\binom{k}{0} = 1$, on a :

$$0 = 1 - \left(\binom{k}{1} - \binom{k}{2} + \binom{k}{3} - \dots + (-1)^{k-1} \binom{k}{k} \right)$$

En réarrangeant, on trouve :

$$1 = \binom{k}{1} - \binom{k}{2} + \binom{k}{3} - \dots + (-1)^{k-1} \binom{k}{k}$$

Cela prouve que n'importe quel élément de l'union est compté exactement une fois.

Ce principe est très utile en probabilité, car il permet de calculer $P(A \cup B \cup \dots)$ en se basant sur les probabilités des intersections, qui sont souvent plus faciles à trouver.

Exemple : Application probabiliste

On lance trois dés équilibrés. Quelle est la probabilité d'obtenir au moins un 6 ?

Solution avec inclusion-exclusion :

Soit A = "le premier dé montre 6", B = "le deuxième dé montre 6", C = "le troisième dé montre 6".

On veut $P(A \cup B \cup C)$.

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) \\ &\quad - P(A \cap B) - P(A \cap C) - P(B \cap C) \\ &\quad + P(A \cap B \cap C) \\ &= \frac{1}{6} + \frac{1}{6} + \frac{1}{6} - \frac{1}{36} - \frac{1}{36} - \frac{1}{36} + \frac{1}{216} \\ &= \frac{3}{6} - \frac{3}{36} + \frac{1}{216} = \frac{1}{2} - \frac{1}{12} + \frac{1}{216} \\ &= \frac{108 - 18 + 1}{216} = \frac{91}{216} \approx 0.421 \end{aligned}$$

Vérification par la méthode complémentaire :

La probabilité de n'obtenir aucun 6 est $\left(\frac{5}{6}\right)^3 = \frac{125}{216}$, donc la probabilité d'au moins un 6 est $1 - \frac{125}{216} = \frac{91}{216}$.

1.8 Exercices

Cette série d'exercices vise à renforcer votre compréhension des concepts fondamentaux du dénombrement et de la probabilité naïve. La difficulté augmente progressivement.

Exercice 1 : Univers et Événements

On lance deux dés à 6 faces, un rouge et un bleu.

1. Décrivez l'univers S de cette expérience. Quelle est sa taille $|S|$?
2. Soit A l'événement "la somme des dés est égale à 7". Listez les issues appartenant à A . Calculez $P(A)$.
3. Soit B l'événement "le dé rouge montre un 3". Listez les issues appartenant à B . Calculez

$P(B)$.

4. Décrivez l'événement $A \cap B$ et calculez sa probabilité.

Exercice 2 : Tirage de Cartes (Prob. Naïve)

On tire une carte au hasard d'un jeu standard de 52 cartes.

1. Quelle est la probabilité de tirer un Roi ?
2. Quelle est la probabilité de tirer une carte rouge (Cœur ou Carreau) ?
3. Quelle est la probabilité de tirer une figure (Valet, Dame, Roi) ?
4. Quelle est la probabilité de tirer un As rouge ?

Exercice 3 : Urne Simple (Prob. Naïve)

Une urne contient 5 boules rouges, 3 boules bleues et 2 boules vertes. On tire une boule au hasard.

1. Quelle est la probabilité qu'elle soit bleue ?
2. Quelle est la probabilité qu'elle ne soit pas verte ?

Exercice 4 : Anagrammes (Permutation Simple)

Combien d'anagrammes distinctes peut-on former avec les lettres du mot "MATHS" ?

Exercice 5 : Course (Arrangement)

Dix athlètes participent à une course. Combien y a-t-il de classements possibles pour les 3 premières places (médaille d'or, d'argent, de bronze) ?

Exercice 6 : Anagrammes (Permutation avec Répétition)

Combien d'anagrammes distinctes peut-on former avec les lettres du mot "PROBABILITE" ?

Exercice 7 : Choix d'un Comité (Combinaison)

Une classe compte 15 étudiants. De combien de manières peut-on choisir un comité de 4 étudiants ?

Exercice 8 : Mains de Poker (Combinaison)

Dans un jeu de 52 cartes, combien de "mains" de 5 cartes différentes peut-on former ?

Exercice 9 : Comité Mixte (Combinaison)

À partir d'un groupe de 6 hommes et 4 femmes, combien de comités de 3 personnes peut-on former contenant exactement 2 hommes et 1 femme ?

Exercice 10 : Probabilité avec Combinaisons

On tire simultanément 3 cartes d'un jeu de 52 cartes. Quelle est la probabilité d'obtenir exactement 2 Rois ?

Exercice 11 : Distribution de Bonbons (Étoiles et Bâtons)

De combien de manières peut-on distribuer 8 bonbons identiques à 3 enfants ? (Certains enfants peuvent ne rien recevoir).

Exercice 12 : Solutions d'Équation (Étoiles et Bâtons)

Combien y a-t-il de solutions entières non négatives ($x_i \geq 0$) à l'équation $x_1 + x_2 + x_3 + x_4 = 10$?

Exercice 13 : Distribution avec Minimum (Étoiles et Bâtons avec Contrainte)

De combien de manières peut-on distribuer 12 pommes identiques à 4 enfants, si chaque enfant doit recevoir au moins une pomme ?

Exercice 14 : Divisibilité (Inclusion-Exclusion 2 Ensembles)

Parmi les entiers de 1 à 100, combien sont divisibles par 2 OU par 3 ?

Exercice 15 : Langues (Inclusion-Exclusion 2 Ensembles)

Dans un groupe de 50 étudiants, 30 étudient l'anglais, 25 étudient l'espagnol et 10 étudient les deux langues. Combien d'étudiants étudient au moins une de ces deux langues ? Combien n'en étudient aucune ?

Exercice 16 : Divisibilité (Inclusion-Exclusion 3 Ensembles)

Parmi les entiers de 1 à 100, combien sont divisibles par 2, 3 OU 5 ?

Exercice 17 : Chemins sur un Grillage (Combinaison)

Sur un grille, combien y a-t-il de chemins pour aller du point (0,0) au point (4,3) en se déplaçant uniquement vers la droite (D) ou vers le haut (H) ?

Exercice 18 : Probabilité Hypergéométrique

Une urne contient 7 boules blanches et 5 boules noires. On tire successivement et sans remise 4 boules. Quelle est la probabilité d'obtenir 2 blanches et 2 noires ?

Exercice 19 : Arrangement Circulaire

De combien de manières 6 personnes peuvent-elles s'asseoir autour d'une table ronde ? (Deux arrangements sont considérés identiques si chaque personne a les mêmes voisins).

Exercice 20 : Problème des Dérangements (Inclusion-Exclusion)

Quatre lettres sont adressées à quatre personnes différentes, avec les enveloppes correspondantes. On met chaque lettre au hasard dans une enveloppe. Quelle est la probabilité qu'aucune lettre ne soit dans la bonne enveloppe ?

1.9 Corrections des Exercices

Correction Exercice 1 : Univers et Événements

- 1) L'univers S est l'ensemble de toutes les paires (r, b) où r est le résultat du dé rouge et b celui du dé bleu. $S = \{(1, 1), (1, 2), \dots, (1, 6), (2, 1), \dots, (6, 6)\}$. La taille de l'univers est $|S| = 6 \times 6 = 36$.
- 2) L'événement A (somme égale à 7) est $A = \{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}$. Il y a $|A| = 6$ issues favorables. La probabilité est $P(A) = |A|/|S| = 6/36 = 1/6$.
- 3) L'événement B (dé rouge montre 3) est $B = \{(3, 1), (3, 2), (3, 3), (3, 4), (3, 5), (3, 6)\}$. Il y a $|B| = 6$ issues favorables. La probabilité est $P(B) = |B|/|S| = 6/36 = 1/6$.
- 4) L'événement $A \cap B$ est l'ensemble des issues où la somme est 7 ET le dé rouge est 3. La seule issue possible est $(3, 4)$. Donc $A \cap B = \{(3, 4)\}$. La probabilité est $P(A \cap B) = |A \cap B|/|S| = 1/36$.

Correction Exercice 2 : Tirage de Cartes (Prob. Naïve)

Le nombre total d'issues est $|S| = 52$.

- a) Il y a 4 Rois. $P(\text{Roi}) = 4/52 = 1/13$.
- b) Il y a 26 cartes rouges (13 Cœurs + 13 Carreaux). $P(\text{Rouge}) = 26/52 = 1/2$.
- c) Il y a 12 figures (4 Valets + 4 Dames + 4 Rois). $P(\text{Figure}) = 12/52 = 3/13$.
- d) Il y a 2 As rouges (As de Cœur, As de Carreau). $P(\text{As Rouge}) = 2/52 = 1/26$.

Correction Exercice 3 : Urne Simple (Prob. Naïve)

Le nombre total de boules est $5 + 3 + 2 = 10$.

- a) Il y a 3 boules bleues. $P(\text{Bleue}) = 3/10$.
- b) L'événement "ne pas être verte" est le complémentaire de "être verte". Il y a 2 boules vertes, donc $P(\text{Verte}) = 2/10$. La probabilité cherchée est $P(\text{Non Verte}) = 1 - P(\text{Verte}) = 1 - 2/10 = 8/10 = 4/5$. (Alternativement, il y a $5 + 3 = 8$ boules non vertes, donc $P = 8/10$).

Correction Exercice 4 : Anagrammes (Permutation Simple)

Le mot "MATHS" a 5 lettres distinctes. Le nombre d'anagrammes est le nombre de permutations de ces 5 lettres, soit $5! = 5 \times 4 \times 3 \times 2 \times 1 = 120$.

Correction Exercice 5 : Course (Arrangement)

On cherche le nombre de façons d'ordonner 3 athlètes parmi 10. C'est un arrangement (permutation de k parmi n) : $P(10, 3) = \frac{10!}{(10-3)!} = \frac{10!}{7!} = 10 \times 9 \times 8 = 720$. Il y a 720 podiums possibles.

Correction Exercice 6 : Anagrammes (Permutation avec Répétition)

Le mot "PROBABILITE" a 11 lettres. Les répétitions sont : B (2 fois), I (2 fois). Les autres lettres (P, R, O, A, L, T, E) apparaissent une fois. Le nombre d'anagrammes distinctes est :

$$\frac{11!}{2! \times 2!} = \frac{39,916,800}{2 \times 2} = \frac{39,916,800}{4} = 9,979,200$$

Correction Exercice 7 : Choix d'un Comité (Combinaison)

L'ordre ne compte pas, c'est donc une combinaison de 4 étudiants parmi 15 :

$$\binom{15}{4} = \frac{15!}{4!(15-4)!} = \frac{15!}{4!11!} = \frac{15 \times 14 \times 13 \times 12}{4 \times 3 \times 2 \times 1} = 15 \times 7 \times 13 \times 1 = 1365$$

Il y a 1365 comités possibles.

Correction Exercice 8 : Mains de Poker (Combinaison)

On choisit 5 cartes parmi 52, sans ordre. C'est une combinaison :

$$\binom{52}{5} = \frac{52!}{5!(52-5)!} = \frac{52!}{5!47!} = \frac{52 \times 51 \times 50 \times 49 \times 48}{5 \times 4 \times 3 \times 2 \times 1} = 2,598,960$$

Il y a 2,598,960 mains de poker possibles.

Correction Exercice 9 : Comité Mixte (Combinaison)

Il faut choisir 2 hommes parmi 6 ET 1 femme parmi 4. On multiplie les possibilités pour chaque choix : Nombre de façons = (choix des hommes) \times (choix des femmes)

$$= \binom{6}{2} \times \binom{4}{1} = \frac{6 \times 5}{2 \times 1} \times \frac{4}{1} = 15 \times 4 = 60$$

Il y a 60 comités possibles.

Correction Exercice 10 : Probabilité avec Combinaisons

L'univers S est l'ensemble de toutes les mains de 3 cartes. $|S| = \binom{52}{3}$. L'événement A est "obtenir exactement 2 Rois". Pour cela, il faut choisir 2 Rois parmi les 4 Rois ET 1 carte qui n'est pas un Roi parmi les 48 autres cartes. $|A| = \binom{4}{2} \times \binom{48}{1}$. La probabilité est $P(A) = \frac{|A|}{|S|} = \frac{\binom{4}{2}\binom{48}{1}}{\binom{52}{3}}$.

$$P(A) = \frac{\frac{4 \times 3}{2 \times 1} \times 48}{\frac{52 \times 51 \times 50}{3 \times 2 \times 1}} = \frac{6 \times 48}{22100} = \frac{288}{22100} \approx 0.013$$

Correction Exercice 11 : Distribution de Bonbons (Étoiles et Bâtons)

C'est un problème de distribution de $k = 8$ objets identiques (bonbons) dans $n = 3$ boîtes distinctes (enfants). On utilise la formule $\binom{n+k-1}{k}$. Nombre de manières = $\binom{3+8-1}{8} = \binom{10}{8} = \binom{10}{2} = \frac{10 \times 9}{2 \times 1} = 45$.

Correction Exercice 12 : Solutions d'Équation (Étoiles et Bâtons)

Cela revient à distribuer $k = 10$ unités identiques dans $n = 4$ variables distinctes. Nombre de solutions = $\binom{n+k-1}{k} = \binom{4+10-1}{10} = \binom{13}{10} = \binom{13}{3} = \frac{13 \times 12 \times 11}{3 \times 2 \times 1} = 286$.

Correction Exercice 13 : Distribution avec Minimum (Étoiles et Bâtons avec Contrainte)

On doit distribuer $k = 12$ pommes à $n = 4$ enfants, avec $x_i \geq 1$. On commence par donner une pomme à chaque enfant. Il reste $12 - 4 = 8$ pommes à distribuer sans contrainte (les x'_i peuvent être nuls). Le problème devient : distribuer $k' = 8$ pommes à $n = 4$ enfants. Nombre de manières $= \binom{n+k'-1}{k'} = \binom{4+8-1}{8} = \binom{11}{8} = \binom{11}{3} = \frac{11 \times 10 \times 9}{3 \times 2 \times 1} = 165$.

Correction Exercice 14 : Divisibilité (Inclusion-Exclusion 2 Ensembles)

Soit A l'ensemble des entiers ≤ 100 divisibles par 2, et B l'ensemble des entiers ≤ 100 divisibles par 3. On cherche $|A \cup B|$. $|A| = \lfloor 100/2 \rfloor = 50$. $|B| = \lfloor 100/3 \rfloor = 33$. $|A \cap B|$ = ensemble des entiers divisibles par $2 \times 3 = 6$. $|A \cap B| = \lfloor 100/6 \rfloor = 16$. Par inclusion-exclusion : $|A \cup B| = |A| + |B| - |A \cap B| = 50 + 33 - 16 = 67$.

Correction Exercice 15 : Langues (Inclusion-Exclusion 2 Ensembles)

Soit E l'ensemble des étudiants étudiant l'anglais, S l'ensemble de ceux étudiant l'espagnol. $|E| = 30$, $|S| = 25$, $|E \cap S| = 10$. Nombre d'étudiants étudiant au moins une langue : $|E \cup S| = |E| + |S| - |E \cap S| = 30 + 25 - 10 = 45$. Nombre total d'étudiants = 50. Nombre d'étudiants n'étudiant aucune de ces langues = Total - $|E \cup S| = 50 - 45 = 5$.

Correction Exercice 16 : Divisibilité (Inclusion-Exclusion 3 Ensembles)

Soit A_2, A_3, A_5 les ensembles des entiers ≤ 100 divisibles respectivement par 2, 3, 5. On cherche $|A_2 \cup A_3 \cup A_5|$. $|A_2| = 50$, $|A_3| = 33$, $|A_5| = 20$. $|A_2 \cap A_3| = |A_6| = \lfloor 100/6 \rfloor = 16$. $|A_2 \cap A_5| = |A_{10}| = \lfloor 100/10 \rfloor = 10$. $|A_3 \cap A_5| = |A_{15}| = \lfloor 100/15 \rfloor = 6$. $|A_2 \cap A_3 \cap A_5| = |A_{30}| = \lfloor 100/30 \rfloor = 3$. Par inclusion-exclusion : $|A_2 \cup A_3 \cup A_5| = (|A_2| + |A_3| + |A_5|) - (|A_2 \cap A_3| + |A_2 \cap A_5| + |A_3 \cap A_5|) + |A_2 \cap A_3 \cap A_5| = (50 + 33 + 20) - (16 + 10 + 6) + 3 = 103 - 32 + 3 = 74$.

Correction Exercice 17 : Chemins sur un Grillage (Combinaison)

Pour aller de $(0,0)$ à $(4,3)$, il faut faire un total de $4 + 3 = 7$ déplacements. Parmi ces 7 déplacements, il faut choisir les 4 moments où l'on va à droite (les 3 autres seront obligatoirement vers le haut), ou choisir les 3 moments où l'on va vers le haut. Le nombre de chemins est $\binom{7}{4} = \binom{7}{3} = \frac{7 \times 6 \times 5}{3 \times 2 \times 1} = 35$.

Correction Exercice 18 : Probabilité Hypergéométrique

C'est un tirage sans remise. On peut utiliser la loi hypergéométrique ou le dénombrement. Population totale = $7 + 5 = 12$ boules. On en tire $m = 4$. On veut $k = 2$ blanches (parmi $w = 7$) et $m - k = 2$ noires (parmi $b = 5$). Probabilité = $\frac{\binom{w}{k} \binom{b}{m-k}}{\binom{w+b}{m}} = \frac{\binom{7}{2} \binom{5}{2}}{\binom{12}{4}}$.

$$P = \frac{\binom{7 \times 6}{2} \times \binom{5 \times 4}{2}}{\binom{12 \times 11 \times 10 \times 9}{4 \times 3 \times 2 \times 1}} = \frac{21 \times 10}{495} = \frac{210}{495} = \frac{14}{33} \approx 0.424$$

Correction Exercice 19 : Arrangement Circulaire

Pour n objets distincts, le nombre d'arrangements circulaires est $(n-1)!$. Ici, $n = 6$. Le nombre de manières est $(6-1)! = 5! = 120$. L'idée est de fixer une personne, puis d'arranger les 5 autres par rapport à elle.

Correction Exercice 20 : Problème des Dérangements (Inclusion-Exclusion)

On cherche le nombre de dérangements de 4 éléments, noté D_4 ou $!4$. La probabilité sera $D_4/4!$. La formule générale des dérangements (obtenue par inclusion-exclusion) est $D_n = n! \sum_{i=0}^n \frac{(-1)^i}{i!}$. Pour $n = 4$: $D_4 = 4!(1/0! - 1/1! + 1/2! - 1/3! + 1/4!)$ $D_4 = 24(1 - 1 + 1/2 - 1/6 + 1/24)$ $D_4 = 24(1/2 - 1/6 + 1/24) = 24(12/24 - 4/24 + 1/24) = 24(9/24) = 9$. Il y a 9 dérangements possibles sur un total de $4! = 24$ permutations. La probabilité est $P(\text{aucun match}) = D_4/4! = 9/24 = 3/8 = 0.375$.

1.10 Exercices Pratiques (Python)

Ces exercices vous aideront à appliquer les concepts de dénombrement et de probabilité naïve en utilisant les bibliothèques Python.

Pour ces exercices, vous aurez besoin de quelques bibliothèques. `math` et `itertools` sont incluses dans Python. Pour le premier exercice, vous aurez besoin de `scikit-learn` :

```
pip install scikit-learn pandas
```

Exercice 1 : Définition Naïve (Dataset Iris)

Le dataset "Iris" contient 150 observations de fleurs, réparties équitablement en 3 espèces (50 de chaque). Nous allons l'utiliser pour appliquer la définition naïve de la probabilité.

Code utile (chargement des données) :

```
from sklearn.datasets import load_iris
import pandas as pd

# Charger le dataset
iris = load_iris()
iris_df = pd.DataFrame(data=iris.data, columns=iris.feature_names)
iris_df['species'] = iris.target

# Le mapping des especes est : 0 = setosa, 1 = versicolor, 2 = virginica
# print(iris_df['species'].value_counts())
```

Votre tâche :

1. Définissez l'univers S . Quelle est sa taille, $|S|$? (Le nombre total de fleurs).
2. Définissez l'événement $A = \text{"la fleur est de l'espèce 'setosa' (target == 0)"}.$ Quelle est la taille de $|A|$?
3. Calculez $P(A)$ en utilisant la définition naïve : $P(A) = |A|/|S|$.
4. Calculez $P(B)$ pour l'événement $B = \text{"la fleur est de l'espèce 'versicolor' (target == 1)"}.$

Exercice 2 : Permutations (Arrangements)

En Python, le module `math` fournit `math.perm(n, k)` pour calculer $P(n, k)$, et le module `itertools` fournit `itertools.permutations` pour les générer.

Votre tâche : Un groupe de 5 coureurs (A, B, C, D, E) participe à une course.

1. En utilisant `math.perm`, calculez combien de podiums (1er, 2e, 3e) différents sont possibles.
2. Utilisez `itertools.permutations` pour générer la liste de tous les podiums possibles.
3. Vérifiez que la longueur de la liste générée à l'étape 2 est égale au nombre calculé à l'étape 1.

```
import math
from itertools import permutations

coureurs = ['A', 'B', 'C', 'D', 'E']
n = len(coureurs)
k = 3 # Podium

# 1. Calculer avec math.perm
# ... votre code ...

# 2. Generer les listes
podiums_list = list(permutations(coureurs, k))
# print(f"Quelques podiums: {podiums_list[:5]}")

# 3. Verifier
# ... votre code ...
```


2 Probabilité conditionnelle

Intuition : Question Fondamentale

La probabilité conditionnelle est le concept qui répond à la question fondamentale : comment devons-nous mettre à jour nos croyances à la lumière des nouvelles informations que nous observons ?

Ce concept de "mise à jour des croyances" est le cœur de la statistique moderne. Il s'agit de quantifier comment une nouvelle information B affecte la probabilité d'un événement A .

2.1 Définition de la Probabilité Conditionnelle

Commençons par la définition formelle.

Définition : Probabilité Conditionnelle

Si A et B sont deux événements avec $P(B) > 0$, alors la probabilité conditionnelle de A sachant B , notée $P(A|B)$, est définie comme :

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Cette formule n'est pas sortie de nulle part. Elle représente une "réduction de l'univers" :

Intuition

Imaginez que l'ensemble de tous les résultats possibles est un grand terrain. Savoir que l'événement B s'est produit, c'est comme si on vous disait que le résultat se trouve dans une zone spécifique de ce terrain. La probabilité conditionnelle $P(A|B)$ ne s'intéresse plus au terrain entier, mais seulement à la proportion de la zone B qui est également occupée par A . On "zoome" sur le monde où B est vrai, et on recalcule les probabilités dans ce nouveau monde plus petit.

2.2 Règle du Produit (Intersection de deux événements)

En réarrangeant simplement les termes de la définition, nous obtenons une règle fondamentale pour calculer la probabilité que deux événements se produisent *ensemble*.

Théorème : Probabilité de l'intersection de deux événements

Pour tous événements A et B avec des probabilités positives, nous avons :

$$P(A \cap B) = P(A)P(B|A) = P(B)P(A|B)$$

Cela découle directement de la définition de la probabilité conditionnelle.

La preuve est une simple réorganisation algébrique :

Preuve

La preuve est une simple réorganisation algébrique de la définition de la probabilité conditionnelle. Par définition, nous avons :

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

En multipliant les deux côtés par $P(B)$, on obtient :

$$P(A \cap B) = P(B)P(A|B)$$

De même, en partant de $P(B|A) = \frac{P(B \cap A)}{P(A)}$, on obtient :

$$P(A \cap B) = P(A)P(B|A)$$

(puisque $P(A \cap B) = P(B \cap A)$).

Cette formule exprime mathématiquement l'idée séquentielle suivante :

Intuition

Pour que deux événements se produisent, le premier doit se produire, PUIS le second doit se produire, sachant que le premier a eu lieu.

Cette règle est particulièrement utile pour les tirages sans remise, où la probabilité du second événement dépend du résultat du premier.

Exemple

Quelle est la probabilité de tirer deux As d'un jeu de 52 cartes sans remise ? Soit A l'événement "le premier tirage est un As", avec $P(A) = \frac{4}{52}$. Soit B l'événement "le deuxième tirage est un As". Nous cherchons $P(A \cap B)$, que l'on calcule avec la formule $P(A \cap B) = P(A) \times P(B|A)$. La probabilité $P(B|A)$ correspond à tirer un As sachant que la première carte était un As. Il reste alors 51 cartes, dont 3 As. Donc, $P(B|A) = \frac{3}{51}$. Finalement, la probabilité de l'intersection est $P(A \cap B) = \frac{4}{52} \times \frac{3}{51} = \frac{12}{2652} \approx 0.0045$.

2.3 Règle de la Chaîne (Intersection de n événements)

On peut logiquement étendre cette règle de deux à n événements.

Théorème : Probabilité de l'intersection de n événements

Pour tous événements A_1, \dots, A_n avec $P(A_1 \cap A_2 \cap \dots \cap A_{n-1}) > 0$, nous avons :

$$P(A_1 \cap \dots \cap A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 \cap A_2) \dots P(A_n|A_1 \cap \dots \cap A_{n-1})$$

La preuve se fait par une simple récurrence :

Preuve : Preuve par récurrence

Nous pouvons prouver cela par une application répétée de la règle du produit pour deux événements.

Cas de base (n=2) : $P(A_1 \cap A_2) = P(A_1)P(A_2|A_1)$. C'est le théorème précédent.

Étape (n=3) : Traitons $(A_1 \cap A_2)$ comme un seul événement :

$$\begin{aligned} P(A_1 \cap A_2 \cap A_3) &= P((A_1 \cap A_2) \cap A_3) \\ &= P(A_1 \cap A_2) \times P(A_3|A_1 \cap A_2) \\ &= (P(A_1)P(A_2|A_1)) \times P(A_3|A_1 \cap A_2) \end{aligned}$$

Généralisation : En continuant ce processus, on voit que pour ajouter A_n , on multiplie par la probabilité de A_n conditionnée par l'intersection de tous les événements précédents $(A_1 \cap \dots \cap A_{n-1})$.

Cette "règle de la chaîne" (chain rule) est cruciale pour les processus stochastiques :

Intuition

Pour qu'une séquence d'événements se produise, chaque événement doit se réaliser tour à tour, en tenant compte de tous les événements précédents qui se sont déjà produits.

Reprenons l'exemple des cartes, mais en continuant le tirage :

Exemple

On tire 3 cartes sans remise. Quelle est la probabilité d'obtenir la séquence Roi, Dame, Valet ? La probabilité de tirer un Roi en premier (A_1) est $P(A_1) = \frac{4}{52}$. Ensuite, la probabilité de tirer une Dame (A_2) sachant qu'un Roi a été tiré est $P(A_2|A_1) = \frac{4}{51}$. Enfin, la probabilité de tirer un Valet (A_3) sachant qu'un Roi et une Dame ont été tirés est $P(A_3|A_1 \cap A_2) = \frac{4}{50}$. La probabilité totale de la séquence est donc le produit de ces probabilités : $P(A_1 \cap A_2 \cap A_3) = \frac{4}{52} \times \frac{4}{51} \times \frac{4}{50} \approx 0.00048$.

2.4 Règle de Bayes

La règle du produit est aussi la pierre angulaire de la formule la plus célèbre des probabilités conditionnelles, qui nous permet d'inverser la condition.

Théorème : Règle de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

La preuve est élégante car elle utilise simplement la symétrie de l'intersection :

Preuve

La preuve découle de l'égalité de la règle du produit. Nous savons que :

1. $P(A \cap B) = P(A|B)P(B)$
2. $P(A \cap B) = P(B|A)P(A)$

En égalisant ces deux expressions, on a :

$$P(A|B)P(B) = P(B|A)P(A)$$

En supposant $P(B) > 0$ et en divisant par $P(B)$, on obtient :

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

L'importance de cette formule ne peut être sous-estimée :

Intuition

La règle de Bayes est la formule pour "inverser" une probabilité conditionnelle. Souvent, il est facile de connaître la probabilité d'un effet étant donné une cause ($P(\text{symptôme}|\text{maladie})$), mais ce qui nous intéresse vraiment, c'est la probabilité de la cause étant donné l'effet observé ($P(\text{maladie}|\text{symptôme})$). La règle de Bayes nous permet de faire ce retournement en utilisant notre connaissance initiale de la probabilité de la cause ($P(\text{maladie})$). C'est le fondement mathématique de la mise à jour de nos croyances.

2.5 Formule des Probabilités Totales

Le dénominateur $P(B)$ dans la règle de Bayes est souvent inconnu. Pour le trouver, nous avons besoin d'un autre outil puissant.

Théorème : Formule des probabilités totales

Soit A_1, \dots, A_n une partition de l'espace échantillon S (c'est-à-dire que les A_i sont des événements disjoints et leur union est S), avec $P(A_i) > 0$ pour tout i . Alors pour tout événement B :

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

La démonstration repose sur la décomposition de l'événement B sur la partition A_i .

Preuve : Démonstration de la formule des probabilités totales

Puisque les A_i forment une partition de S , on peut décomposer B comme :

$$B = (B \cap A_1) \cup (B \cap A_2) \cup \dots \cup (B \cap A_n)$$

Comme les A_i sont disjoints, les événements $(B \cap A_i)$ le sont aussi. On peut donc sommer leurs probabilités :

$$P(B) = P(B \cap A_1) + P(B \cap A_2) + \dots + P(B \cap A_n)$$


En appliquant le théorème de l'intersection des probabilités à chaque terme, on obtient :

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + \dots + P(B|A_n)P(A_n) = \sum_{i=1}^n P(B|A_i)P(A_i)$$

Visuellement, cette formule consiste à "découper" l'événement B et à additionner les morceaux :

Intuition

C'est une stratégie de "diviser pour régner". Pour calculer la probabilité totale d'un événement B , on peut décomposer le monde en plusieurs scénarios mutuellement exclusifs (la partition A_i). On calcule ensuite la probabilité de B dans chacun de ces scénarios ($P(B|A_i)$), on pondère chaque résultat par la probabilité du scénario en question ($P(A_i)$), et on additionne le tout.



L'exemple de l'usine est un cas d'école pour cette formule :

Exemple

Une usine possède trois machines, $M1$, $M2$, et $M3$, qui produisent respectivement 50%, 30% et 20% des articles. Leurs taux de production défectueuse sont de 4%, 2% et 5%. Quelle est la probabilité qu'un article choisi au hasard soit défectueux? Soit D l'événement "l'article est défectueux". Les machines forment une partition avec $P(M1) = 0.5$, $P(M2) = 0.3$, et $P(M3) = 0.2$. Les probabilités conditionnelles de défaut sont $P(D|M1) = 0.04$, $P(D|M2) = 0.02$, et $P(D|M3) = 0.05$. En appliquant la formule, on obtient : $P(D) = P(D|M1)P(M1) + P(D|M2)P(M2) + P(D|M3)P(M3) = (0.04 \times 0.5) + (0.02 \times 0.3) + (0.05 \times 0.2) = 0.02 + 0.006 + 0.01 = 0.036$. La probabilité qu'un article soit défectueux est de 3.6%.

Maintenant, nous pouvons combiner la Règle de Bayes et la Formule des Probabilités Totales pour résoudre des problèmes complexes, comme celui du dépistage médical.

Exemple : Application Combinée : Bayes et Probabilités Totales

Une maladie touche 1% de la population ($P(M) = 0.01$). Un test de dépistage est fiable à 95% : il est positif pour 95% des malades ($P(T|M) = 0.95$) et négatif pour 95% des non-malades, ce qui implique un taux de faux positifs de $P(T|\neg M) = 0.05$. Une personne est testée positive. Quelle est la probabilité qu'elle soit réellement malade, $P(M|T)$?

On cherche $P(M|T) = \frac{P(T|M)P(M)}{P(T)}$.

D'abord, on calcule $P(T)$ avec la formule des probabilités totales (la partition est $\{M, \neg M\}$) : $P(T) = P(T|M)P(M) + P(T|\neg M)P(\neg M) = (0.95 \times 0.01) + (0.05 \times 0.99) = 0.0095 + 0.0495 = 0.059$.

Ensuite, on applique la règle de Bayes : $P(M|T) = \frac{0.95 \times 0.01}{0.059} \approx 0.161$. Malgré un test positif, il n'y a que 16.1% de chance que la personne soit malade.

2.6 Règle de Bayes avec Conditionnement Additionnel

Les règles que nous venons de voir (Bayes, Probabilités Totales) fonctionnent aussi si nous avons déjà une information de base E .

Théorème : Règle de Bayes avec conditionnement additionnel

À condition que $P(A \cap E) > 0$ et $P(B \cap E) > 0$, nous avons :

$$P(A|B, E) = \frac{P(B|A, E)P(A|E)}{P(B|E)}$$

La preuve consiste à appliquer la définition de la probabilité conditionnelle à un univers déjà restreint par E .

Preuve

La preuve est identique à celle de la règle de Bayes standard, mais en appliquant la définition de la probabilité conditionnelle à un univers restreint E .

$$P(A|B, E) = P(A|(B \cap E)) = \frac{P(A \cap (B \cap E))}{P(B \cap E)}$$

$$P(B|A, E) = P(B|(A \cap E)) = \frac{P(B \cap (A \cap E))}{P(A \cap E)}$$

De la première équation : $P(A \cap B \cap E) = P(A|B, E)P(B \cap E)$. De la seconde : $P(A \cap B \cap E) = P(B|A, E)P(A \cap E)$. En égalisant : $P(A|B, E)P(B \cap E) = P(B|A, E)P(A \cap E)$. D'où : $P(A|B, E) = \frac{P(B|A, E)P(A \cap E)}{P(B \cap E)}$. En utilisant $P(X \cap Y) = P(X|Y)P(Y)$, on a $P(A \cap E) = P(A|E)P(E)$ et $P(B \cap E) = P(B|E)P(E)$.

$$P(A|B, E) = \frac{P(B|A, E)P(A|E)P(E)}{P(B|E)P(E)} = \frac{P(B|A, E)P(A|E)}{P(B|E)}$$

Cette formule peut sembler intimidante, mais elle signifie simplement que nous appliquons la même logique dans un "sous-monde" :

Intuition

Cette formule est simplement la règle de Bayes standard, mais appliquée à l'intérieur d'un univers que l'on a déjà "rétréci".

Imaginez que vous recevez une information **E** qui élimine une grande partie des possibilités. C'est votre nouveau point de départ, votre monde est plus petit. Toutes les probabilités que vous calculez désormais sont relatives à ce monde restreint.

Dans ce nouveau monde, vous recevez une autre information, l'évidence **B**. La règle de Bayes conditionnelle vous permet alors de mettre à jour votre croyance sur un événement **A**, en utilisant exactement la même logique que la règle de Bayes classique, mais en vous assurant que chaque calcul reste confiné à l'intérieur des frontières de l'univers défini par **E**.

2.7 Formule des Probabilités Totales avec Conditionnement Additionnel

De même, la loi des probabilités totales s'adapte à ce nouvel univers restreint.

Théorème : Formule des probabilités totales avec conditionnement additionnel

Soit A_1, \dots, A_n une partition de S . À condition que $P(A_i \cap E) > 0$ pour tout i , nous avons :

$$P(B|E) = \sum_{i=1}^n P(B|A_i, E)P(A_i|E)$$

La démonstration est une application directe de la formule standard, mais à l'intérieur de l'univers E .

Preuve

La preuve suit celle de la formule des probabilités totales standard, mais tout est conditionné par E . Soit $P_E(\cdot)$ une mesure de probabilité définie par $P_E(X) = P(X|E)$. Les A_i forment une partition de S , donc les $(A_i \cap E)$ forment une partition de E . On applique la formule standard

à $B \cap E$:

$$P(B|E) = \sum_{i=1}^n P(B \cap A_i|E)$$

Par la définition de la probabilité conditionnelle :


$$P(B \cap A_i|E) = \frac{P(B \cap A_i \cap E)}{P(E)}$$

Et $P(B|A_i, E)P(A_i|E) = \frac{P(B \cap A_i \cap E)}{P(A_i \cap E)} \times \frac{P(A_i \cap E)}{P(E)} = \frac{P(B \cap A_i \cap E)}{P(E)}$ Les deux termes sont égaux, donc :

$$P(B|E) = \sum_{i=1}^n P(B|A_i, E)P(A_i|E)$$

L'exemple visuel de la carte au trésor illustre parfaitement cette double-conditionnalité :

Intuition



Imaginez que le graphique ci-dessus représente la carte d'un trésor. La carte est partitionnée en trois grandes régions : **A1**, **A2**, et **A3**. Sur cette carte, on a identifié deux types de terrains : une **zone marécageuse** (événement E, hachures rouges) qui s'étend sur **10 parcelles**, et une **zone près d'un vieux chêne** (événement B, hachures bleues) qui couvre **3 parcelles**.

On vous donne un premier indice : "Le trésor est dans la zone marécageuse (E)". Votre univers de recherche se réduit instantanément à ces 10 parcelles rouges. Puis, on vous donne un second indice : "Le trésor est aussi près d'un chêne (B)". Votre recherche se concentre alors sur les parcelles qui sont à la fois marécageuses et proches d'un chêne (les cases violettes, $B \cap E$).

La question est : "Sachant que le trésor est dans une parcelle violette, quelle est la probabilité qu'il se trouve dans la région A2?". On cherche donc $P(A_2|B, E)$. La règle de Bayes nous permet de le calculer.

Calcul des termes nécessaires : D'abord, nous devons évaluer les probabilités à l'intérieur du "monde marécageux" (sachant E).

La **vraisemblance** est $P(B|A_2, E)$. En se limitant aux 4 parcelles marécageuses de la région A2, une seule est aussi près d'un chêne. Donc, $P(B|A_2, E) = 1/4$.

La **probabilité a priori** est $P(A_2|E)$. Sur les 10 parcelles marécageuses, 4 sont dans la région A2. Donc, $P(A_2|E) = 4/10$.

L'**évidence**, $P(B|E)$, est la probabilité de trouver un chêne dans l'ensemble de la zone marécageuse. On peut la calculer avec la formule des probabilités totales :

$$P(B|E) = P(B|A_1, E)P(A_1|E) + P(B|A_2, E)P(A_2|E) + P(B|A_3, E)P(A_3|E)$$

$$P(B|E) = \left(\frac{1}{3} \times \frac{3}{10}\right) + \left(\frac{1}{4} \times \frac{4}{10}\right) + \left(0 \times \frac{3}{10}\right) = \frac{1}{10} + \frac{1}{10} = \frac{2}{10}$$

Application de la règle de Bayes : Maintenant, nous assemblons le tout.

$$P(A_2|B, E) = \frac{P(B|A_2, E)P(A_2|E)}{P(B|E)} = \frac{(1/4) \times (4/10)}{2/10} = \frac{1/10}{2/10} = \frac{1}{2}$$

L'intuition confirme le calcul : sachant que le trésor est sur une parcelle violette, et qu'il n'y en a que deux (une en A1, une en A2), il y a bien une chance sur deux qu'il se trouve dans la région A2.

2.8 Indépendance de Deux Événements

Le concept d'indépendance est un cas spécial de probabilité conditionnelle où l'information B n'a aucun effet sur la probabilité de A .

Définition : Indépendance de deux événements

Les événements A et B sont indépendants si :

$$P(A \cap B) = P(A)P(B)$$

Si $P(A) > 0$ et $P(B) > 0$, cela est équivalent à :

$$P(A|B) = P(A)$$

En d'autres termes :

Intuition

L'indépendance est l'absence d'information. Si deux événements sont indépendants, apprendre que l'un s'est produit ne change absolument rien à la probabilité de l'autre. Savoir qu'il pleut à Tokyo (B) ne modifie pas la probabilité que vous obteniez pile en lançant une pièce (A).

2.9 Indépendance Conditionnelle

Attention : l'indépendance n'est pas la même chose que l'exclusion mutuelle. Il faut aussi se méfier de l'indépendance qui n'est qu'apparente, ou qui dépend d'une autre condition.

Définition : Indépendance Conditionnelle

Les événements A et B sont dits conditionnellement indépendants étant donné E si :

$$P(A \cap B|E) = P(A|E)P(B|E)$$

C'est un concept subtil mais crucial :

Intuition

L'indépendance peut apparaître ou disparaître quand on observe un autre événement. Par exemple, vos notes en maths (A) et en physique (B) ne sont probablement pas indépendantes. Mais si l'on sait que vous avez beaucoup travaillé (E), alors vos notes en maths et en physique pourraient devenir indépendantes. L'information "vous avez beaucoup travaillé" explique la corrélation ; une fois qu'on la connaît, connaître votre note en maths n'apporte plus d'information sur votre note en physique.

2.10 Le Problème de Monty Hall

Pour tester notre compréhension de tous ces concepts, le problème de Monty Hall est un exercice incontournable. Il met en lumière à quel point notre intuition sur la mise à jour des probabilités peut être faussée.

Remarque : Le problème de Monty Hall

Imaginez que vous êtes à un jeu télévisé. Face à vous se trouvent trois portes fermées. Derrière l'une d'elles se trouve une voiture, et derrière les deux autres, des chèvres.

1. Vous choisissez une porte (disons, la porte n°1).
2. L'animateur, qui sait où se trouve la voiture, ouvre une autre porte (par exemple, la n°3) derrière laquelle se trouve une chèvre.
3. Il vous demande alors : "Voulez-vous conserver votre choix initial (porte n°1) ou changer pour l'autre porte restante (la n°2) ?"

Question : Avez-vous intérêt à changer de porte ? Votre probabilité de gagner la voiture est-elle plus grande si vous changez, si vous ne changez pas, ou est-elle la même dans les deux cas ?

La réponse est contre-intuitive pour la plupart des gens, mais mathématiquement claire.

Solution du problème de Monty Hall

La réponse est sans équivoque : il faut **toujours changer de porte**. Cette stratégie fait passer la probabilité de gagner de $1/3$ à $2/3$. L'intuition et la preuve ci-dessous détaillent ce résultat surprenant.

Pourquoi ? L'erreur est de penser que l'animateur agit au hasard.

Intuition : Le secret : l'information de l'animateur


L'erreur commune est de supposer qu'il reste deux portes avec une chance égale de $1/2$. Cela ignore une information capitale : le choix de l'animateur n'est **pas aléatoire**. Il sait où se trouve la voiture et ouvrira toujours une porte perdante.

Le raisonnement correct se déroule en deux temps. D'abord, votre choix initial a $1/3$ de chance d'être correct. Cela implique qu'il y a $2/3$ de chance que la voiture soit derrière l'une des *deux autres portes*. Ensuite, lorsque l'animateur ouvre l'une de ces deux portes, il ne fait que vous montrer où la voiture n'est *pas* dans cet ensemble. La probabilité de $2/3$ se **concentre** alors entièrement sur la seule porte qu'il a laissée fermée. Changer de porte revient à miser sur cette probabilité de $2/3$.

La preuve la plus claire est de suivre les stratégies :

Preuve : Preuve par l'arbre de décision

L'analyse de la meilleure stratégie peut être visualisée à l'aide de l'arbre de décision ci-dessous. Il décompose le problème en deux scénarios initiaux : avoir choisi la bonne porte (probabilité $1/3$) ou une mauvaise porte (probabilité $2/3$).



Analyse de l'arbre :

Branche du bas (cas le plus probable) : Avec une probabilité de $2/3$, votre choix initial se porte sur une "Mauvaise porte". L'animateur est alors obligé de révéler l'autre porte perdante. La seule porte restante est donc la bonne. L'arbre montre que cela mène à un "Gain" avec une probabilité de 1 . Ce chemin correspond au résultat de la stratégie **"Changer"**.

Branche du haut (cas le moins probable) : Avec une probabilité de $1/3$, vous avez choisi la "Bonne porte" du premier coup. L'arbre se divise alors en deux issues équiprobables ($1/2$ chacune). L'issue "Gain" correspond à la stratégie **"Garder"** votre choix initial, tandis que l'issue "Perte" correspond à la stratégie **"Changer"** pour la porte perdante restante.

Conclusion : Pour évaluer la meilleure stratégie, il suffit de sommer les probabilités de gain. La **probabilité de gain en changeant** est de $2/3$, car vous gagnez uniquement si votre choix initial était mauvais (branche du bas). La **probabilité de gain en gardant** est de $1/3$, car vous gagnez uniquement si votre choix initial était bon (branche "Gain" du haut). La stratégie optimale est donc bien de toujours changer de porte.

2.11 Exercices

Exercice 1 : Dés et Probabilité Conditionnelle Simple

On lance deux dés équilibrés à 6 faces.

1. Quelle est la probabilité que la somme des dés soit 8 ?
2. Sachant que le premier dé a donné un 3, quelle est la probabilité que la somme soit 8 ?
3. Sachant que la somme est 8, quelle est la probabilité que le premier dé ait donné un 3 ?

Exercice 2 : Tirage de Cartes (Sans Remise)

On tire deux cartes successivement et sans remise d'un jeu standard de 52 cartes.

1. Quelle est la probabilité que la deuxième carte soit un Roi, sachant que la première était un Roi ?
2. Quelle est la probabilité de tirer deux Rois ?

Exercice 3 : Urne (Règle du Produit)

Une urne contient 7 boules rouges et 3 boules bleues. On tire deux boules successivement et sans remise.

1. Quelle est la probabilité que la première boule soit rouge ?
2. Quelle est la probabilité que la deuxième boule soit bleue, sachant que la première était rouge ?
3. Quelle est la probabilité de tirer une boule rouge puis une boule bleue ?

Exercice 4 : Famille (Condition Simple)

Une famille a deux enfants. On suppose que la probabilité d'avoir un garçon (G) ou une fille (F) est la même (0.5) et que les naissances sont indépendantes.

1. Quel est l'univers S des possibilités ?
2. Sachant que l'aîné est un garçon, quelle est la probabilité que la famille ait deux garçons ?

Exercice 5 : Famille (Condition "Au Moins")

En utilisant le même scénario que l'exercice 4 (famille de deux enfants) : Sachant qu'il y a *au moins un* garçon dans la famille, quelle est la probabilité que la famille ait deux garçons ?

Exercice 6 : Indépendance (Dés)

On lance deux dés équilibrés. Soit A l'événement "le premier dé donne 3" et B l'événement "la somme des deux dés est 7". Les événements A et B sont-ils indépendants ? Justifiez par le calcul.

Exercice 7 : Indépendance (Cartes)

On tire une carte d'un jeu de 52 cartes. Soit A l'événement "la carte est un Roi" et B l'événement "la carte est un Cœur". Les événements A et B sont-ils indépendants ?

Exercice 8 : Indépendance vs Exclusion Mutuelle

Soient A et B deux événements avec $P(A) = 0.5$ et $P(B) = 0.3$.

1. Si A et B sont mutuellement exclusifs (disjoints), sont-ils indépendants ?
2. Si A et B sont indépendants, quelle est $P(A \cup B)$?

Exercice 9 : LTP (Deux Urnes)

L'urne U_1 contient 2 boules noires et 3 boules blanches. L'urne U_2 contient 4 boules noires et 1 boule blanche. On choisit une urne au hasard (chaque urne a 50% de chance d'être choisie), puis on tire une boule de cette urne. Quelle est la probabilité de tirer une boule blanche ?

Exercice 10 : LTP (Usine)

Une usine utilise deux machines, M_1 et M_2 , pour produire des pièces. M_1 produit 40% des pièces et M_2 produit 60%. 5% des pièces de M_1 sont défectueuses, et 2% des pièces de M_2

sont défectueuses. Si l'on choisit une pièce au hasard dans la production totale, quelle est la probabilité qu'elle soit défectueuse ?

Exercice 11 : LTP (Pièce de Monnaie Inconnue)

On a deux pièces. La pièce A est équilibrée ($P(\text{Pile}) = 0.5$). La pièce B est truquée ($P(\text{Pile}) = 0.8$). On choisit une pièce au hasard et on la lance. Quelle est la probabilité d'obtenir Pile ?

Exercice 12 : Bayes (Test Médical)

Une maladie touche 1 personne sur 1000 ($P(M) = 0.001$). Un test de dépistage donne un résultat positif chez 98% des personnes malades ($P(T|M) = 0.98$). Il donne aussi un résultat positif (un "faux positif") chez 3% des personnes non malades ($P(T|\neg M) = 0.03$). Une personne reçoit un test positif. Quelle est la probabilité qu'elle soit réellement malade ?

Exercice 13 : Bayes (Inversion d'Urnes)

Reprenons le scénario de l'exercice 9 (U1 avec 2N/3B, U2 avec 4N/1B). On a tiré une boule et on constate qu'elle est blanche. Quelle est la probabilité qu'elle provienne de l'urne U1 ?

Exercice 14 : Bayes (Spam)

Dans une boîte de réception, 60% des emails sont des spams. 70% des spams contiennent le mot "gratuit". Seuls 10% des emails légitimes contiennent le mot "gratuit". Vous recevez un email qui contient le mot "gratuit". Quelle est la probabilité que ce soit un spam ?

Exercice 15 : Bayes (Usine Inversée)

Reprenons le scénario de l'exercice 10 (M1 : 40% prod, 5% défaut ; M2 : 60%). On trouve une pièce défectueuse. Quelle est la probabilité qu'elle ait été produite par la machine M1 ?

Exercice 16 : Règle de la Chaîne (3 Cartes)

On tire 3 cartes successivement et sans remise d'un jeu de 52 cartes. Quelle est la probabilité de tirer 3 Piques ?

Exercice 17 : Problème de Monty Hall (Calcul)

En utilisant la formalisation du problème de Monty Hall (vous choisissez la Porte 1, la voiture est en $V \in \{1, 2, 3\}$, l'animateur ouvre $H \in \{2, 3\}$) : Calculez $P(V = 1|H = 3)$ (la probabilité que la voiture soit derrière votre porte, sachant que l'animateur a ouvert la 3). Supposez que $P(V = i) = 1/3$ pour $i = 1, 2, 3$.

Exercice 18 : Bayes avec Mise à Jour (Pièce Truquée)

Reprenons l'exercice 11 (Pièce A équilibrée, Pièce B truquée $P(\text{Pile}) = 0.8$). On choisit une pièce au hasard. On la lance deux fois et on obtient Pile, puis Pile (PP). Quelle est la probabilité que l'on ait choisi la pièce truquée (Pièce B) ?

Exercice 19 : Indépendance Conditionnelle (Dés)

On lance deux dés, D_1 et D_2 . Soit $S = D_1 + D_2$ leur somme. Soit A l'événement " $D_1 = 1$ ", B l'événement " $D_2 = 1$ ". A et B sont indépendants. Sont-ils indépendants conditionnellement à l'événement $C = \{S = 2\}$?

Exercice 20 : Jeu Séquentiel

Alice et Bob jouent à un jeu. Ils lancent un dé à tour de rôle, en commençant par Alice. Le premier qui obtient un 6 gagne. Quelle est la probabilité qu'Alice gagne ?

2.12 Corrections des Exercices

Correction Exercice 1 : Dés et Probabilité Conditionnelle Simple

L'univers S a $|S| = 6 \times 6 = 36$ issues.

1. Soit A l'événement "la somme est 8". $A = \{(2, 6), (3, 5), (4, 4), (5, 3), (6, 2)\}$. $|A| = 5$, donc $P(A) = 5/36$.
2. Soit B l'événement "le premier dé donne 3". $B = \{(3, 1), (3, 2), (3, 3), (3, 4), (3, 5), (3, 6)\}$. On cherche $P(A|B)$. Sachant B , l'univers est réduit à ces 6 issues. Parmi celles-ci, seule l'issue $(3, 5)$ donne une somme de 8. Donc, $P(A|B) = 1/6$. *Par formule :* $A \cap B = \{(3, 5)\}$, $P(A \cap B) = 1/36$. $P(B) = 6/36 = 1/6$. $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{1/36}{1/6} = 1/6$.
3. On cherche $P(B|A)$. Sachant A , l'univers est réduit aux 5 issues de A . Parmi celles-ci, seule l'issue $(3, 5)$ a 3 sur le premier dé. Donc, $P(B|A) = 1/5$. *Par formule :* $P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{1/36}{5/36} = 1/5$.

Correction Exercice 2 : Tirage de Cartes (Sans Remise)

Soit K_1 l'événement "Roi au 1er tirage" et K_2 "Roi au 2e tirage".

1. On cherche $P(K_2|K_1)$. Si K_1 s'est produit, il reste 51 cartes dans le jeu, dont $4 - 1 = 3$ Rois. $P(K_2|K_1) = 3/51 = 1/17$.
2. On cherche $P(K_1 \cap K_2)$. On utilise la règle du produit : $P(K_1 \cap K_2) = P(K_1) \times P(K_2|K_1)$. $P(K_1) = 4/52 = 1/13$. $P(K_1 \cap K_2) = (4/52) \times (3/51) = (1/13) \times (1/17) = 1/221$.

Correction Exercice 3 : Urne (Règle du Produit)

Urne avec 7 Rouges (R) et 3 Bleues (B). Total = 10. Soit R_1 "Rouge au 1er tirage" et B_2 "Bleue au 2e tirage".

1. $P(R_1) = 7/10$.
2. On cherche $P(B_2|R_1)$. Si R_1 s'est produit, il reste 9 boules (6R, 3B). $P(B_2|R_1) = 3/9 = 1/3$.
3. On cherche $P(R_1 \cap B_2)$. $P(R_1 \cap B_2) = P(R_1) \times P(B_2|R_1) = (7/10) \times (1/3) = 7/30$.

Correction Exercice 4 : Famille (Condition Simple)

1. L'univers est $S = \{GG, GF, FG, FF\}$, où le premier enfant est l'aîné. $|S| = 4$, chaque issue a une probabilité de $1/4$.
2. Soit A l'événement "l'aîné est un garçon" : $A = \{GG, GF\}$. $P(A) = 2/4 = 1/2$. Soit B l'événement "la famille a deux garçons" : $B = \{GG\}$. $P(B) = 1/4$. On cherche $P(B|A)$. L'événement $A \cap B = \{GG\}$. $P(A \cap B) = 1/4$. $P(B|A) = \frac{P(A \cap B)}{P(A)} = \frac{1/4}{1/2} = 1/2$.

Correction Exercice 5 : Famille (Condition "Au Moins")

Soit B l'événement "la famille a deux garçons" : $B = \{GG\}$. Soit C l'événement "il y a au moins un garçon" : $C = \{GG, GF, FG\}$. $P(C) = 3/4$. On cherche $P(B|C)$. L'événement $B \cap C = \{GG\}$. $P(B \cap C) = 1/4$. $P(B|C) = \frac{P(B \cap C)}{P(C)} = \frac{1/4}{3/4} = 1/3$. *Intuition :* L'univers de C est $\{GG, GF, FG\}$. Parmi ces 3 issues équiprobables, une seule est GG .

Correction Exercice 6 : Indépendance (Dés)

A = "premier dé = 3". $P(A) = 6/36 = 1/6$. B = "somme = 7". $B = \{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}$. $P(B) = 6/36 = 1/6$. $A \cap B$ = "premier dé = 3 ET somme = 7" = $\{(3, 4)\}$. $P(A \cap B) = 1/36$. On teste si $P(A \cap B) = P(A)P(B)$. $P(A)P(B) = (1/6) \times (1/6) = 1/36$. Puisque $P(A \cap B) = P(A)P(B)$, les événements A et B sont indépendants.

Correction Exercice 7 : Indépendance (Cartes)

A = "Roi". $P(A) = 4/52 = 1/13$. B = "Cœur". $P(B) = 13/52 = 1/4$. $A \cap B$ = "Roi de Cœur". $P(A \cap B) = 1/52$. On teste si $P(A \cap B) = P(A)P(B)$. $P(A)P(B) = (1/13) \times (1/4) = 1/52$. Puisque $P(A \cap B) = P(A)P(B)$, les événements A et B sont indépendants.

Correction Exercice 8 : Indépendance vs Exclusion Mutuelle

$P(A) = 0.5, P(B) = 0.3$.

1. Si A et B sont mutuellement exclusifs, $A \cap B = \emptyset$, donc $P(A \cap B) = 0$. Pour qu'ils soient indépendants, il faudrait $P(A \cap B) = P(A)P(B) = 0.5 \times 0.3 = 0.15$. Puisque $0 \neq 0.15$, ils ne sont pas indépendants. (Deux événements non impossibles ne peuvent pas être à la fois mutuellement exclusifs et indépendants).
2. Si A et B sont indépendants, $P(A \cap B) = P(A)P(B) = 0.15$. $P(A \cup B) = P(A) + P(B) - P(A \cap B) = 0.5 + 0.3 - 0.15 = 0.65$.

Correction Exercice 9 : LTP (Deux Urnes)

Soit U_1 et U_2 les événements "choisir l'urne 1" et "choisir l'urne 2". $P(U_1) = 0.5, P(U_2) = 0.5$. Soit W l'événement "tirer une boule blanche". On a $P(W|U_1) = 3/(2+3) = 3/5 = 0.6$. On a $P(W|U_2) = 1/(4+1) = 1/5 = 0.2$. Par la formule des probabilités totales : $P(W) = P(W|U_1)P(U_1) + P(W|U_2)P(U_2)$ $P(W) = (0.6 \times 0.5) + (0.2 \times 0.5) = 0.3 + 0.1 = 0.4$.

Correction Exercice 10 : LTP (Usine)

Soit M_1 et M_2 les machines. $P(M_1) = 0.4, P(M_2) = 0.6$. Soit D l'événement "la pièce est défectueuse". On a $P(D|M_1) = 0.05$ et $P(D|M_2) = 0.02$. Par la formule des probabilités totales : $P(D) = P(D|M_1)P(M_1) + P(D|M_2)P(M_2)$ $P(D) = (0.05 \times 0.4) + (0.02 \times 0.6) = 0.020 + 0.012 = 0.032$. La probabilité est de 3.2%.

Correction Exercice 11 : LTP (Pièce de Monnaie Inconnue)

Soit A "choisir pièce A" et B "choisir pièce B". $P(A) = 0.5, P(B) = 0.5$. Soit H l'événement "obtenir Pile". On a $P(H|A) = 0.5$ et $P(H|B) = 0.8$. Par la formule des probabilités totales : $P(H) = P(H|A)P(A) + P(H|B)P(B)$ $P(H) = (0.5 \times 0.5) + (0.8 \times 0.5) = 0.25 + 0.40 = 0.65$.

Correction Exercice 12 : Bayes (Test Médical)

Soit M "Malade" et T "Test Positif". $P(M) = 0.001$, donc $P(\neg M) = 0.999$. $P(T|M) = 0.98$. $P(T|\neg M) = 0.03$. On cherche $P(M|T)$. Par la règle de Bayes : $P(M|T) = \frac{P(T|M)P(M)}{P(T)}$.

1. Calculer $P(T)$ (dénominateur) avec la LTP : $P(T) = P(T|M)P(M) + P(T|\neg M)P(\neg M)$ $P(T) = (0.98 \times 0.001) + (0.03 \times 0.999) = 0.00098 + 0.02997 = 0.03095$.
2. Appliquer la règle de Bayes : $P(M|T) = \frac{0.00098}{0.03095} \approx 0.03166$. Il n'y a que 3.17% de chance que la personne soit malade, même avec un test positif.

Correction Exercice 13 : Bayes (Inversion d'Urnes)

D'après l'exercice 9, on a : $P(W) = 0.4$ (prob. totale de tirer une blanche). $P(W|U_1) = 0.6$. $P(U_1) = 0.5$. On cherche $P(U_1|W)$. Par la règle de Bayes : $P(U_1|W) = \frac{P(W|U_1)P(U_1)}{P(W)} = \frac{0.6 \times 0.5}{0.4} = \frac{0.3}{0.4} = 0.75$. Sachant que la boule est blanche, il y a 75% de chance qu'elle vienne de l'urne U_1 .

Correction Exercice 14 : Bayes (Spam)

Soit S "Spam" et G "Contient 'gratuit'". $P(S) = 0.6$, donc $P(\neg S) = 0.4$. $P(G|S) = 0.7$. $P(G|\neg S) = 0.1$. On cherche $P(S|G)$. Par la règle de Bayes : $P(S|G) = \frac{P(G|S)P(S)}{P(G)}$.

1. Calculer $P(G)$ (dénominateur) avec la LTP : $P(G) = P(G|S)P(S) + P(G|\neg S)P(\neg S)$ $P(G) = (0.7 \times 0.6) + (0.1 \times 0.4) = 0.42 + 0.04 = 0.46$.
2. Appliquer la règle de Bayes : $P(S|G) = \frac{0.42}{0.46} \approx 0.913$. Il y a 91.3% de chance que l'email soit un spam.

Correction Exercice 15 : Bayes (Usine Inversée)

D'après l'exercice 10, on a : $P(D) = 0.032$ (prob. totale d'être défectueux). $P(D|M_1) = 0.05$. $P(M_1) = 0.4$. On cherche $P(M_1|D)$. Par la règle de Bayes : $P(M_1|D) = \frac{P(D|M_1)P(M_1)}{P(D)} = \frac{0.05 \times 0.4}{0.032} = \frac{0.02}{0.032} = 0.625$. Sachant que la pièce est défectueuse, il y a 62.5% de chance qu'elle vienne de M_1 .

Correction Exercice 16 : Règle de la Chaîne (3 Cartes)

Soit P_i l'événement "tirer un Pique au i -ème tirage". Il y a 13 Piques sur 52 cartes. On cherche $P(P_1 \cap P_2 \cap P_3)$. On utilise la règle de la chaîne : $P(P_1 \cap P_2 \cap P_3) = P(P_1) \times P(P_2|P_1) \times P(P_3|P_1 \cap P_2)$. $P(P_1) = 13/52$. $P(P_2|P_1) = 12/51$ (il reste 12 Piques sur 51 cartes). $P(P_3|P_1 \cap P_2) = 11/50$ (il reste 11 Piques sur 50 cartes). $P = (13/52) \times (12/51) \times (11/50) = \frac{1}{4} \times \frac{4}{17} \times \frac{11}{50} = \frac{11}{17 \times 50} = 11/850 \approx 0.0129$.

Correction Exercice 17 : Problème de Monty Hall (Calcul)

On cherche $P(V = 1|H = 3)$. On utilise la règle de Bayes : $P(V = 1|H = 3) = \frac{P(H=3|V=1)P(V=1)}{P(H=3)}$.

*Numérateur : $P(V = 1) = 1/3$. $P(H = 3|V = 1)$ est la probabilité que l'animateur ouvre la 3, sachant que vous avez choisi la 1 et que la voiture est en 1. Il peut ouvrir la 2 ou la 3 (deux chèvres). On suppose qu'il choisit au hasard : $P(H = 3|V = 1) = 1/2$. Numérateur = $(1/2) \times (1/3) = 1/6$.

*Dénominateur $P(H = 3)$ par LTP (partition sur V) : $P(H = 3) = P(H = 3|V = 1)P(V = 1) + P(H = 3|V = 2)P(V = 2) + P(H = 3|V = 3)P(V = 3)$. $P(H = 3|V = 1) = 1/2$ (calculé ci-dessus). $P(H = 3|V = 2) = 1$ (l'animateur doit ouvrir la 3, car vous avez choisi 1 et la voiture est en 2). $P(H = 3|V = 3) = 0$ (l'animateur ne peut pas ouvrir la porte 3 car elle contient la voiture). $P(H = 3) = (1/2 \times 1/3) + (1 \times 1/3) + (0 \times 1/3) = 1/6 + 1/3 + 0 = 1/2$.

*Résultat : $P(V = 1|H = 3) = \frac{1/6}{1/2} = 1/3$. (La probabilité que la voiture soit derrière votre porte reste $1/3$. La probabilité qu'elle soit derrière l'autre porte fermée (la 2) est $P(V = 2|H = 3) = 1 - P(V = 1|H = 3) = 2/3$. Il faut donc changer.)

Correction Exercice 18 : Bayes avec Mise à Jour (Pièce Truquée)

Soit A "pièce A (équil.)" et B "pièce B (truquée, $p=0.8$)". $P(A) = P(B) = 0.5$. Soit E l'événement "obtenir Pile, Pile" (PP). On cherche $P(B|E) = \frac{P(E|B)P(B)}{P(E)}$.

1. Probabilités conditionnelles de l'évidence E : $P(E|A) = P(PP|A) = 0.5 \times 0.5 = 0.25$ (indépendance des lancers). $P(E|B) = P(PP|B) = 0.8 \times 0.8 = 0.64$.

2. Calculer $P(E)$ (dénominateur) avec la LTP : $P(E) = P(E|A)P(A) + P(E|B)P(B)$. $P(E) = (0.25 \times 0.5) + (0.64 \times 0.5) = 0.125 + 0.320 = 0.445$.

3. Appliquer la règle de Bayes : $P(B|E) = \frac{P(E|B)P(B)}{P(E)} = \frac{0.64 \times 0.5}{0.445} = \frac{0.32}{0.445} \approx 0.719$. Après avoir observé PP, la probabilité que ce soit la pièce truquée passe de 50% à 71.9%.

Correction Exercice 19 : Indépendance Conditionnelle (Dés)

$A = \{D_1 = 1\}$, $B = \{D_2 = 1\}$, $C = \{S = 2\}$. On teste si $P(A \cap B|C) = P(A|C)P(B|C)$.

L'événement $C = \{S = 2\}$ ne peut se produire que d'une seule façon : $C = \{(1, 1)\}$. Donc, C est l'événement $A \cap B$. $C \subseteq A$ et $C \subseteq B$.

Calculons les termes : $P(A|C) = P(A \cap C)/P(C)$. Puisque $C \subseteq A$, $A \cap C = C$. $P(A|C) = P(C)/P(C) = 1$. $P(B|C) = P(B \cap C)/P(C)$. Puisque $C \subseteq B$, $B \cap C = C$. $P(B|C) = P(C)/P(C) = 1$. $P(A \cap B|C) = P((A \cap B) \cap C)/P(C)$. Puisque $A \cap B = C$, $(A \cap B) \cap C = C$. $P(A \cap B|C) = P(C)/P(C) = 1$.

Test d'indépendance : $P(A \cap B|C) = 1$. $P(A|C)P(B|C) = 1 \times 1 = 1$. Puisque $1 = 1$, les événements A et B sont bien indépendants conditionnellement à C . *Intuition : * Sachant que la somme est 2, nous savons avec certitude que $D_1 = 1$ et $D_2 = 1$. Il n'y a plus d'aléa.

Correction Exercice 20 : Jeu Séquentiel

Soit $p = 1/6$ la probabilité de gagner (obtenir un 6) et $q = 5/6$ la probabilité de rater. Alice gagne si elle réussit au tour 1, OU si (elle rate ET Bob rate) et elle réussit au tour 3, OU si (A rate, B rate, A rate, B rate) et elle réussit au tour 5, etc.

$P(A \text{ gagne}) = P(A \text{ au tour 1}) + P(A \text{ au tour 3}) + P(A \text{ au tour 5}) + \dots$. $P(A \text{ gagne}) = p + (q \times q)p + (q \times q \times q \times q)p + \dots$. $P(A \text{ gagne}) = p + q^2p + q^4p + \dots$. $P(A \text{ gagne}) = p \times (1 + q^2 + q^4 + \dots)$. $P(A \text{ gagne}) = p \sum_{k=0}^{\infty} (q^2)^k$.

C'est une série géométrique de premier terme p et de raison $r = q^2 = (5/6)^2 = 25/36$. La somme est $\frac{\text{premier terme}}{1 - \text{raison}} = \frac{p}{1 - q^2}$. $P(A \text{ gagne}) = \frac{1/6}{1 - 25/36} = \frac{1/6}{11/36} = \frac{1}{6} \times \frac{36}{11} = 6/11$.

2.13 Exercices Pratiques (Python)

Ces exercices vous aideront à appliquer les concepts de probabilité conditionnelle, d'indépendance et la règle de Bayes en utilisant Python, principalement avec le dataset "Titanic".

Pour ces exercices, vous aurez besoin des bibliothèques `pandas`, `seaborn` et `numpy`.

```
pip install pandas seaborn numpy
```

Code utile (chargement des données pour les exercices 1 à 4) :

```
import pandas as pd
import seaborn as sns
import numpy as np

# Charger le dataset Titanic
df = sns.load_dataset('titanic')

# Simplification pour les exercices:
# Remplir les ages manquants par la moyenne
df['age'] = df['age'].fillna(df['age'].mean())
# Supprimer les lignes ou 'embarked' ou 'deck' est manquant
df = df.dropna(subset=['embarked', 'deck'])

# Vous pouvez decommentez la ligne suivante pour inspecter le DataFrame
# df.info()
```

Exercice 1 : Définition de la Probabilité Conditionnelle

En utilisant le DataFrame `df` du Titanic, nous allons calculer $P(A|B)$. Soit A l'événement "le passager a survécu" (`survived == 1`). Soit B l'événement "le passager était un homme" (`sex == 'male'`).

Votre tâche : Calculez $P(A|B) = P(\text{survived}|\text{male})$ en suivant la définition :

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

1. Calculez $P(B) = P(\text{male})$. (Nombre d'hommes / Nombre total de passagers).
2. Calculez $P(A \cap B) = P(\text{survived} \cap \text{male})$. (Nombre d'hommes survivants / Nombre total).
3. Divisez les deux pour trouver $P(A|B)$.

```
# Definit le nombre total de passagers (notre univers |S|)
total_passagers = len(df)

# 1. Calculer P(B) = P(male)
# ... votre code ...
p_male = 0 # A remplacer
print(f"P(male) = {p_male:.4f}")

# 2. Calculer P(A inter B) = P(survived ET male)
# ... votre code ...
p_male_survived = 0 # A remplacer
print(f"P(male ET survived) = {p_male_survived:.4f}")

# 3. Calculer P(A|B) = P(survived | male)
# ... votre code ...
p_survived_given_male = 0 # A remplacer
print(f"P(survived | male) = {p_survived_given_male:.4f}")

# Verification (methode directe, optionnelle)
# p_survived_given_male_direct = ...
# print(f"Verification directe: {p_survived_given_male_direct:.4f}")
```

Exercice 2 : Indépendance

Les événements A et B sont indépendants si $P(A \cap B) = P(A)P(B)$. Soit A l'événement "le passager a survécu" (`survived == 1`). Soit C l'événement "le passager était en 1ère classe" (`pclass == 1`).

Votre tâche : Vérifiez si les événements A et C sont indépendants dans notre dataset.

1. Calculez $P(A) = P(\text{survived})$.
2. Calculez $P(C) = P(\text{pclass} == 1)$.
3. Calculez $P(A) \times P(C)$.
4. Calculez $P(A \cap C) = P(\text{survived} \cap \text{pclass} == 1)$.
5. Comparez les résultats de 3 et 4. Sont-ils indépendants ?

```
total_passagers = len(df)

# 1. P(A) = P(survived)
# ... votre code ...
p_survived = 0 # A remplacer
print(f"P(survived) = {p_survived:.4f}")

# 2. P(C) = P(pclass == 1)
# ... votre code ...
p_pclass_1 = 0 # A remplacer
print(f"P(pclass == 1) = {p_pclass_1:.4f}")

# 3. P(A) * P(C)
p_a_fois_p_c = p_survived * p_pclass_1
print(f"P(A) * P(C) = {p_a_fois_p_c:.4f}")

# 4. P(A inter C) = P(survived ET pclass == 1)
# ... votre code ...
p_a_inter_c = 0 # A remplacer
print(f"P(A inter C) = {p_a_inter_c:.4f}")

# 5. Comparaison
# ... votre code ...
```

Exercice 3 : Formule des Probabilités Totales

Calculez la probabilité totale de survie $P(A) = P(\text{survived})$ en utilisant la formule des probabilités totales, partitionnée par la classe du passager (`pclass` 1, 2, et 3). La formule est :

$$P(A) = \sum_{i=1}^3 P(A|C_i)P(C_i)$$

où C_i est l'événement "le passager est en classe i ".

Votre tâche :

1. Calculez $P(C_1)$, $P(C_2)$, $P(C_3)$.
2. Calculez $P(A|C_1)$, $P(A|C_2)$, $P(A|C_3)$.
3. Appliquez la formule pour trouver $P(A)$.

```

total_passagers = len(df)
p_total_survived = 0.0

# Boucle sur les classes 1, 2, 3
for i in [1, 2, 3]:
    # P(Ci)
    # ... votre code ...
    p_classe_i = 0 # A remplacer

    # P(A | Ci) = P(survived | pclass == i)
    # ... votre code ...
    p_surv_given_classe_i = 0.0 # A remplacer

    print(f"Classe {i}: P(C{i})={p_classe_i:.3f}, P(A|C{i})={p_surv_given_classe_i:.3f}")

    # Somme
    p_total_survived += p_surv_given_classe_i * p_classe_i

print(f"Probabilite totale de survie (calculee): {p_total_survived:.4f}")

```

Exercice 4 : Règle de Bayes

Utilisons la règle de Bayes pour "inverser" une probabilité. Nous voulons trouver $P(C_1|A)$, c'est-à-dire : "sachant qu'un passager a survécu, quelle est la probabilité qu'il était en 1ère classe?" La formule est :

$$P(C_1|A) = \frac{P(A|C_1)P(C_1)}{P(A)}$$

Votre tâche : En utilisant les valeurs que vous avez calculées dans les exercices 2 et 3 :

1. $P(A|C_1) = P(\text{survived} | \text{pclass} == 1)$
2. $P(C_1) = P(\text{pclass} == 1)$
3. $P(A) = P(\text{survived})$
4. Appliquez la formule de Bayes pour trouver $P(C_1|A)$.

```

# Recuperer les valeurs des exercices precedents
p_a_given_c1 = 0 # A remplacer
p_c1 = 0 # A remplacer
p_a = 0 # A remplacer

# 4. Appliquer Bayes
p_c1_given_a = 0 # A remplacer

print(f"P(pclass 1 | survived) = {p_c1_given_a:.4f}")

# Verification (methode directe, optionnelle)
# ... votre code ...

```

Exercice 5 : Simulation du Problème de Monty Hall

Pour prouver le résultat contre-intuitif de Monty Hall, nous allons le simuler.

Votre tâche : Complétez le code ci-dessous pour simuler $N = 10000$ parties.

1. Simulez la stratégie "Garder" (stay) : comptez 1 victoire si `choix_initial == voiture`.
2. Simulez la stratégie "Changer" (switch) : comptez 1 victoire si `choix_initial != voiture`.
3. Calculez les taux de victoire pour les deux stratégies.

(Note : La logique pour "Changer" est simplifiée. Si votre choix initial est faux (2/3 des cas), l'animateur ouvre l'autre mauvaise porte, et changer vous fait gagner. Si votre choix initial est bon (1/3 des cas), changer vous fait perdre.)


```

import random

def simuler_monty_hall(N_simulations):
    victoires_garder = 0
    victoires_changer = 0

    portes = [1, 2, 3]

    for _ in range(N_simulations):
        # 1. Placer la voiture et faire le choix initial
        voiture = random.choice(portes)
        choix_initial = random.choice(portes)

        # 2. Simuler la strategie "Garder"
        # ... votre code ...

        # 3. Simuler la strategie "Changer"
        # ... votre code ...

    # 4. Calculer les taux
    taux_victoire_garder = victoires_garder / N_simulations
    taux_victoire_changer = victoires_changer / N_simulations

    return taux_victoire_garder, taux_victoire_changer

# Lancer la simulation
N = 100000
garder, changer = simuler_monty_hall(N)

print(f"Simulations: {N}")
print(f"Taux de victoire (Garder): {garder:.4f}")
print(f"Taux de victoire (Changer): {changer:.4f}")

```

3 Variables Aléatoires Discrètes

3.1 Variable Aléatoire

Jusqu'à présent, nous avons parlé d'événements (comme "obtenir Pile" ou "tirer un Roi"). Pour analyser ces phénomènes avec des outils mathématiques plus puissants, nous devons traduire ces résultats concrets en nombres. C'est le rôle de la variable aléatoire.

Définition : Variable Aléatoire

Étant donné une expérience avec un univers S , une variable aléatoire est une fonction de l'univers S vers les nombres réels \mathbb{R} .

Cette définition formelle masque une idée très simple :

Intuition

Une variable aléatoire est une manière de traduire les résultats d'une expérience en nombres. Au lieu de travailler avec des concepts comme "Pile" ou "Face", on leur assigne des valeurs numériques (par exemple, 1 pour Pile, 0 pour Face). Cela nous permet d'utiliser toute la puissance des outils mathématiques (fonctions, calculs, etc.) pour analyser le hasard. C'est un pont entre le monde concret des événements et le monde abstrait des nombres.

Prenons un exemple classique :

Exemple

On lance deux dés. L'univers S est l'ensemble des 36 paires de résultats, comme $(1, 1), (1, 2), \dots, (6, 6)$. On peut définir une variable aléatoire X comme étant la **somme des deux dés**. Pour le résultat $(2, 5)$, la valeur de la variable aléatoire est $X(2, 5) = 2 + 5 = 7$.

3.2 Variable Aléatoire Discrète

Les variables aléatoires peuvent être de différents types. Nous commençons par le type le plus simple à "compter".

Définition : Variable Aléatoire Discrète

Une variable aléatoire X est dite discrète s'il existe une liste finie ou infinie dénombrable de valeurs a_1, a_2, \dots telle que $P(X = a_j \text{ pour un certain } j) = 1$.

L'analogie la plus simple pour comprendre le terme "discret" est celle d'un escalier.

Intuition

Une variable aléatoire est "discrète" si on peut lister (compter) toutes les valeurs qu'elle peut prendre, même si cette liste est infinie. Pensez aux "sauts" d'une valeur à l'autre, sans possibilité de prendre une valeur intermédiaire. C'est comme monter un escalier : on peut être sur la marche 1, 2 ou 3, mais jamais sur la marche 2.5. Le nombre de têtes en 10 lancers, le résultat d'un dé, le nombre d'emails que vous recevez en une heure sont des exemples. À l'opposé, une variable continue pourrait être la taille exacte d'une personne, qui peut prendre n'importe quelle valeur dans un intervalle.

3.3 Fonction de Masse (PMF)

Maintenant que nous avons une variable aléatoire qui produit des nombres discrets, nous avons besoin d'une fonction pour décrire la probabilité de chacun de ces nombres.

Définition : Probability Mass Function (PMF)

La fonction de masse (PMF) d'une variable aléatoire discrète X est la fonction P_X donnée par $P_X(x) = P(X = x)$.

C'est la "carte d'identité" probabiliste de la variable :

Intuition

La PMF est la "carte d'identité" probabiliste d'une variable aléatoire discrète. Pour chaque valeur que la variable peut prendre, la PMF nous donne la probabilité exacte associée à cette valeur. C'est comme si chaque résultat possible avait une "étiquette de prix" qui indique sa chance de se produire. La somme de toutes ces probabilités doit bien sûr valoir 1.

Un exemple très simple est le lancer de dé :

Exemple

Soit X le résultat d'un lancer de dé équilibré. La variable X peut prendre les valeurs $\{1, 2, 3, 4, 5, 6\}$. La PMF de X est la fonction qui assigne $1/6$ à chaque valeur : $P(X = 1) = 1/6$, $P(X = 2) = 1/6$, ..., $P(X = 6) = 1/6$. Pour toute autre valeur x (par exemple $x = 2.5$ ou $x = 7$), $P(X = x) = 0$.

3.4 Loi de Bernoulli

Commençons par la loi de probabilité discrète la plus simple.

Définition : Distribution de Bernoulli

Une variable aléatoire X suit la distribution de Bernoulli avec paramètre p si $P(X = 1) = p$ et $P(X = 0) = 1 - p$, où $0 < p < 1$. On note cela $X \sim \text{Bern}(p)$.

C'est la brique fondamentale de nombreuses autres distributions.

Intuition

La distribution de Bernoulli est le modèle le plus simple pour une expérience aléatoire avec seulement deux issues : "succès" (codé par 1) et "échec" (codé par 0). C'est la brique de base de nombreuses autres distributions. Pensez à un unique lancer de pièce (Pile/Face), un unique tir au but (Marqué/Manqué), ou la réponse à une question par oui/non. Le paramètre p est simplement la probabilité du "succès".

3.5 Loi Binomiale

Que se passe-t-il si nous répétons une expérience de Bernoulli n fois et que nous comptons le nombre total de succès ?

Théorème : PMF Binomiale

Si $X \sim \text{Bin}(n, p)$, alors la PMF de X est :

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

pour $k = 0, 1, \dots, n$.

La preuve de cette formule est un argument combinatoire direct.

Preuve

Nous voulons trouver la probabilité d'obtenir exactement k succès au cours de n essais indépendants.

1. **Probabilité d'une séquence spécifique** : Considérons d'abord une séquence spécifique contenant k succès (S) et $n - k$ échecs (E), par exemple $S, S, \dots, S, E, E, \dots, E$. Puisque les essais sont indépendants, la probabilité de cette séquence est le produit des probabilités individuelles :

$$\underbrace{p \times p \times \dots \times p}_{k \text{ fois}} \times \underbrace{(1 - p) \times \dots \times (1 - p)}_{n-k \text{ fois}} = p^k (1 - p)^{n-k}$$

2. **Nombre de séquences possibles** : La séquence ci-dessus n'est qu'une des nombreuses façons d'obtenir k succès. Le nombre total de façons d'arranger k succès parmi n positions (essais) est donné par le coefficient binomial $\binom{n}{k}$.

3. **Probabilité totale :** Chacune de ces $\binom{n}{k}$ séquences a la même probabilité $p^k(1-p)^{n-k}$. Puisque toutes ces séquences sont des événements disjoints, la probabilité totale d'obtenir k succès (dans n'importe quel ordre) est la somme de leurs probabilités :

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Chaque partie de cette formule a une signification logique claire.

Intuition

La distribution binomiale répond à la question : "Si je répète n fois la même expérience de Bernoulli (qui a une probabilité de succès p), quelle est la probabilité d'obtenir exactement k succès ?" La formule est construite logiquement en multipliant trois composantes. D'abord, p^k représente la probabilité d'obtenir k succès. Ensuite, $(1-p)^{n-k}$ est la probabilité que les $n-k$ échecs restants se produisent. Finalement, comme les k succès peuvent apparaître n'importe où parmi les n essais, on multiplie par $\binom{n}{k}$, qui compte le nombre de manières distinctes de placer ces succès.

Appliquons cela à un exemple classique :

Exemple

On lance une pièce équilibrée 10 fois ($n = 10$, $p = 0.5$). Quelle est la probabilité d'obtenir exactement 6 Piles ($k = 6$) ?

$$P(X = 6) = \binom{10}{6} (0.5)^6 (1-0.5)^{10-6} = \frac{10!}{6!4!} (0.5)^{10} = 210 \times (0.5)^{10} \approx 0.205$$

Il y a environ 20.5% de chance d'obtenir exactement 6 Piles.

3.6 Loi Hypergéométrique

La loi binomiale suppose que les essais sont indépendants, ce qui est vrai si l'on tire *avec remise*. Que se passe-t-il si l'on tire *sans remise* ?

Théorème : PMF Hypergéométrique

Si $X \sim \text{HG}(w, b, m)$, alors la PMF de X est :

$$P(X = k) = \frac{\binom{w}{k} \binom{b}{m-k}}{\binom{w+b}{m}}$$

La preuve de cette formule est un argument de dénombrement pur, basé sur la définition naïve de la probabilité.

Preuve

Nous utilisons la définition naïve $P(A) = |A|/|S|$. Nous tirons m boules d'une urne contenant w blanches et b noires, soit $w+b$ boules au total.

1. **Taille de l'univers ($|S|$) :** Le nombre total de façons de choisir m boules parmi $w+b$ est $\binom{w+b}{m}$.
2. **Taille de l'événement favorable ($|A|$) :** Nous voulons l'événement $A =$ "obtenir exactement k boules blanches ET $m-k$ boules noires".
 - Le nombre de façons de choisir k blanches parmi w est $\binom{w}{k}$.
 - Le nombre de façons de choisir $m-k$ noires parmi b est $\binom{b}{m-k}$.

Par le principe de la multiplication (dénombrement), le nombre total de façons de réaliser A est $|A| = \binom{w}{k} \binom{b}{m-k}$.

3. **Probabilité :** En divisant le nombre d'issues favorables par le nombre total d'issues, on obtient :

$$P(X = k) = \frac{|A|}{|S|} = \frac{\binom{w}{k} \binom{b}{m-k}}{\binom{w+b}{m}}$$

Chaque terme de cette fraction a un sens très concret :

Intuition

La distribution hypergéométrique est la "cousine" de la binomiale pour les tirages **sans remise**. Imaginez une urne avec des boules de deux couleurs (par exemple, w blanches et b noires). Vous tirez m boules d'un coup. Quelle est la probabilité que vous ayez exactement k boules blanches ? La formule est un simple ratio issu du dénombrement. Le **dénominateur**, $\binom{w+b}{m}$, compte le nombre total de façons de tirer m boules parmi toutes celles disponibles. Le **numérateur** compte les issues favorables : c'est le produit du nombre de façons de choisir k blanches parmi les w ($\binom{w}{k}$) ET de choisir les $m-k$ boules restantes parmi les noires ($\binom{b}{m-k}$). La différence clé avec la loi binomiale est que les tirages ne sont pas indépendants.

Un exemple typique est la formation de comités à partir d'un groupe.

Exemple

Un comité de 5 personnes est choisi au hasard parmi un groupe de 8 hommes et 10 femmes. Quelle est la probabilité que le comité soit composé de 2 hommes et 3 femmes ? Ici, on tire 5 personnes ($m = 5$) d'une population de 18 personnes. On s'intéresse au nombre d'hommes ($k = 2$) parmi les 8 disponibles ($w = 8$). Le reste du comité sera composé de femmes ($b = 10$).

$$P(X = 2) = \frac{\binom{8}{2} \binom{10}{3}}{\binom{18}{5}} = \frac{28 \times 120}{8568} \approx 0.392$$

Il y a environ 39.2% de chance que le comité ait exactement cette composition.

3.7 Loi Géométrique

Revenons aux essais de Bernoulli (indépendants). Au lieu de fixer le nombre d'essais n , demandons-nous : combien d'essais faut-il avant d'obtenir notre premier succès ?

Théorème : PMF de la loi géométrique

Une variable aléatoire X suit la loi géométrique de paramètre p , notée $X \sim \text{Geom}(p)$, si elle modélise le nombre d'échecs avant le premier succès dans une série d'épreuves de Bernoulli indépendantes. Sa fonction de masse (PMF) est :

$$P(X = k) = (1 - p)^k p \quad \text{pour } k = 0, 1, 2, \dots$$

où $q = 1 - p$ est la probabilité d'échec.

La preuve de cette formule est une application directe de l'indépendance des essais.

Preuve

Soit S_i l'événement "succès au i -ème essai" et E_i l'événement "échec au i -ème essai". L'événement $\{X = k\}$ signifie que nous avons observé exactement k échecs, suivis d'un succès au $(k + 1)$ -ème essai. C'est la séquence d'événements : $E_1 \cap E_2 \cap \dots \cap E_k \cap S_{k+1}$.

Puisque tous les essais sont indépendants, la probabilité de cette intersection est le produit des probabilités individuelles :

$$\begin{aligned} P(X = k) &= P(E_1) \times P(E_2) \times \dots \times P(E_k) \times P(S_{k+1}) \\ &= \underbrace{(1 - p) \times (1 - p) \times \dots \times (1 - p)}_{k \text{ fois}} \times p \\ &= (1 - p)^k p \end{aligned}$$

La formule est donc très littérale :

Intuition

La formule $P(X = k) = q^k p$ décrit la probabilité d'une séquence très spécifique : k échecs consécutifs (chacun avec une probabilité q , donc q^k pour la série), suivis immédiatement d'un succès (avec une probabilité p). C'est la loi de "l'attente du premier succès".

Un exemple classique est l'attente d'un résultat spécifique sur un dé.

Exemple : Premier 6 au lancer de dé

On lance un dé jusqu'à obtenir un 6. La probabilité de succès est $p = 1/6$, et celle d'échec est $q = 5/6$. Quelle est la probabilité que l'on ait besoin de 3 lancers (donc 2 échecs avant le premier succès)? Ici, $k = 2$. La probabilité est :

$$P(X = 2) = (5/6)^2 \cdot (1/6) = \frac{25}{216} \approx 0.116$$

3.8 Loi de Poisson

Introduisons maintenant une loi utilisée pour modéliser le nombre d'événements se produisant dans un intervalle de temps ou d'espace fixe.

Définition : Distribution de Poisson

Une variable aléatoire X suit la loi de Poisson de paramètre $\lambda > 0$ si sa PMF est donnée par :

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!} \quad \text{pour } k = 0, 1, 2, \dots$$

Elle modélise typiquement le nombre d'événements se produisant dans un intervalle de temps ou d'espace fixe.

Cette loi est souvent appelée la loi des événements rares.

Intuition

La loi de Poisson est la loi des événements rares. Imaginez que vous comptez le nombre d'appels arrivant à un standard téléphonique en une minute. Il y a de nombreux instants où un appel pourrait arriver, mais la probabilité à chaque instant est infime. La loi de Poisson modélise ce type de scénario, où l'on connaît seulement le taux moyen d'arrivée des événements (λ).

Mais d'où vient cette formule avec e et une factorielle? Elle vient d'une approximation de la loi binomiale lorsque n est très grand et p très petit.

Théorème : La loi de Poisson comme limite de la loi binomiale

Soit $X_n \sim \text{Bin}(n, p_n)$, où $\lambda = np_n$ est une constante positive fixée. Alors, pour tout $k \in \{0, 1, 2, \dots\}$, nous avons :

$$\lim_{n \rightarrow \infty} P(X_n = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

En pratique, la loi de Poisson est une excellente approximation de la loi binomiale quand n est grand et p est petit.

Intuition : Convergence Binomiale vers Poisson : L'Exemple des Naissances

Supposons que les bébés naissent dans une grande ville à un taux moyen de $\lambda = 10$ naissances par jour. Comment modéliser le nombre X de naissances un jour donné?

1. Approche Binomiale (Découpage du Temps) : On peut diviser la journée (24h) en n très petits intervalles de temps (par exemple, $n = 24 \times 60 \times 60 = 86400$ secondes).

- Si n est très grand, la chance p qu'une naissance se produise *exactement* pendant une seconde donnée est minuscule. On peut calculer cette probabilité p comme le taux moyen divisé par le nombre d'intervalles : $p = \lambda/n = 10/86400$.
- On peut aussi supposer que la probabilité d'avoir *deux* naissances ou plus dans la même seconde est négligeable. Chaque seconde est donc comme un mini-essai de Bernoulli : soit 1 naissance (avec probabilité p), soit 0 naissance (avec probabilité $1 - p$).
- Le nombre total de naissances X sur la journée est la somme de ces n essais de Bernoulli quasi-indépendants. X suit donc approximativement une loi binomiale : $X \approx \text{Bin}(n, p = \lambda/n)$.

La probabilité d'avoir exactement k naissances serait $P(X = k) \approx \binom{n}{k} p^k (1 - p)^{n-k}$.

2. Le Passage à la Limite (Modèle Continu) : Que se passe-t-il si on rend les intervalles de temps infiniment petits ($n \rightarrow \infty$)? C'est là que la magie opère :

- Le terme $\binom{n}{k}$ (combien de façons de choisir k secondes parmi n) se comporte comme $n^k/k!$ pour n grand.
- Le terme $p^k = (\lambda/n)^k$ devient λ^k/n^k .
- Le terme $(1-p)^{n-k} = (1-\lambda/n)^{n-k}$. Comme k est petit par rapport à n , ceci est très proche de $(1-\lambda/n)^n$, qui tend vers $e^{-\lambda}$.

En combinant ces approximations (expliquées plus en détail dans la preuve formelle), on trouve que la probabilité $P(X = k)$ tend vers $\frac{n^k}{k!} \frac{\lambda^k}{n^k} e^{-\lambda} = \frac{e^{-\lambda} \lambda^k}{k!}$.

Conclusion : La loi de Poisson apparaît naturellement comme la limite d'un processus binomial où l'on a un très grand nombre d'opportunités (n) pour qu'un événement rare (probabilité p) se produise, tout en maintenant un taux moyen constant ($\lambda = np$).

La preuve formelle montre comment les termes de la formule binomiale se transforment en ceux de la formule de Poisson lorsque $n \rightarrow \infty$.

Preuve : Dérivation de la loi de Poisson à partir de la loi Binomiale (Détailée)

On part de la fonction de masse (PMF) d'une variable aléatoire X_n suivant une loi binomiale $\text{Bin}(n, p)$, où l'on pose $p = \lambda/n$. L'objectif est de trouver la limite de cette PMF lorsque n tend vers l'infini, tout en gardant $\lambda = np$ constant (ce qui implique que p doit tendre vers 0).

La PMF binomiale est :

$$P(X_n = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

Substituons $p = \lambda/n$:

$$P(X_n = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

Maintenant, développons le coefficient binomial $\binom{n}{k} = \frac{n!}{k!(n-k)!} = \frac{n(n-1)(n-2)\cdots(n-k+1)}{k!}$:

$$P(X_n = k) = \frac{n(n-1)\cdots(n-k+1)}{k!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

Réorganisons les termes pour isoler ceux qui dépendent de n :

$$P(X_n = k) = \frac{\lambda^k}{k!} \times \frac{n(n-1)\cdots(n-k+1)}{n^k} \times \left(1 - \frac{\lambda}{n}\right)^n \times \left(1 - \frac{\lambda}{n}\right)^{-k}$$

Nous allons maintenant examiner la limite de chaque partie lorsque $n \rightarrow \infty$, pour k et λ fixés.

1. $\frac{\lambda^k}{k!}$: Ce terme est constant par rapport à n , donc sa limite est lui-même.
2. $\frac{n(n-1)\cdots(n-k+1)}{n^k}$: Ce terme est un produit de k facteurs divisé par n^k . On peut le réécrire comme :

$$\begin{aligned} & \frac{n}{n} \times \frac{n-1}{n} \times \frac{n-2}{n} \times \cdots \times \frac{n-k+1}{n} \\ &= 1 \times \left(1 - \frac{1}{n}\right) \times \left(1 - \frac{2}{n}\right) \times \cdots \times \left(1 - \frac{k-1}{n}\right) \end{aligned}$$

Lorsque $n \rightarrow \infty$, chacun des termes $\frac{1}{n}, \frac{2}{n}, \dots, \frac{k-1}{n}$ tend vers 0 (car k est fixe). Donc, chaque parenthèse tend vers $(1-0) = 1$. Puisqu'il y a un nombre fixe k de termes dans le produit, la limite du produit est le produit des limites :

$$\lim_{n \rightarrow \infty} \frac{n(n-1)\cdots(n-k+1)}{n^k} = 1 \times 1 \times \cdots \times 1 = 1$$

Intuition : Pour n très grand par rapport à k , les k termes $n, n-1, \dots, n-k+1$ sont tous "presque" égaux à n . Leur produit est donc "presque" n^k , et le ratio est "presque" 1.

3. $\left(1 - \frac{\lambda}{n}\right)^n$: C'est une limite fondamentale en analyse. On sait que pour tout réel x , $\lim_{n \rightarrow \infty} (1 + x/n)^n = e^x$. Ici, nous avons $x = -\lambda$. Donc :

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^n = e^{-\lambda}$$

Intuition : C'est la définition même de l'exponentielle comme limite d'intérêts composés continus (ici, avec un taux négatif).

4. $\left(1 - \frac{\lambda}{n}\right)^{-k}$: Lorsque $n \rightarrow \infty$, le terme λ/n tend vers 0. L'expression à l'intérieur de la parenthèse tend donc vers $(1 - 0) = 1$. Puisque k est un exposant fixe :

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}\right)^{-k} = 1^{-k} = 1$$

Intuition : Pour n très grand, $(1 - \lambda/n)$ est très proche de 1. Élever ce nombre très proche de 1 à une puissance fixe k le laisse très proche de 1.

Finalement, en multipliant les limites de chaque partie (puisque la limite d'un produit est le produit des limites) :

$$\lim_{n \rightarrow \infty} P(X_n = k) = \left(\frac{\lambda^k}{k!}\right) \times (1) \times (e^{-\lambda}) \times (1) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Ceci est exactement la fonction de masse de probabilité d'une loi de Poisson de paramètre λ .

Un ensemble de données historiques célèbres illustre parfaitement cette loi.

Exemple : Décès par ruade de cheval : Les données de Bortkiewicz

En 1898, le statisticien Ladislaus Bortkiewicz a publié des données célèbres sur le nombre de soldats de la cavalerie prussienne tués par des ruades de cheval. Ces données sont un exemple classique d'application de la loi de Poisson pour modéliser des événements rares.

Contexte et calcul du paramètre λ : Sur une période de 20 ans, en observant 10 corps d'armée, il a collecté des données sur 200 "corps-années". Durant cette période, il y a eu un total de 122 décès. Le taux moyen de décès par corps-année est donc :

$$\lambda = \frac{\text{Nombre total de décès}}{\text{Nombre total de corps-années}} = \frac{122}{200} = 0.61$$

Le nombre de décès par corps-année, X , est donc modélisé par une loi de Poisson : $X \sim \text{Poisson}(\lambda = 0.61)$.

Comparaison des données observées et des prédictions du modèle : On peut calculer la probabilité d'observer k décès en une année-corps en utilisant la PMF de Poisson : $P(X = k) = \frac{e^{-0.61} (0.61)^k}{k!}$. En multipliant cette probabilité par le nombre total d'observations (200), on obtient le nombre de cas attendus (nombre de corps d'armes dans lesquels il y a k décès).

Nombre de décès (k)	Observé	Probabilité de Poisson	Attendu
0	109	$P(X = 0) \approx 0.543$	108.7
1	65	$P(X = 1) \approx 0.331$	66.3
2	22	$P(X = 2) \approx 0.101$	20.2
3	3	$P(X = 3) \approx 0.021$	4.1
4	1	$P(X = 4) \approx 0.003$	0.6
5+	0	$P(X \geq 5) \approx 0.000$	0.0

L'adéquation remarquable entre les fréquences observées et les valeurs attendues par le modèle de Poisson a contribué à populariser cette distribution pour l'analyse d'événements rares.

3.9 Fonction de Répartition (CDF)

Nous avons la PMF, qui donne $P(X = x)$. Une autre fonction tout aussi importante est la fonction de répartition (CDF), qui "accumule" ces probabilités.

Définition : Cumulative Distribution Function (CDF)

La fonction de répartition (CDF) d'une variable aléatoire X est la fonction F_X donnée par $F_X(x) = P(X \leq x)$.

Cette fonction répond à une question différente de celle de la PMF.

Intuition

Alors que la PMF répond à la question "Quelle est la probabilité d'obtenir *exactement* x ?", la CDF répond à la question "Quelle est la probabilité d'obtenir *au plus* x ?". C'est une fonction cumulative : pour une valeur x donnée, elle additionne les probabilités de tous les résultats inférieurs ou égaux à x . La CDF a toujours une forme d'escalier pour les variables discrètes. Elle commence à 0 (très loin à gauche) et monte par "sauts" à chaque valeur possible de la variable, pour finalement atteindre 1 (très loin à droite). La hauteur de chaque saut correspond à la valeur de la PMF à ce point.

Traçons cette fonction "en escalier" pour notre exemple du dé.

Exemple

Reprenons le lancer d'un dé équilibré (X). Calculons quelques valeurs de la CDF, notée $F(x)$.

$$F(0.5) = P(X \leq 0.5) = 0$$

$$F(1) = P(X \leq 1) = P(X = 1) = 1/6$$

$$F(1.5) = P(X \leq 1.5) = P(X = 1) = 1/6$$

$$F(2) = P(X \leq 2) = P(X = 1) + P(X = 2) = 2/6$$

$$F(5.9) = P(X \leq 5.9) = P(X = 1) + \dots + P(X = 5) = 5/6$$

$$F(6) = P(X \leq 6) = 1$$

$$F(100) = P(X \leq 100) = 1$$

3.10 Variable Aléatoire Indicatrice

Enfin, nous introduisons un outil simple mais qui s'avérera extraordinairement puissant pour les preuves, notamment celles concernant l'espérance.

Définition : Variable Aléatoire Indicatrice

La variable aléatoire indicatrice d'un événement A est la variable aléatoire qui vaut 1 si A se produit et 0 sinon. Nous la noterons I_A . Notez que $I_A \sim \text{Bern}(p)$ avec $p = P(A)$.

C'est un simple interrupteur "on/off".

Intuition

Une variable indicatrice est un interrupteur. Elle est sur "ON" (valeur 1) si un événement qui nous intéresse se produit, et sur "OFF" (valeur 0) sinon. C'est un outil extrêmement puissant car il transforme les questions sur les probabilités des événements en questions sur les espérances des variables aléatoires, ce qui simplifie souvent les calculs.

3.11 Exercices

Exercice 1 : Identification de Variables Aléatoires

Pour chacune des situations suivantes, indiquez si la variable aléatoire X est discrète ou continue.

1. X est le nombre de Piles obtenues en lançant 10 fois une pièce.
2. X est le temps exact nécessaire pour courir un marathon.
3. X est le nombre d'emails que vous recevez un jour donné.
4. X est la température exacte à midi à Paris.
5. X est le nombre de lancers d'un dé jusqu'à obtenir un 6.

Exercice 2 : Construction d'une PMF

On lance un dé équilibré à 4 faces (un tétraèdre) numérotées de 1 à 4. Soit X le résultat du lancer.

1. Quelles sont les valeurs possibles pour X ?
2. Donnez la fonction de masse de probabilité (PMF) $P(X = k)$ pour chaque valeur k .
3. Vérifiez que la somme des probabilités est égale à 1.

Exercice 3 : PMF d'une Somme

On lance deux dés équilibrés à 4 faces (ceux de l'exercice 2). Soit Y la somme des deux résultats.

1. Quelles sont les valeurs possibles pour Y ?
2. Calculez la PMF $P(Y = k)$ pour chaque valeur k possible (Indice : listez les 16 issues possibles).

Exercice 4 : Construction d'une CDF

En utilisant la variable Y et sa PMF de l'exercice 3 (somme de deux dés à 4 faces) :

1. Calculez $F_Y(y) = P(Y \leq y)$ pour toutes les valeurs y de 2 à 8.
2. Quelle est la valeur de $F_Y(1.5)$?
3. Quelle est la valeur de $F_Y(5.2)$?
4. Quelle est la valeur de $F_Y(10)$?

Exercice 5 : Loi de Bernoulli

Une machine produit des pièces, avec une probabilité $p = 0.05$ que la pièce soit défectueuse. Soit X une variable aléatoire qui vaut 1 si une pièce est défectueuse et 0 sinon.

1. Quelle loi suit X ? Donnez son (ou ses) paramètre(s).
2. Quelle est la PMF de X ? (Donnez $P(X = 0)$ et $P(X = 1)$).

Exercice 6 : Loi Binomiale (Calcul Direct)

On lance une pièce truquée 5 fois ($n = 5$). La probabilité d'obtenir Pile (succès) est $p = 0.7$. Soit X le nombre de Piles obtenus.

1. Quelle loi suit X ? Donnez ses paramètres.
2. Quelle est la probabilité d'obtenir exactement 3 Piles, $P(X = 3)$?
3. Quelle est la probabilité d'obtenir exactement 5 Piles, $P(X = 5)$?

Exercice 7 : Loi Binomiale (Calcul Cumulé)

On reprend la situation de l'exercice 6 ($X \sim \text{Bin}(5, 0.7)$).

1. Quelle est la probabilité d'obtenir 0 Pile, $P(X = 0)$?
2. En déduire la probabilité d'obtenir au moins 1 Pile, $P(X \geq 1)$.

Exercice 8 : Problème Binomial (Contrôle Qualité)

Un lot de 10000 articles contient 10% d'articles défectueux. On prélève un échantillon de 20 articles *avec remise* pour inspection. Quelle est la probabilité que l'échantillon contienne exactement 2 articles défectueux ?

Exercice 9 : Loi Hypergéométrique (Urne)

Une urne contient 7 boules blanches et 5 boules noires (total 12). On tire $m = 4$ boules *sans remise*. Soit X le nombre de boules blanches tirées.

1. Quelle loi suit X ? Donnez ses paramètres (w, b, m).
2. Quelle est la probabilité d'obtenir exactement 2 boules blanches, $P(X = 2)$?

Exercice 10 : Problème Hypergéométrique (Comité)

Un département est composé de 10 hommes et 8 femmes. On choisit un comité de 6 personnes au hasard. Quelle est la probabilité que le comité soit composé d'exactly 3 hommes et 3 femmes ?

Exercice 11 : Binomiale vs Hypergéométrique

Reprenons le problème de l'exercice 8 (lot de 10000 articles, 10% défectueux), mais cette fois on prélève les 20 articles *sans remise*.

1. Quelle est la loi exacte du nombre X d'articles défectueux ? (Donnez son nom et ses paramètres).
2. Calculez la probabilité exacte $P(X = 2)$.

3. Comparez ce résultat à celui obtenu à l'exercice 8. L'approximation binomiale était-elle bonne ? Pourquoi ?

Exercice 12 : Loi Géométrique (Calcul Direct)

On lance un dé équilibré à 6 faces jusqu'à obtenir un 6. Soit X le nombre d'échecs *avant* le premier 6.

1. Quelle loi suit X ? Donnez son paramètre p .
2. Quelle est la probabilité que le premier 6 apparaisse au 3ème lancer ? (C'est-à-dire $P(X = 2)$).
3. Quelle est la probabilité que le premier 6 apparaisse au 1er lancer ? (C'est-à-dire $P(X = 0)$).

Exercice 13 : Loi Géométrique (Calcul Cumulé)

Un archer touche sa cible avec une probabilité $p = 0.2$ à chaque tir. Les tirs sont indépendants. Il tire jusqu'à ce qu'il touche la cible. Soit X le nombre d'échecs avant son premier succès.

1. Quelle est la probabilité qu'il ait besoin d'exactly 4 tirs au total ? (C'est-à-dire $P(X = 3)$).
2. Quelle est la probabilité qu'il ait besoin de plus de 2 tirs au total ? (C'est-à-dire $P(X \geq 2)$ ou $P(\text{les 2 premiers tirs sont des échecs})$).

Exercice 14 : Variante de la Loi Géométrique

Certains manuels définissent la loi géométrique Y comme le *nombre total d'essais* (et non le nombre d'échecs). Si $Y \sim \text{Geom}(p)$ selon cette définition :

1. Quelle est la PMF $P(Y = k)$ pour $k = 1, 2, 3, \dots$?
2. En utilisant $p = 1/6$ (lancer de dé), calculez $P(Y = 3)$. Comparez avec $P(X = 2)$ de l'exercice 12.

Exercice 15 : Loi de Poisson (Calcul Direct)

Un centre d'appels reçoit en moyenne $\lambda = 5$ appels par heure. Soit X le nombre d'appels reçus en une heure donnée. On suppose que X suit une loi de Poisson.

1. Quelle est la probabilité qu'il n'y ait aucun appel ($P(X = 0)$) ?
2. Quelle est la probabilité qu'il y ait exactement 5 appels ($P(X = 5)$) ? (Laissez e^{-5} dans votre réponse).

Exercice 16 : Loi de Poisson (Calcul Cumulé)

Un site web reçoit en moyenne $\lambda = 2$ visiteurs par minute. Soit X le nombre de visiteurs en une minute. Calculez la probabilité de recevoir au plus 2 visiteurs, $P(X \leq 2)$. (Laissez e^{-2} dans votre réponse).

Exercice 17 : Loi de Poisson (Changement de λ)

Un livre contient en moyenne 0.5 faute de frappe par page ($\lambda = 0.5$).

1. Quelle est la probabilité qu'une page donnée contienne 0 faute ?
2. Soit Y le nombre de fautes dans un chapitre de 10 pages. Quel est le nouveau paramètre λ_Y pour Y ?
3. Quelle est la probabilité que ce chapitre de 10 pages contienne 0 faute ?

Exercice 18 : Approximation Binomiale par Poisson

Une compagnie d'assurance a 10000 clients ($n = 10000$). La probabilité qu'un client ait un accident dans l'année est $p = 0.0003$.

1. Quelle est la loi exacte X du nombre d'accidents ?
2. Calculez le paramètre $\lambda = np$ pour une approximation par la loi de Poisson.
3. En utilisant la loi de Poisson, estimez la probabilité qu'il y ait exactement 2 accidents cette année, $P(X = 2)$.

Exercice 19 : Choisir la Bonne Loi

Pour chaque scénario, identifiez la loi discrète la plus appropriée (Binomiale, Hypergéométrique, Géométrique, Poisson).

1. On compte le nombre de Rois en tirant 5 cartes d'un jeu, sans remise.
2. On compte le nombre de clients arrivant à une banque entre 10h et 11h.
3. On compte le nombre de lancers de pièce jusqu'à obtenir le premier Pile.
4. On compte le nombre de "6" obtenus en lançant un dé 20 fois.
5. On compte le nombre de soldats tués par ruade de cheval dans un corps d'armée en un an.

Exercice 20 : Variable Indicatrice

Soit A l'événement "obtenir un 6 en lançant un dé équilibré". Soit I_A la variable indicatrice de l'événement A .

1. Quelle loi suit I_A ? Donnez son nom et son paramètre.
2. Écrivez la PMF de I_A .

3.12 Corrections des Exercices

Correction Exercice 1 : Identification de Variables Aléatoires

1. **Discrète.** X ne peut prendre que des valeurs entières $\{0, 1, \dots, 10\}$. 2. **Continue.** Le temps peut prendre n'importe quelle valeur dans un intervalle (par ex. $T \in [2.5, 5]$ heures). 3. **Discrète.** X ne peut prendre que des valeurs entières $\{0, 1, 2, \dots\}$. 4. **Continue.** La température peut prendre n'importe quelle valeur dans un intervalle (par ex. $T \in [15.0, 25.0]^\circ\text{C}$). 5. **Discrète.** X ne peut prendre que des valeurs entières $\{0, 1, 2, \dots\}$ (si on compte les échecs) ou $\{1, 2, 3, \dots\}$ (si on compte les lancers).

Correction Exercice 2 : Construction d'une PMF

On lance un dé à 4 faces (1, 2, 3, 4). X est le résultat. 1. Valeurs possibles : $S_X = \{1, 2, 3, 4\}$. 2. PMF : Le dé est équilibré, donc chaque face a la même probabilité $1/4$. $P(X = 1) = 1/4$ $P(X = 2) = 1/4$ $P(X = 3) = 1/4$ $P(X = 4) = 1/4$ Et $P(X = k) = 0$ pour tout autre k . 3. Vérification : $\sum P(X = k) = 1/4 + 1/4 + 1/4 + 1/4 = 4/4 = 1$.

Correction Exercice 3 : PMF d'une Somme

$Y = D_1 + D_2$, où $D_1, D_2 \in \{1, 2, 3, 4\}$. Il y a $4 \times 4 = 16$ issues équiprobables (prob. $1/16$ chacune). 1. Valeurs possibles : Min = $1 + 1 = 2$. Max = $4 + 4 = 8$. $S_Y = \{2, 3, 4, 5, 6, 7, 8\}$. 2. PMF (en comptant les issues favorables sur 16) : - $P(Y = 2) = P(1, 1) \Rightarrow 1/16$ - $P(Y = 3) = P(1, 2) + P(2, 1) \Rightarrow 2/16$ - $P(Y = 4) = P(1, 3) + P(2, 2) + P(3, 1) \Rightarrow 3/16$ - $P(Y = 5) = P(1, 4) + P(2, 3) + P(3, 2) + P(4, 1) \Rightarrow 4/16$ - $P(Y = 6) = P(2, 4) + P(3, 3) + P(4, 2) \Rightarrow 3/16$ - $P(Y = 7) = P(3, 4) + P(4, 3) \Rightarrow 2/16$ - $P(Y = 8) = P(4, 4) \Rightarrow 1/16$ (Vérification : $1 + 2 + 3 + 4 + 3 + 2 + 1 = 16$. La somme est $16/16 = 1$).

Correction Exercice 4 : Construction d'une CDF

On utilise la PMF de l'exercice 3. $F_Y(y) = P(Y \leq y)$. 1. CDF aux points de masse : - $F_Y(2) = P(Y \leq 2) = P(Y = 2) = 1/16$ - $F_Y(3) = P(Y \leq 3) = P(Y = 2) + P(Y = 3) = 1/16 + 2/16 = 3/16$ - $F_Y(4) = P(Y \leq 4) = 3/16 + P(Y = 4) = 3/16 + 3/16 = 6/16$ - $F_Y(5) = P(Y \leq 5) = 6/16 + P(Y = 5) = 6/16 + 4/16 = 10/16$ - $F_Y(6) = P(Y \leq 6) = 10/16 + P(Y = 6) = 10/16 + 3/16 = 13/16$ - $F_Y(7) = P(Y \leq 7) = 13/16 + P(Y = 7) = 13/16 + 2/16 = 15/16$ - $F_Y(8) = P(Y \leq 8) = 15/16 + P(Y = 8) = 15/16 + 1/16 = 16/16 = 1$ 2. $F_Y(1.5) = P(Y \leq 1.5) = 0$ (car la valeur minimale est 2). 3. $F_Y(5.2) = P(Y \leq 5.2) = P(Y \leq 5) = F_Y(5) = 10/16$. 4. $F_Y(10) = P(Y \leq 10) = 1$ (car la valeur maximale est 8).

Correction Exercice 5 : Loi de Bernoulli

1. X suit une **loi de Bernoulli**. Le paramètre est $p = 0.05$. On note $X \sim \text{Bern}(0.05)$. 2. La PMF est : $P(X = 1) = p = 0.05$ (succès = défectueux) $P(X = 0) = 1 - p = 0.95$ (échec = non défectueux)

Correction Exercice 6 : Loi Binomiale (Calcul Direct)

1. X est le nombre de succès (Pile) en $n = 5$ essais indépendants avec probabilité $p = 0.7$. X suit une **loi Binomiale**. $X \sim \text{Bin}(n = 5, p = 0.7)$. 2. $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$. $P(X = 3) = \binom{5}{3} (0.7)^3 (1-0.7)^{5-3} = 10 \times 0.343 \times (0.3)^2 = 10 \times 0.343 \times 0.09 = 0.3087$. 3. $P(X = 5) = \binom{5}{5} (0.7)^5 (0.3)^0 = 1 \times (0.7)^5 \times 1 = 0.16807$.

Correction Exercice 7 : Loi Binomiale (Calcul Cumulé)

On a $X \sim \text{Bin}(5, 0.7)$. 1. $P(X = 0) = \binom{5}{0} (0.7)^0 (0.3)^5 = 1 \times 1 \times (0.3)^5 = 0.00243$. 2. L'événement "au moins 1 Pile" ($X \geq 1$) est le complémentaire de "0 Pile" ($X = 0$). $P(X \geq 1) = 1 - P(X = 0) = 1 - 0.00243 = 0.99757$.

Correction Exercice 8 : Problème Binomial (Contrôle Qualité)

Le tirage est *avec remise*, donc les essais sont indépendants. C'est une loi binomiale. $n = 20$ (nombre d'essais). $p = 0.10$ (probabilité de succès = défectueux). On cherche $P(X = 2)$. $P(X = 2) = \binom{20}{2} (0.1)^2 (1-0.1)^{20-2}$. $P(X = 2) = \frac{20 \times 19}{2} (0.1)^2 (0.9)^{18} = 190 \times 0.01 \times (0.9)^{18}$. $P(X = 2) = 1.9 \times (0.9)^{18} \approx 1.9 \times 0.15009 \approx 0.2852$.

Correction Exercice 9 : Loi Hypergéométrique (Urne)

Le tirage est *sans remise* d'une population finie. 1. X suit une **loi Hypergéométrique**. Paramètres : $w = 7$ (blanches, succès), $b = 5$ (noires, échecs), $m = 4$ (nombre de tirages). $X \sim \text{HG}(w = 7, b = 5, m = 4)$. 2. On cherche $P(X = 2)$. $P(X = k) = \frac{\binom{w}{k} \binom{b}{m-k}}{\binom{w+b}{m}}$. $P(X = 2) = \frac{\binom{7}{2} \binom{5}{4-2}}{\binom{12}{4}} = \frac{\binom{7}{2} \binom{5}{2}}{\binom{12}{4}} = \frac{(\frac{7 \times 6}{2}) \times (\frac{5 \times 4}{2})}{\frac{12 \times 11 \times 10 \times 9}{4 \times 3 \times 2 \times 1}} = \frac{21 \times 10}{495} = \frac{210}{495} = \frac{14}{33} \approx 0.4242$.

Correction Exercice 10 : Problème Hypergéométrique (Comité)

Tirage sans remise. C'est une loi Hypergéométrique. $w = 10$ (hommes), $b = 8$ (femmes), $m = 6$ (taille du comité). Total $N = 18$. On cherche $P(X = 3)$ (exactement 3 hommes, ce qui implique $m - k = 6 - 3 = 3$ femmes). $P(X = 3) = \frac{\binom{10}{3} \binom{8}{3}}{\binom{18}{6}}$. $P(X = 3) = \frac{(\frac{10 \times 9 \times 8}{3 \times 2 \times 1}) \times (\frac{8 \times 7 \times 6}{3 \times 2 \times 1})}{\frac{18 \times 17 \times 16 \times 15 \times 14 \times 13}{6 \times 5 \times 4 \times 3 \times 2 \times 1}} = \frac{120 \times 56}{18564} = \frac{6720}{18564} \approx 0.362$.

Correction Exercice 11 : Binomiale vs Hypergéométrique

Population totale $N = 10000$. 10% défectueux, donc $w = 1000$ (défectueux), $b = 9000$ (non défectueux). Tirage de $m = 20$ *sans remise*. 1. Loi exacte : **Loi Hypergéométrique**. $X \sim \text{HG}(w = 1000, b = 9000, m = 20)$. 2. Probabilité exacte $P(X = 2)$: $P(X = 2) = \frac{\binom{1000}{2} \binom{9000}{18}}{\binom{10000}{20}}$. $P(X = 2) = \frac{(\frac{1000 \times 999}{2}) \times (\frac{9000 \times \dots \times 8981}{18!})}{\frac{10000 \times \dots \times 9981}{20!}} \approx 0.2854$. (Le calcul est très complexe, mais on peut montrer qu'il est très proche de la binomiale). 3. Le résultat de l'exercice 8 (Binomiale) était ≈ 0.2852 . L'approximation binomiale est excellente. La raison est que la taille de l'échantillon ($m = 20$) est très petite par rapport à la taille de la population ($N = 10000$). Le fait de ne pas remettre les 20 articles change à peine les probabilités pour les tirages suivants.

Correction Exercice 12 : Loi Géométrique (Calcul Direct)

1. X est le nombre d'échecs avant le premier succès. X suit une **loi Géométrique**. Le succès est "obtenir 6", donc $p = 1/6$. $X \sim \text{Geom}(p = 1/6)$. 2. "Premier 6 au 3ème lancer" signifie 2 échecs (lancers 1 et 2) puis 1 succès (lancer 3). C'est $P(X = 2)$. $q = 1 - p = 5/6$. $P(X = 2) = q^2 p^1 = (5/6)^2 (1/6) = 25/216 \approx 0.1157$. 3. "Premier 6 au 1er lancer" signifie 0 échec. C'est $P(X = 0)$. $P(X = 0) = q^0 p^1 = 1 \times (1/6) = 1/6$.

Correction Exercice 13 : Loi Géométrique (Calcul Cumulé)

$p = 0.2$ (succès), $q = 0.8$ (échec). X compte les échecs. $X \sim \text{Geom}(0.2)$. 1. "Exactement 4 tirs au total" signifie 3 échecs suivis d'un succès. On cherche $P(X = 3)$. $P(X = 3) = q^3 p^1 = (0.8)^3 (0.2) = 0.512 \times 0.2 = 0.1024$. 2. "Plus de 2 tirs au total" signifie qu'il faut au moins 3 tirs. C'est l'événement "les 2 premiers tirs sont des échecs". La probabilité est $P(\text{Echec 1} \cap \text{Echec 2}) = q \times q = q^2$. $P(X \geq 2) = (0.8)^2 = 0.64$.

Correction Exercice 14 : Variante de la Loi Géométrique

Y est le nombre total d'essais ($k = 1, 2, 3, \dots$). p est la prob. de succès. 1. Pour que $Y = k$, il faut $k - 1$ échecs, suivis d'un succès. $P(Y = k) = (1 - p)^{k-1}p = q^{k-1}p$, pour $k = 1, 2, \dots$. 2. Avec $p = 1/6$, on cherche $P(Y = 3)$. $P(Y = 3) = (5/6)^{3-1}(1/6) = (5/6)^2(1/6) = 25/216$. C'est le même résultat que $P(X = 2)$ de l'exercice 12. Les deux définitions décrivent la même situation (3 lancers au total).

Correction Exercice 15 : Loi de Poisson (Calcul Direct)

$X \sim \text{Poisson}(\lambda = 5)$. PMF : $P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$. 1. $P(X = 0) = \frac{e^{-5} 5^0}{0!} = \frac{e^{-5} \times 1}{1} = e^{-5} \approx 0.0067$. 2. $P(X = 5) = \frac{e^{-5} 5^5}{5!} = \frac{e^{-5} \times 3125}{120} = e^{-5} \times \frac{625}{24} \approx 26.04 \times e^{-5} \approx 0.1755$.

Correction Exercice 16 : Loi de Poisson (Calcul Cumulé)

$X \sim \text{Poisson}(\lambda = 2)$. On cherche $P(X \leq 2)$. $P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$
 $P(X = 0) = \frac{e^{-2} 2^0}{0!} = e^{-2}$ $P(X = 1) = \frac{e^{-2} 2^1}{1!} = 2e^{-2}$ $P(X = 2) = \frac{e^{-2} 2^2}{2!} = \frac{4e^{-2}}{2} = 2e^{-2}$
 $P(X \leq 2) = e^{-2} + 2e^{-2} + 2e^{-2} = 5e^{-2} \approx 5 \times 0.1353 = 0.6767$.

Correction Exercice 17 : Loi de Poisson (Changement de λ)

1. Pour une page, $X \sim \text{Poisson}(\lambda = 0.5)$. $P(X = 0) = \frac{e^{-0.5} (0.5)^0}{0!} = e^{-0.5} \approx 0.6065$. 2. Si le taux est 0.5 faute/page, le taux pour 10 pages est $\lambda_Y = 0.5 \times 10 = 5$. $Y \sim \text{Poisson}(\lambda_Y = 5)$. 3. On cherche $P(Y = 0)$. $P(Y = 0) = \frac{e^{-5} 5^0}{0!} = e^{-5} \approx 0.0067$.

Correction Exercice 18 : Approximation Binomiale par Poisson

1. C'est un tirage de $n = 10000$ clients, où chaque client est un essai de Bernoulli avec $p = 0.0003$. La loi exacte est $X \sim \text{Bin}(10000, 0.0003)$. 2. Le paramètre λ pour l'approximation Poisson est $\lambda = np = 10000 \times 0.0003 = 3$. 3. On utilise $Y \sim \text{Poisson}(\lambda = 3)$ pour approximer X . $P(X = 2) \approx P(Y = 2) = \frac{e^{-3} 3^2}{2!} = \frac{9e^{-3}}{2} = 4.5e^{-3} \approx 4.5 \times 0.04979 \approx 0.224$.

Correction Exercice 19 : Choisir la Bonne Loi

1. Tirage sans remise d'une population finie : **Loi Hypergéométrique**. 2. Comptage d'événements sur un intervalle de temps fixe : **Loi de Poisson**. 3. Comptage d'essais jusqu'au premier succès : **Loi Géométrique**. 4. Comptage de succès sur un nombre fixe d'essais indépendants : **Loi Binomiale**. 5. Comptage d'événements rares sur un intervalle (temps/espace) : **Loi de Poisson**.

Correction Exercice 20 : Variable Indicatrice

$A = \text{"obtenir 6"}$. $P(A) = 1/6$. $I_A = 1$ si A se produit, $I_A = 0$ sinon. 1. C'est une expérience avec deux issues (succès/échec). I_A suit une **Loi de Bernoulli**. Le paramètre est $p = P(A) = 1/6$. $I_A \sim \text{Bern}(1/6)$. 2. La PMF de I_A est : $P(I_A = 1) = p = 1/6$ $P(I_A = 0) = 1 - p = 5/6$

3.13 Exercices Pratiques (Python)

Ces exercices vous aideront à implémenter et visualiser les fonctions de masse (PMF) des principales lois discrètes vues dans ce chapitre.

Pour ces exercices, vous aurez besoin des bibliothèques `math` (incluse), `random` (incluse), `pandas` et `matplotlib`.

```
pip install pandas matplotlib
```

Exercice 1 : PMF Empirique (Somme de deux dés)

Nous allons simuler le lancer de deux dés à 6 faces et tracer la PMF empirique de leur somme, $Y = D_1 + D_2$.

Votre tâche :

1. Créez une fonction `lancer_deux_des()` qui simule le lancer de deux dés (valeurs de 1 à 6) et retourne leur somme.

2. Appelez cette fonction 10000 fois et stockez les résultats dans une liste.
3. Convertissez cette liste en `pandas.Series`.
4. Utilisez la méthode `.value_counts(normalize=True).sort_index()` sur la Series pour obtenir la PMF empirique (les probabilités de chaque somme).
5. Utilisez `.plot(kind='bar')` pour visualiser cette PMF.

```
import random
import pandas as pd
import matplotlib.pyplot as plt

def lancer_deux_des():
    # ... votre code ...
    pass

N_simulations = 10000
resultats = []

# 2. Boucle de simulation
# ... votre code ...

# 3. Conversion en Series
# ... votre code ...

# 4. Calcul de la PMF empirique
# ... votre code ...

# 5. Affichage
# ... votre code ...
plt.title("PMF Empirique de la Somme de Deux Des")
plt.xlabel("Somme Y")
plt.ylabel("Probabilite P(Y=k)")
plt.show()
```

Exercice 2 : Loi Binomiale (Implémentation de la PMF)

Nous allons implémenter la formule de la PMF Binomiale $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$ en utilisant le module `math`.

Votre tâche :

1. Importez `math`.
2. Écrivez une fonction `pmf_binomiale(k, n, p)` qui prend k , n , et p et retourne la probabilité $P(X = k)$.
3. Testez votre fonction en calculant la probabilité d'obtenir exactement 6 Piles ($k = 6$) en 10 lancers ($n = 10$) d'une pièce équilibrée ($p = 0.5$).

```
import math

def pmf_binomiale(k, n, p):
    # ... votre code ...
    pass

# 4. Test
k, n, p = 6, 10, 0.5
# probabilite = ...
# print(f"P(X={k}) pour Bin({n}, {p}) = {probabilite:.5f}")
```

Exercice 3 : Loi Hypergéométrique (Implémentation de la PMF)

Implémentons la PMF de la loi Hypergéométrique $P(X = k) = \frac{\binom{w}{k} \binom{b}{m-k}}{\binom{w+b}{m}}$.

Votre tâche :

1. Écrivez une fonction `pmf_hypergeometrique(k, w, b, m)` qui calcule $P(X = k)$.
2. Testez votre fonction avec l'exemple du cours : un comité de $m = 5$ personnes choisi

parmi $w = 8$ hommes et $b = 10$ femmes. Quelle est la probabilité d'avoir $k = 2$ hommes ?

```
import math

def pmf_hypergeometrique(k, w, b, m):
    # k = succes desires (parmi w)
    # w = nombre total de succes dans la population
    # b = nombre total d'echecs dans la population
    # m = taille de l'echantillon

    # ... votre code ...
    pass

# 3. Test
w, b, m, k = 8, 10, 5, 2
# probabilite = ...
# print(f"Probabilite d'avoir {k} hommes : {probabilite:.5f}")
```

Exercice 4 : Loi Géométrique (Simulation)

Nous allons simuler la loi Géométrique $X \sim \text{Geom}(p)$ qui compte le nombre d'échecs (k) avant le premier succès.

Votre tâche :

1. Écrivez une fonction `simuler_geometrique(p)` qui simule des essais de Bernoulli (avec probabilité p) jusqu'à obtenir un succès, et qui retourne le nombre d'échecs.
2. Appelez cette fonction 10000 fois pour $p = 1/6$ (lancer de dé) et stockez les k (nombre d'échecs) dans une liste.
3. Calculez et affichez la moyenne du nombre d'échecs dans vos simulations.

```
import random

def simuler_geometrique(p):
    # ... votre code ...
    pass

N_simulations = 10000
p = 1/6.0
resultats_geom = []

# 3. Boucle de simulation
# ... votre code ...

# 4. Calculer la moyenne
# ... votre code ...
# print(f"Moyenne d'echecs avant succes (p={p:.3f}): {moyenne_echecs:.3f}")
```

Exercice 5 : Loi de Poisson (Implémentation de la PMF)

Implémentons la PMF de la loi de Poisson $P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$.

Votre tâche :

1. Importez `math`.
2. Écrivez une fonction `pmf_poisson(k, lambda)` qui calcule $P(X = k)$.
3. Testez votre fonction en calculant les probabilités pour l'exemple de Bortkiewicz ($\lambda = 0.61$) : $P(X = 0)$, $P(X = 1)$, et $P(X = 2)$.


```

import math

def pmf_poisson(k, lambda):
    # ... votre code ...
    pass

# 4. Test avec l'exemple de Bortkiewicz
lambda = 0.61

# p_k0 = ...
# p_k1 = ...
# p_k2 = ...

# print(f"Parametre lambda = {lambda}")
# print(f"P(X=0) = {p_k0:.5f}")
# print(f"P(X=1) = {p_k1:.5f}")
# print(f"P(X=2) = {p_k2:.5f}")

```

Exercice 6 : Approximation Binomiale par Poisson

Nous avons vu que la loi de Poisson $\text{Poisson}(\lambda)$ est une excellente approximation de la loi Binomiale $\text{Bin}(n, p)$ lorsque n est grand, p est petit, et $\lambda = np$.

Votre tâche : En utilisant vos fonctions `pmf_binomiale` (Ex 2) et `pmf_poisson` (Ex 5) :

1. Choisissez des paramètres : $n = 1000$ et $p = 0.002$.
2. Calculez le paramètre $\lambda = np$ correspondant pour la loi de Poisson.
3. Calculez $P(X = k)$ pour $k = 0, 1, 2, 3$ en utilisant la PMF **Binomiale**.
4. Calculez $P(Y = k)$ pour $k = 0, 1, 2, 3$ en utilisant la PMF **Poisson**.
5. Affichez les résultats côte à côte pour comparer la précision de l'approximation.

```

import math

# Collez vos fonctions pmf_binomiale et pmf_poisson ici
def pmf_binomiale(k, n, p):
    # ... (code de l'exercice 2) ...
    pass

def pmf_poisson(k, lambda):
    # ... (code de l'exercice 5) ...
    pass

# 1. Parametres
n = 1000
p = 0.002

# 2. Calculer lambda
lambda = n * p
print(f"n={n}, p={p}, lambda={lambda}")
print("-" * 30)
print(f"k \t Binomiale \t Poisson")
print("-" * 30)

# 3. & 4. Boucle de calcul et comparaison
for k_val in [0, 1, 2, 3, 4]:
    # prob_bin = ...
    # prob_poi = ...
    # print(f"{k_val} \t {prob_bin:.6f} \t {prob_poi:.6f}")
    pass

```

4 Espérance et Variance

4.1 Espérance d'une variable aléatoire discrète

Maintenant que nous avons défini les variables aléatoires discrètes et leur distribution (PMF), l'étape suivante est de résumer ces distributions. La mesure la plus importante est leur "centre", ou leur valeur moyenne.

Définition : Espérance

L'espérance (ou valeur attendue) d'une variable aléatoire discrète X , qui prend les valeurs distinctes x_1, x_2, \dots , est définie par :

$$E(X) = \sum_j x_j P(X = x_j)$$

Cette formule est une moyenne pondérée de toutes les valeurs possibles.

Intuition

L'espérance représente la valeur moyenne que l'on obtiendrait si l'on répétait l'expérience un très grand nombre de fois. C'est le **centre de gravité** de la distribution de probabilité. Si les probabilités étaient des masses placées sur une tige aux positions x_j , l'espérance serait le point d'équilibre.

L'exemple le plus simple est le lancer d'un dé.

Exemple : Lancer d'un dé

Soit X le résultat d'un lancer de dé équilibré. Chaque face a une probabilité de $1/6$. L'espérance est :

$$E(X) = 1 \left(\frac{1}{6} \right) + 2 \left(\frac{1}{6} \right) + 3 \left(\frac{1}{6} \right) + 4 \left(\frac{1}{6} \right) + 5 \left(\frac{1}{6} \right) + 6 \left(\frac{1}{6} \right) = \frac{21}{6} = 3.5$$

Même si 3.5 n'est pas un résultat possible, c'est la valeur moyenne sur un grand nombre de lancers.

4.2 Linéarité de l'espérance

Le calcul de l'espérance deviendrait très fastidieux si nous devions toujours utiliser la définition. Heureusement, l'espérance possède une propriété fondamentale qui simplifie énormément les calculs.

Théorème : Linéarité de l'espérance

Pour toutes variables aléatoires X et Y , et pour toute constante c , on a :

$$\begin{aligned} E(X + Y) &= E(X) + E(Y) \\ E(cX) &= cE(X) \end{aligned}$$

Cette propriété est extrêmement puissante car elle ne requiert pas que X et Y soient indépendantes.

La preuve de $E(cX) = cE(X)$ est directe à partir de la définition. La preuve pour la somme $E(X + Y)$ est plus complexe mais essentielle.

Preuve

La première propriété est directe :

$$E(cX) = \sum_x (cx)P(X = x) = c \sum_x xP(X = x) = cE(X)$$

Pour la seconde, nous devons utiliser la définition de l'espérance pour une fonction de deux variables (une extension de LOTUS). Soit $S = X + Y$. L'espérance $E(S)$ se calcule en sommant

sur toutes les paires possibles (x, y) :

$$\begin{aligned} E(X + Y) &= \sum_x \sum_y (x + y) P(X = x, Y = y) \\ &= \sum_x \sum_y x P(X = x, Y = y) + \sum_x \sum_y y P(X = x, Y = y) \\ &= \sum_x x \left(\sum_y P(X = x, Y = y) \right) + \sum_y y \left(\sum_x P(X = x, Y = y) \right) \end{aligned}$$

Par la loi des probabilités totales (ou "marginalisation"), la somme interne $\sum_y P(X = x, Y = y)$ est simplement $P(X = x)$. De même, $\sum_x P(X = x, Y = y) = P(Y = y)$.

$$E(X + Y) = \sum_x x P(X = x) + \sum_y y P(Y = y) = E(X) + E(Y)$$

Notez que l'indépendance n'a jamais été requise pour cette preuve.

Cette propriété est incroyablement utile.

Intuition

Cette propriété formalise une idée très simple : "la moyenne d'une somme est la somme des moyennes". Si vous jouez à deux jeux de hasard, votre gain moyen total est simplement la somme de ce que vous gagnez en moyenne à chaque jeu, que les jeux soient liés ou non.

Cette propriété rend le calcul de l'espérance d'une somme trivial, comme le montre l'exemple des deux dés.

Exemple : Somme de deux dés

Soit X_1 le résultat du premier dé et X_2 celui du second. On sait que $E(X_1) = 3.5$ et $E(X_2) = 3.5$. Soit $S = X_1 + X_2$ la somme des deux dés. Grâce à la linéarité, on peut calculer l'espérance de la somme sans avoir à lister les 36 résultats possibles :

$$E(S) = E(X_1 + X_2) = E(X_1) + E(X_2) = 3.5 + 3.5 = 7$$

4.3 Espérance de la loi binomiale

Nous pouvons maintenant utiliser cette puissante propriété de linéarité pour trouver l'espérance de nos distributions de référence, en évitant des sommes complexes.

Théorème : Espérance de la loi binomiale

Si $X \sim \text{Bin}(n, p)$, alors son espérance est $E(X) = np$.

Ce résultat est profondément intuitif.

Intuition

Ce résultat est très naturel. Si vous lancez une pièce 100 fois ($n = 100$) avec une probabilité de 50% d'obtenir Pile ($p = 0.5$), vous vous attendez en moyenne à obtenir $100 \times 0.5 = 50$ Piles. La formule np généralise cette idée.

La preuve formelle est un exemple parfait de l'élégance de la linéarité, utilisant les variables indicatrices.

Preuve

Le calcul direct de l'espérance avec la PMF binomiale est possible, mais long. En utilisant la linéarité de l'espérance, on obtient une preuve beaucoup plus courte et élégante.

On peut voir une variable binomiale X comme la somme de n variables de Bernoulli indépendantes, $X = I_1 + I_2 + \dots + I_n$, où chaque I_j représente le succès (1) ou l'échec (0) du j -ième essai.

Chaque I_j a pour espérance $E(I_j) = 1 \cdot p + 0 \cdot (1 - p) = p$.

Par linéarité de l'espérance, on a :

$$E(X) = E(I_1) + E(I_2) + \cdots + E(I_n) = \underbrace{p + p + \cdots + p}_{n \text{ fois}} = np$$

4.4 Espérance de la loi géométrique

Calculons maintenant l'espérance pour la loi qui modélise le temps d'attente.

Théorème : Espérance de la loi géométrique

L'espérance d'une variable aléatoire $X \sim \text{Geom}(p)$ (comptant le nombre d'échecs) est :

$$E(X) = \frac{1-p}{p} = \frac{q}{p}$$

L'intuition est aussi très forte ici :

Intuition

Si un événement a 1 chance sur 10 de se produire ($p = 0.1$), il est logique de penser qu'il faudra en moyenne 9 échecs ($q/p = 0.9/0.1 = 9$) avant qu'il ne se produise. L'espérance du nombre total d'essais (échecs + 1 succès) serait alors $1/p$.

Contrairement à la loi binomiale, la preuve la plus directe ne repose pas sur la linéarité mais sur une manipulation de séries.

Preuve : Démonstration de l'espérance géométrique via les séries entières

Soit $X \sim \text{Geom}(p)$, où X compte le nombre d'échecs avant le premier succès. La PMF est $P(X = k) = q^k p$ pour $k = 0, 1, 2, \dots$, avec $q = 1 - p$.

Par définition, l'espérance est :

$$E(X) = \sum_{k=0}^{\infty} k \cdot P(X = k) = \sum_{k=0}^{\infty} k q^k p$$

Le terme pour $k = 0$ est nul, on peut donc commencer la somme à $k = 1$:

$$E(X) = p \sum_{k=1}^{\infty} k q^k$$

L'astuce consiste à reconnaître que la somme ressemble à la dérivée d'une série géométrique. Rappelons la formule de la série géométrique pour $|q| < 1$:

$$\sum_{k=0}^{\infty} q^k = \frac{1}{1-q}$$

En dérivant les deux côtés par rapport à q , on obtient :

$$\begin{aligned} \frac{d}{dq} \left(\sum_{k=0}^{\infty} q^k \right) &= \frac{d}{dq} \left(\frac{1}{1-q} \right) \\ \sum_{k=1}^{\infty} k q^{k-1} &= \frac{1}{(1-q)^2} \end{aligned}$$

Pour faire apparaître ce terme dans notre formule d'espérance, on factorise q dans la somme :

$$E(X) = p \cdot q \sum_{k=1}^{\infty} k q^{k-1}$$

On peut maintenant remplacer la somme par son expression analytique :

$$E(X) = p \cdot q \cdot \frac{1}{(1-q)^2}$$

Puisque $p = 1 - q$, on a :

$$E(X) = p \cdot q \cdot \frac{1}{p^2} = \frac{q}{p}$$

Ce qui démontre que l'espérance du nombre d'échecs avant le premier succès est $\frac{q}{p}$.

4.5 Loi du statisticien inconscient (LOTUS)

Souvent, nous ne sommes pas intéressés par l'espérance de X elle-même, mais par l'espérance d'une fonction de X , par exemple $E(X^2)$ ou $E(e^X)$.

Théorème : Théorème de Transfert (LOTUS)

Si X est une variable aléatoire discrète et $g(x)$ est une fonction de \mathbb{R} dans \mathbb{R} , alors l'espérance de la variable aléatoire $g(X)$ est donnée par :

$$E[g(X)] = \sum_x g(x)P(X = x)$$

La somme porte sur toutes les valeurs possibles de X . Ce théorème est utile car il évite d'avoir à trouver la PMF de $g(X)$.

La preuve dans le cas discret consiste simplement à regrouper les termes.

Preuve

Soit $Y = g(X)$. Par définition, l'espérance de Y est $E(Y) = \sum_y yP(Y = y)$. L'ensemble des valeurs y que Y peut prendre est $\{g(x) \mid x \in \text{support de } X\}$. Pour une valeur y donnée, l'événement $\{Y = y\}$ est l'union de tous les événements $\{X = x\}$ tels que $g(x) = y$.

$$P(Y = y) = P(g(X) = y) = \sum_{x:g(x)=y} P(X = x)$$

En substituant cela dans la définition de $E(Y)$:

$$E(Y) = \sum_y y \left(\sum_{x:g(x)=y} P(X = x) \right)$$

On peut réécrire y comme $g(x)$ à l'intérieur de la seconde somme :

$$E(g(X)) = \sum_y \sum_{x:g(x)=y} g(x)P(X = x)$$

Cette double somme parcourt toutes les valeurs de y , et pour chaque y , elle parcourt tous les x correspondants. Cela revient à simplement sommer sur tous les x possibles dès le départ :

$$E[g(X)] = \sum_x g(x)P(X = x)$$

Ce théorème justifie son nom : c'est ce que l'on ferait "inconsciemment".

Intuition

Pour trouver la valeur moyenne d'une fonction d'une variable aléatoire (par exemple, le carré du résultat d'un dé), vous n'avez pas besoin de déterminer d'abord la distribution de ce carré. Vous pouvez simplement prendre chaque valeur possible du résultat original, lui appliquer la fonction, et pondérer ce nouveau résultat par la probabilité du résultat original.

Utilisons ce théorème pour calculer $E(X^2)$ pour notre dé.

Exemple : Calcul de $E(X^2)$ pour un dé

Soit X le résultat d'un lancer de dé. Calculons l'espérance de $Y = X^2$. La fonction est $g(x) =$

x^2 .

$$\begin{aligned} E(X^2) &= \sum_{k=1}^6 k^2 P(X = k) \\ &= 1^2 \left(\frac{1}{6}\right) + 2^2 \left(\frac{1}{6}\right) + 3^2 \left(\frac{1}{6}\right) + 4^2 \left(\frac{1}{6}\right) + 5^2 \left(\frac{1}{6}\right) + 6^2 \left(\frac{1}{6}\right) \\ &= \frac{1 + 4 + 9 + 16 + 25 + 36}{6} = \frac{91}{6} \approx 15.17 \end{aligned}$$

4.6 Variance

L'espérance nous donne le centre d'une distribution, mais elle ne dit rien sur sa "largeur" ou sa "dispersion". C'est le rôle de la variance.

Définition : Variance et écart-type

La **variance** d'une variable aléatoire X mesure la dispersion de sa distribution autour de son espérance. Elle est définie par :

$$\text{Var}(X) = E[(X - E(X))^2]$$

La racine carrée de la variance est appelée l'**écart-type** :

$$\text{SD}(X) = \sqrt{\text{Var}(X)}$$

L'idée est de mesurer l'écart quadratique moyen à l'espérance.

Intuition

La variance est la "distance carrée moyenne à la moyenne". On prend l'écart de chaque valeur par rapport à la moyenne, on le met au carré (pour que les écarts positifs et négatifs ne s'annulent pas), puis on en calcule la moyenne. L'écart-type est souvent plus interprétable car il ramène cette mesure de dispersion dans les mêmes unités que la variable aléatoire elle-même.

La définition $E[(X - E(X))^2]$ est excellente pour l'interprétation, mais pénible pour le calcul. Une formule alternative est presque toujours utilisée.

Théorème : Formule de calcul de la variance

Pour toute variable aléatoire X , une formule plus pratique pour le calcul de la variance est :

$$\text{Var}(X) = E(X^2) - [E(X)]^2$$

La preuve est une simple expansion algébrique utilisant la linéarité de l'espérance.

Preuve

Soit $\mu = E(X)$. On part de la définition de la variance :

$$\begin{aligned} \text{Var}(X) &= E[(X - \mu)^2] \\ &= E[X^2 - 2X\mu + \mu^2] \quad (\text{On développe le carré}) \\ &= E(X^2) - E(2X\mu) + E(\mu^2) \quad (\text{Par linéarité de l'espérance}) \\ &= E(X^2) - 2\mu E(X) + \mu^2 \quad (\text{Car } 2\mu \text{ et } \mu^2 \text{ sont des constantes}) \\ &= E(X^2) - 2\mu(\mu) + \mu^2 \quad (\text{Car } E(X) = \mu) \\ &= E(X^2) - 2\mu^2 + \mu^2 \\ &= E(X^2) - \mu^2 = E(X^2) - [E(X)]^2 \end{aligned}$$

Nous pouvons maintenant calculer la variance de notre lancer de dé.

Exemple : Variance d'un lancer de dé

Nous avons déjà calculé pour un dé que $E(X) = 3.5$ et $E(X^2) = 91/6$. On peut maintenant

trouver la variance facilement :

$$\text{Var}(X) = E(X^2) - [E(X)]^2 = \frac{91}{6} - (3.5)^2 = \frac{91}{6} - 12.25 = 15.166... - 12.25 \approx 2.917$$

L'écart-type est $\text{SD}(X) = \sqrt{2.917} \approx 1.708$.

4.7 Exercices

Exercice 1 : Calcul d'Espérance (PMF Simple)

Une variable aléatoire X a la distribution de probabilité suivante : $P(X = -1) = 0.3$, $P(X = 0) = 0.5$, $P(X = 2) = 0.2$. Calculez l'espérance $E(X)$.

Exercice 2 : LOTUS (Calcul de $E(X^2)$)

En utilisant la même variable aléatoire X que dans l'exercice 1, calculez $E(X^2)$.

Exercice 3 : Variance (Calcul de base)

En utilisant les résultats des exercices 1 et 2, calculez la variance $\text{Var}(X)$.

Exercice 4 : Espérance (Jeu Simple)

Un jeu consiste à payer 2 pour lancer un dé à 6 faces. Si le dé tombe sur 6, vous gagnez 10. Sinon, vous ne gagnez rien. Soit G votre gain net (gain - mise).

1. Quelle est la PMF de G ?
2. Calculez $E(G)$. Le jeu est-il favorable au joueur ?

Exercice 5 : Variance (Jeu Simple)

En utilisant la variable aléatoire G de l'exercice 4 :

1. Calculez $E(G^2)$.
2. Calculez $\text{Var}(G)$.

Exercice 6 : Espérance de Bernoulli

Soit X une variable aléatoire $X \sim \text{Bern}(p)$ (variable indicatrice). En utilisant la définition de l'espérance, montrez que $E(X) = p$.

Exercice 7 : Variance de Bernoulli

En utilisant le résultat de l'exercice 6 et le théorème de LOTUS, montrez que $\text{Var}(X) = p(1-p)$ pour $X \sim \text{Bern}(p)$. (Indice : $X^2 = X$ pour une variable de Bernoulli).

Exercice 8 : Linéarité (Simple)

Soient X et Y deux variables aléatoires. On sait que $E(X) = 10$ et $E(Y) = -5$. Calculez $E(3X - 2Y + 4)$.

Exercice 9 : Linéarité (Trois Dés)

On lance trois dés équilibrés à 6 faces. Soit S la somme des trois résultats. En utilisant la linéarité de l'espérance, calculez $E(S)$.

Exercice 10 : Linéarité (Somme de Bernoulli)

Soit $X \sim \text{Bin}(n, p)$. On rappelle que X peut s'écrire comme la somme de n variables de Bernoulli indépendantes $X = I_1 + \dots + I_n$, où $E(I_j) = p$. Utilisez la linéarité de l'espérance pour prouver que $E(X) = np$.

Exercice 11 : Espérance Binomiale (Application)

Un QCM (questionnaire à choix multiples) comporte 40 questions. Chaque question a 4 options de réponse, dont une seule est correcte. Un étudiant répond à tout au hasard. Quel est le nombre attendu (l'espérance) de bonnes réponses ?

Exercice 12 : Espérance Géométrique (Application)

On lance une paire de dés équilibrés. Un "succès" est d'obtenir un double-six.

1. Quelle est la probabilité p d'un succès ?
2. Soit X le nombre d'échecs avant le premier double-six. Quelle est l'espérance $E(X)$?

Exercice 13 : Espérance Géométrique (Attente Totale)

En reprenant la situation de l'exercice 12 ($p = 1/36$), soit Y le *nombre total de lancers* nécessaires pour obtenir le premier double-six ($Y = X + 1$). Calculez $E(Y)$.

Exercice 14 : Espérance (Loi Hypergéométrique)

On tire 5 cartes d'un jeu de 52 cartes sans remise. Soit X le nombre d'As tirés. On peut écrire $X = I_1 + I_2 + I_3 + I_4 + I_5$, où $I_j = 1$ si la j -ème carte tirée est un As, et 0 sinon.

1. Quelle est la probabilité $P(I_1 = 1)$ (que la 1ère carte soit un As) ?
2. Quelle est la probabilité $P(I_2 = 1)$ (que la 2ème carte soit un As) ? (Indice : Pensez par symétrie ou utilisez la LTP).
3. Calculez $E(X)$ en utilisant la linéarité.

Exercice 15 : Espérance et Variance (Dé à 4 faces)

Soit X le résultat d'un lancer de dé équilibré à 4 faces ($X \in \{1, 2, 3, 4\}$).

1. Calculez $E(X)$.
2. Calculez $E(X^2)$.
3. Calculez $\text{Var}(X)$.

Exercice 16 : Formule de la Variance (Inverse)

Une variable aléatoire Y a une espérance $E(Y) = 5$ et une variance $\text{Var}(Y) = 4$. Quelle est la valeur de $E(Y^2)$?

Exercice 17 : Formule de la Variance (Inverse 2)

Une variable aléatoire W a $E(W^2) = 50$ et $\text{Var}(W) = 1$. Quelles sont les deux valeurs possibles pour $E(W)$?

Exercice 18 : Variance Nulle

Une variable aléatoire X a une variance $\text{Var}(X) = 0$. Que pouvez-vous conclure sur la distribution de X ? (Indice : $\text{Var}(X) = E[(X - \mu)^2]$).

Exercice 19 : LOTUS et Linéarité

Soit X une variable aléatoire avec $E(X) = 3$ et $E(X^2) = 10$. Calculez $E[(X + 1)^2]$. (Indice : Développez $(X + 1)^2$ avant de prendre l'espérance).

Exercice 20 : Synthèse (Jeu de Roulette)

À la roulette, vous misez 1 sur "Rouge". Il y a 18 cases rouges, 18 noires, et 1 verte (le 0). Total = 37 cases. Si "Rouge" sort, vous récupérez votre mise de 1 et gagnez 1 de plus (gain net $G = +1$). Si "Noir" or "Vert" sort, vous perdez votre mise (gain net $G = -1$).

1. Calculez $E(G)$.
2. Calculez $E(G^2)$.
3. Calculez $\text{Var}(G)$.

4.8 Corrections des Exercices

Correction Exercice 1 : Identification de Variables Aléatoires

1. **Discrète.** X ne peut prendre que des valeurs entières $\{0, 1, \dots, 10\}$. 2. **Continue.** Le temps peut prendre n'importe quelle valeur dans un intervalle (par ex. $T \in [2.5, 5]$ heures). 3. **Discrète.** X ne peut prendre que des valeurs entières $\{0, 1, 2, \dots\}$. 4. **Continue.** La température

peut prendre n'importe quelle valeur dans un intervalle (par ex. $T \in [15.0, 25.0]^\circ\text{C}$). 5. **Discreté**. X ne peut prendre que des valeurs entières $\{0, 1, 2, \dots\}$ (si on compte les échecs) ou $\{1, 2, 3, \dots\}$ (si on compte les lancers).

Correction Exercice 2 : Construction d'une PMF

On lance un dé à 4 faces (1, 2, 3, 4). X est le résultat. 1. Valeurs possibles : $S_X = \{1, 2, 3, 4\}$. 2. PMF : Le dé est équilibré, donc chaque face a la même probabilité $1/4$. $P(X = 1) = 1/4$ $P(X = 2) = 1/4$ $P(X = 3) = 1/4$ $P(X = 4) = 1/4$ Et $P(X = k) = 0$ pour tout autre k . 3. Vérification : $\sum P(X = k) = 1/4 + 1/4 + 1/4 + 1/4 = 4/4 = 1$.

Correction Exercice 3 : PMF d'une Somme

$Y = D_1 + D_2$, où $D_1, D_2 \in \{1, 2, 3, 4\}$. Il y a $4 \times 4 = 16$ issues équiprobables (prob. $1/16$ chacune). 1. Valeurs possibles : Min = $1 + 1 = 2$. Max = $4 + 4 = 8$. $S_Y = \{2, 3, 4, 5, 6, 7, 8\}$. 2. PMF (en comptant les issues favorables sur 16) : - $P(Y = 2) = P(1, 1) \Rightarrow 1/16$ - $P(Y = 3) = P(1, 2) + P(2, 1) \Rightarrow 2/16$ - $P(Y = 4) = P(1, 3) + P(2, 2) + P(3, 1) \Rightarrow 3/16$ - $P(Y = 5) = P(1, 4) + P(2, 3) + P(3, 2) + P(4, 1) \Rightarrow 4/16$ - $P(Y = 6) = P(2, 4) + P(3, 3) + P(4, 2) \Rightarrow 3/16$ - $P(Y = 7) = P(3, 4) + P(4, 3) \Rightarrow 2/16$ - $P(Y = 8) = P(4, 4) \Rightarrow 1/16$ (Vérification : $1 + 2 + 3 + 4 + 3 + 2 + 1 = 16$. La somme est $16/16 = 1$).

Correction Exercice 4 : Construction d'une CDF

On utilise la PMF de l'exercice 3. $F_Y(y) = P(Y \leq y)$. 1. CDF aux points de masse : - $F_Y(2) = P(Y \leq 2) = P(Y = 2) = 1/16$ - $F_Y(3) = P(Y \leq 3) = P(Y = 2) + P(Y = 3) = 1/16 + 2/16 = 3/16$ - $F_Y(4) = P(Y \leq 4) = 3/16 + P(Y = 4) = 3/16 + 3/16 = 6/16$ - $F_Y(5) = P(Y \leq 5) = 6/16 + P(Y = 5) = 6/16 + 4/16 = 10/16$ - $F_Y(6) = P(Y \leq 6) = 10/16 + P(Y = 6) = 10/16 + 3/16 = 13/16$ - $F_Y(7) = P(Y \leq 7) = 13/16 + P(Y = 7) = 13/16 + 2/16 = 15/16$ - $F_Y(8) = P(Y \leq 8) = 15/16 + P(Y = 8) = 15/16 + 1/16 = 16/16 = 1$ 2. $F_Y(1.5) = P(Y \leq 1.5) = 0$ (car la valeur minimale est 2). 3. $F_Y(5.2) = P(Y \leq 5.2) = P(Y \leq 5) = F_Y(5) = 10/16$. 4. $F_Y(10) = P(Y \leq 10) = 1$ (car la valeur maximale est 8).

Correction Exercice 5 : Loi de Bernoulli

1. X suit une **loi de Bernoulli**. Le paramètre est $p = 0.05$. On note $X \sim \text{Bern}(0.05)$. 2. La PMF est : $P(X = 1) = p = 0.05$ (succès = défectueux) $P(X = 0) = 1 - p = 0.95$ (échec = non défectueux)

Correction Exercice 6 : Loi Binomiale (Calcul Direct)

1. X est le nombre de succès (Pile) en $n = 5$ essais indépendants avec probabilité $p = 0.7$. X suit une **loi Binomiale**. $X \sim \text{Bin}(n = 5, p = 0.7)$. 2. $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$. $P(X = 3) = \binom{5}{3} (0.7)^3 (1 - 0.7)^{5-3} = 10 \times (0.343) \times (0.3)^2 = 10 \times 0.343 \times 0.09 = 0.3087$. 3. $P(X = 5) = \binom{5}{5} (0.7)^5 (0.3)^0 = 1 \times (0.7)^5 \times 1 = 0.16807$.

Correction Exercice 7 : Loi Binomiale (Calcul Cumulé)

On a $X \sim \text{Bin}(5, 0.7)$. 1. $P(X = 0) = \binom{5}{0} (0.7)^0 (0.3)^5 = 1 \times 1 \times (0.3)^5 = 0.00243$. 2. L'événement "au moins 1 Pile" ($X \geq 1$) est le complémentaire de "0 Pile" ($X = 0$). $P(X \geq 1) = 1 - P(X = 0) = 1 - 0.00243 = 0.99757$.

Correction Exercice 8 : Problème Binomial (Contrôle Qualité)

Le tirage est *avec remise*, donc les essais sont indépendants. C'est une loi binomiale. $n = 20$ (nombre d'essais). $p = 0.10$ (probabilité de succès = défectueux). On cherche $P(X = 2)$. $P(X = 2) = \binom{20}{2} (0.1)^2 (1 - 0.1)^{20-2}$ $P(X = 2) = \frac{20 \times 19}{2} (0.1)^2 (0.9)^{18} = 190 \times 0.01 \times (0.9)^{18}$ $P(X = 2) = 1.9 \times (0.9)^{18} \approx 1.9 \times 0.15009 \approx 0.2852$.

Correction Exercice 9 : Loi Hypergéométrique (Urne)

Le tirage est *sans remise* d'une population finie. 1. X suit une **loi Hypergéométrique**. Paramètres : $w = 7$ (blanches, succès), $b = 5$ (noires, échecs), $m = 4$ (nombre de tirages). $X \sim \text{HG}(w = 7, b = 5, m = 4)$. 2. On cherche $P(X = 2)$. $P(X = k) = \frac{\binom{w}{k} \binom{b}{m-k}}{\binom{w+b}{m}}$ $P(X = 2) =$

$$\frac{\binom{7}{2}\binom{5}{4-2}}{\binom{12}{4}} = \frac{\binom{7}{2}\binom{5}{2}}{\binom{12}{4}} P(X=2) = \frac{\left(\frac{7 \times 6}{2}\right) \times \left(\frac{5 \times 4}{2}\right)}{\frac{12 \times 11 \times 10 \times 9}{4 \times 3 \times 2 \times 1}} = \frac{21 \times 10}{495} = \frac{210}{495} = \frac{14}{33} \approx 0.4242.$$

Correction Exercice 10 : Problème Hypergéométrique (Comité)

Tirage sans remise. C'est une loi Hypergéométrique. $w = 10$ (hommes), $b = 8$ (femmes), $m = 6$ (taille du comité). Total $N = 18$. On cherche $P(X = 3)$ (exactement 3 hommes, ce qui implique $m - k = 6 - 3 = 3$ femmes). $P(X = 3) = \frac{\binom{10}{3}\binom{8}{3}}{\binom{18}{6}} P(X = 3) = \frac{\left(\frac{10 \times 9 \times 8}{3 \times 2 \times 1}\right) \times \left(\frac{8 \times 7 \times 6}{3 \times 2 \times 1}\right)}{\frac{18 \times 17 \times 16 \times 15 \times 14 \times 13}{6 \times 5 \times 4 \times 3 \times 2 \times 1}} = \frac{120 \times 56}{18564} = \frac{6720}{18564} \approx 0.362$.

Correction Exercice 11 : Binomiale vs Hypergéométrique

Population totale $N = 10000$. 10% défectueux, donc $w = 1000$ (défectueux), $b = 9000$ (non défectueux). Tirage de $m = 20$ sans remise. 1. Loi exacte : **Loi Hypergéométrique**. $X \sim \text{HG}(w = 1000, b = 9000, m = 20)$. 2. Probabilité exacte $P(X = 2)$: $P(X = 2) = \frac{\binom{1000}{2}\binom{9000}{18}}{\binom{10000}{20}}$
 $P(X = 2) = \frac{\left(\frac{1000 \times 999}{2}\right) \times \left(\frac{9000 \times \dots \times 8983}{18!}\right)}{\frac{10000 \times \dots \times 9981}{20!}} \approx 0.2854$. (Le calcul est très complexe, mais on peut montrer qu'il est très proche de la binomiale). 3. Le résultat de l'exercice 8 (Binomiale) était ≈ 0.2852 . L'approximation binomiale est excellente. La raison est que la taille de l'échantillon ($m = 20$) est très petite par rapport à la taille de la population ($N = 10000$). Le fait de ne pas remettre les 20 articles change à peine les probabilités pour les tirages suivants.

Correction Exercice 12 : Loi Géométrique (Calcul Direct)

1. X est le nombre d'échecs avant le premier succès. X suit une **loi Géométrique**. Le succès est "obtenir 6", donc $p = 1/6$. $X \sim \text{Geom}(p = 1/6)$. 2. "Premier 6 au 3ème lancer" signifie 2 échecs (lancers 1 et 2) puis 1 succès (lancer 3). C'est $P(X = 2)$. $q = 1 - p = 5/6$. $P(X = 2) = q^2 p^1 = (5/6)^2 (1/6) = 25/216 \approx 0.1157$. 3. "Premier 6 au 1er lancer" signifie 0 échec. C'est $P(X = 0)$. $P(X = 0) = q^0 p^1 = 1 \times (1/6) = 1/6$.

Correction Exercice 13 : Loi Géométrique (Calcul Cumulé)

$p = 0.2$ (succès), $q = 0.8$ (échec). X compte les échecs. $X \sim \text{Geom}(0.2)$. 1. "Exactement 4 tirs au total" signifie 3 échecs suivis d'un succès. On cherche $P(X = 3)$. $P(X = 3) = q^3 p^1 = (0.8)^3 (0.2) = 0.512 \times 0.2 = 0.1024$. 2. "Plus de 2 tirs au total" signifie qu'il faut au moins 3 tirs. C'est l'événement "les 2 premiers tirs sont des échecs". La probabilité est $P(\text{Echec } 1 \cap \text{Echec } 2) = q \times q = q^2$. $P(X \geq 2) = (0.8)^2 = 0.64$.

Correction Exercice 14 : Variante de la Loi Géométrique

Y est le nombre total d'essais ($k = 1, 2, 3, \dots$). p est la prob. de succès. 1. Pour que $Y = k$, il faut $k - 1$ échecs, suivis d'un succès. $P(Y = k) = (1 - p)^{k-1} p = q^{k-1} p$, pour $k = 1, 2, \dots$. 2. Avec $p = 1/6$, on cherche $P(Y = 3)$. $P(Y = 3) = (5/6)^{3-1} (1/6) = (5/6)^2 (1/6) = 25/216$. C'est le même résultat que $P(X = 2)$ de l'exercice 12. Les deux définitions décrivent la même situation (3 lancers au total).

Correction Exercice 15 : Loi de Poisson (Calcul Direct)

$X \sim \text{Poisson}(\lambda = 5)$. PMF : $P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$. 1. $P(X = 0) = \frac{e^{-5} 5^0}{0!} = \frac{e^{-5} \times 1}{1} = e^{-5} \approx 0.0067$. 2. $P(X = 5) = \frac{e^{-5} 5^5}{5!} = \frac{e^{-5} \times 3125}{120} = e^{-5} \times \frac{625}{24} \approx 26.04 \times e^{-5} \approx 0.1755$.

Correction Exercice 16 : Loi de Poisson (Calcul Cumulé)

$X \sim \text{Poisson}(\lambda = 2)$. On cherche $P(X \leq 2)$. $P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$
 $P(X = 0) = \frac{e^{-2} 2^0}{0!} = e^{-2}$ $P(X = 1) = \frac{e^{-2} 2^1}{1!} = 2e^{-2}$ $P(X = 2) = \frac{e^{-2} 2^2}{2!} = \frac{4e^{-2}}{2} = 2e^{-2}$
 $P(X \leq 2) = e^{-2} + 2e^{-2} + 2e^{-2} = 5e^{-2} \approx 5 \times 0.1353 = 0.6767$.

Correction Exercice 17 : Loi de Poisson (Changement de λ)

1. Pour une page, $X \sim \text{Poisson}(\lambda = 0.5)$. $P(X = 0) = \frac{e^{-0.5} (0.5)^0}{0!} = e^{-0.5} \approx 0.6065$. 2. Si le taux est 0.5 faute/page, le taux pour 10 pages est $\lambda_Y = 0.5 \times 10 = 5$. $Y \sim \text{Poisson}(\lambda_Y = 5)$. 3. On cherche $P(Y = 0)$. $P(Y = 0) = \frac{e^{-5} 5^0}{0!} = e^{-5} \approx 0.0067$.

Correction Exercice 18 : Approximation Binomiale par Poisson

1. C'est un tirage de $n = 10000$ clients, où chaque client est un essai de Bernoulli avec $p = 0.0003$. La loi exacte est $X \sim \text{Bin}(10000, 0.0003)$. 2. Le paramètre λ pour l'approximation Poisson est $\lambda = np = 10000 \times 0.0003 = 3$. 3. On utilise $Y \sim \text{Poisson}(\lambda = 3)$ pour approximer X . $P(X = 2) \approx P(Y = 2) = \frac{e^{-3} 3^2}{2!} = \frac{9e^{-3}}{2} = 4.5e^{-3} \approx 4.5 \times 0.04979 \approx 0.224$.

Correction Exercice 19 : Choisir la Bonne Loi

1. Tirage sans remise d'une population finie : **Loi Hypergéométrique**. 2. Comptage d'événements sur un intervalle de temps fixe : **Loi de Poisson**. 3. Comptage d'essais jusqu'au premier succès : **Loi Géométrique**. 4. Comptage de succès sur un nombre fixe d'essais indépendants : **Loi Binomiale**. 5. Comptage d'événements rares sur un intervalle (temps/espace) : **Loi de Poisson**.

Correction Exercice 20 : Variable Indicatrice

$A = \text{"obtenir 6"}$. $P(A) = 1/6$. $I_A = 1$ si A se produit, $I_A = 0$ sinon. 1. C'est une expérience avec deux issues (succès/échec). I_A suit une **Loi de Bernoulli**. Le paramètre est $p = P(A) = 1/6$. $I_A \sim \text{Bern}(1/6)$. 2. La PMF de I_A est : $P(I_A = 1) = p = 1/6$ $P(I_A = 0) = 1 - p = 5/6$

4.9 Exercices Pratiques (Python)

Ces exercices vous aideront à calculer et à vérifier empiriquement les concepts d'espérance et de variance en utilisant des simulations.

Pour ces exercices, vous aurez besoin de la bibliothèque `numpy`.

```
pip install numpy
```

Exercice 1 : $E(X)$ $E(X^2)$ et Variance (Dé)

Nous allons simuler N lancers d'un dé à 6 faces pour vérifier empiriquement la définition de l'espérance, le théorème LOTUS, et la formule de calcul de la variance.

Votre tâche :

1. Simulez 100 000 lancers d'un dé équilibré (valeurs de 1 à 6) et stockez les résultats dans un tableau NumPy.
2. Calculez l'espérance empirique $E(X)$ en prenant la moyenne du tableau.
3. En utilisant LOTUS, calculez l'espérance empirique $E(X^2)$ (en créant un nouveau tableau des carrés, puis en prenant sa moyenne).
4. Calculez la variance empirique en utilisant la formule : $\text{Var}(X) = E(X^2) - [E(X)]^2$.
5. Comparez votre résultat à la variance calculée directement avec `numpy.var()`.

```

import numpy as np

N_simulations = 100000

# 1. Simuler N lancers d'un de a 6 faces
# lancers = ...

# 2. Calculer E(X) (moyenne empirique)
# E_X = ...
# print(f"E(X) empirique: {E_X:.4f} (Theorique: 3.5)")

# 3. Calculer E(X^2) (LOTUS)
# lancers_carres = ...
# E_X2 = ...
# print(f"E(X^2) empirique: {E_X2:.4f} (Theorique: 91/6 = 15.1667)")

# 4. Calculer Var(X) avec la formule
# var_calc = ...
# print(f"Variance (calculee): {var_calc:.4f}")

# 5. Calculer Var(X) avec la fonction numpy
# var_np = ...
# print(f"Variance (numpy.var): {var_np:.4f}")
# print(f"Difference: {np.abs(var_calc - var_np):.6f}")

```

Exercice 2 : Linearite de l'Esperance

Vérifions empiriquement que $E(X + Y) = E(X) + E(Y)$. Nous allons simuler deux variables aléatoires différentes : X (un dé à 4 faces) et Y (un dé à 6 faces).

Votre tâche :

1. Simulez $N = 100000$ lancers d'un dé à 4 faces (X).
2. Simulez $N = 100000$ lancers d'un dé à 6 faces (Y).
3. Créez la variable aléatoire $Z = X + Y$.
4. Calculez les moyennes empiriques $E(X)$, $E(Y)$, et $E(Z)$.
5. Vérifiez que $E(Z)$ est très proche de $E(X) + E(Y)$.

```

import numpy as np

N_simulations = 100000

# 1. Simuler X (de a 4 faces) et Y (de a 6 faces)
# X = ...
# Y = ...

# 2. Creer Z = X + Y
# Z = ...

# 3. Calculer les moyennes empiriques
# E_X = ...
# E_Y = ...
# E_Z = ...

# 4. Verifier la linearite
# print(f"E(X) = {E_X:.4f}")
# print(f"E(Y) = {E_Y:.4f}")
# print(f"E(X) + E(Y) = {E_X + E_Y:.4f}")
# print(f"E(Z) = E(X+Y) = {E_Z:.4f}")

```

Exercice 3 : Esperance Binomiale (Simulation)

La théorie nous dit que pour $X \sim \text{Bin}(n, p)$, $E(X) = np$. Nous allons vérifier cela par simulation.

Votre tâche :

1. Définissez les paramètres $n = 20$ et $p = 0.4$.
2. Simulez 100 000 réalisations d'une variable aléatoire $X \sim \text{Bin}(n, p)$ en utilisant `numpy.random.binomial()`.
3. Calculez la moyenne empirique de vos simulations.
4. Comparez la moyenne empirique à l'espérance théorique np .

```
import numpy as np

n, p = 20, 0.4
N_simulations = 100000

# 1. Simuler N fois une loi Bin(n, p)
# resultats_bin = ...

# 2. Calculer la moyenne empirique
# moyenne_empirique = ...

# 3. Calculer la moyenne theorique
# moyenne_theorique = ...

# 4. Afficher
# print(f"Moyenne empirique: {moyenne_empirique:.4f}")
# print(f"Esperance theorique (np): {moyenne_theorique:.4f}")
```

Exercice 4 : Esperance Geometrique (Simulation)

Pour $X \sim \text{Geom}(p)$ (comptant les échecs), $E(X) = q/p$. Vérifions cela.

Votre tâche :

1. Définissez $p = 0.2$ (et $q = 1 - p$).
2. Simulez 100 000 réalisations d'une variable $Y \sim \text{Geom}(p)$ en utilisant `numpy.random.geometric()`.
3. **Attention :** `numpy.random.geometric` compte le nombre d'essais ($k = 1, 2, \dots$). Pour obtenir X (le nombre d'échecs, $k = 0, 1, \dots$), vous devez soustraire 1 de chaque résultat.
4. Calculez la moyenne empirique de X (le nombre d'échecs).
5. Comparez cette moyenne à l'espérance théorique q/p .

```
import numpy as np

p = 0.2
q = 1 - p
N_simulations = 100000

# 1. Simuler N fois une loi Geom(p) (nb d'essais)
# resultats_geom_essais = ...

# 3. Convertir en nombre d'echecs
# resultats_geom_echecs = ...

# 4. Calculer la moyenne empirique des echecs
# moyenne_empirique = ...

# 5. Calculer la moyenne theorique des echecs
# moyenne_theorique = ...

# 6. Afficher
# print(f"Moyenne empirique (echecs): {moyenne_empirique:.4f}")
# print(f"Esperance theorique (q/p): {moyenne_theorique:.4f}")
```

Exercice 5 : Esperance et Variance de Bernoulli

La variable aléatoire de Bernoulli $X \sim \text{Bern}(p)$ est la brique de base. Théoriquement, $E(X) = p$ et $\text{Var}(X) = p(1 - p)$.

Votre tâche :

1. Définissez $p = 0.8$.
2. Simulez 100 000 essais de Bernoulli (résultats 0 ou 1) avec probabilité p . (Indice : `numpy.random.choice` ou `numpy.random.binomial` avec $n = 1$).
3. Calculez l'espérance empirique (la moyenne) et la variance empirique (`numpy.var`).
4. Comparez-les aux valeurs théoriques p et $p(1 - p)$.

```
import numpy as np

p = 0.8
N_simulations = 100000

# 1. Simuler N essais de Bernoulli
# essais = ...

# 2. Calculer l'esperance et la variance empiriques
# E_empirique = ...
# Var_empirique = ...

# 3. Calculer les valeurs theoriques
# E_theorique = ...
# Var_theorique = ...

# 4. Afficher
# print(f"Esperance: Empirique={E_empirique:.4f}, Theorique={E_theorique:.4f}")
# print(f"Variance: Empirique={Var_empirique:.4f}, Theorique={Var_theorique:.4f}")
```

5 Distributions Multivariées et Concepts Associés

5.1 Distributions Jointes et Marginales

Jusqu'à présent, nous avons étudié les variables aléatoires isolément. Nous allons maintenant examiner comment analyser les relations entre *plusieurs* variables aléatoires.

Définition : Distribution Jointe (Cas Discret)

Pour deux variables aléatoires discrètes X et Y , la **distribution jointe** (ou loi jointe) spécifie la probabilité de chaque paire d'issues. La fonction de masse de probabilité jointe (joint PMF) est :

$$P(X = x, Y = y)$$

Si X prend ses valeurs dans un ensemble S et Y dans un ensemble T , alors la somme de toutes les probabilités jointes est égale à 1 :

$$\sum_{x \in S} \sum_{y \in T} P(X = x, Y = y) = 1$$

Cette loi jointe est la "carte" complète de toutes les issues possibles.

Intuition

La distribution jointe est la "carte" complète de toutes les issues possibles. Elle répond à la question : "Quelle est la probabilité que X prenne cette valeur ET que Y prenne cette autre valeur en même temps?". Si vous imaginez un tableau à double entrée pour X et Y , la loi jointe est l'ensemble de toutes les probabilités à l'intérieur du tableau.

Cette "carte" complète contient toutes les informations. Si nous ne nous intéressons qu'à une seule variable, nous pouvons la "réduire" en calculant sa distribution marginale.

Définition : Distribution Marginale

À partir de la distribution jointe, on peut obtenir la distribution **marginale** (ou loi marginale) de chaque variable. Pour obtenir la probabilité que X prenne une valeur x , on somme sur toutes les valeurs possibles de Y :

$$P(X = x) = \sum_{y \in T} P(X = x, Y = y)$$

Visuellement, cela correspond à "écraser" le tableau de probabilités sur un seul de ses axes.

Intuition

Les distributions marginales sont les "ombres" ou "projections" de la carte jointe sur un seul axe. Si la loi jointe est un tableau, les lois marginales sont les totaux de chaque ligne et de chaque colonne, que l'on écrirait "dans la marge" du tableau. Elles nous disent la probabilité d'une issue pour X sans se soucier de ce qu'il advient de Y .

L'exemple le plus simple est le lancer de deux dés.

Exemple : Lois jointe et marginale

On lance un dé rouge (X) et un dé bleu (Y). Il y a 36 issues, chacune avec une probabilité de $1/36$. **Loi jointe** : $P(X = x, Y = y) = 1/36$ pour tout $x, y \in \{1, \dots, 6\}$. Par exemple, $P(X = 2, Y = 5) = 1/36$.

Loi marginale de X : Cherchons $P(X = 2)$. C'est la probabilité d'obtenir 2 sur le dé rouge, quel que soit le résultat du bleu.

$$P(X = 2) = \sum_{y=1}^6 P(X = 2, Y = y)$$

$$P(X = 2) = P(X = 2, Y = 1) + \dots + P(X = 2, Y = 6)$$

$$P(X = 2) = \frac{1}{36} + \frac{1}{36} + \frac{1}{36} + \frac{1}{36} + \frac{1}{36} + \frac{1}{36} = \frac{6}{36} = \frac{1}{6}$$

Ceci est bien la loi d'un seul dé.

5.2 Espérance d'une fonction de deux variables

Maintenant que nous avons la loi jointe (la carte des probabilités), nous pouvons l'utiliser pour calculer l'espérance de n'importe quelle fonction qui dépend des deux variables, $g(X, Y)$.

Définition : Espérance d'une fonction $g(X, Y)$

L'espérance d'une fonction $g(X, Y)$ de deux variables aléatoires discrètes X et Y est une généralisation du théorème de transfert (LOTUS) :

$$E[g(X, Y)] = \sum_{x \in S} \sum_{y \in T} g(x, y) P(X = x, Y = y)$$

C'est la moyenne de g , pondérée par les probabilités jointes.

Intuition

C'est la valeur moyenne attendue de la fonction g . Pour la calculer, on prend chaque résultat possible de $g(x, y)$, on le pondère par la probabilité que cette combinaison (x, y) se produise (donnée par la loi jointe), et on somme le tout.

Le cas le plus important de $g(X, Y)$ est la somme $X + Y$.

Exemple

Espérance de $E[X + Y]$ Avec nos deux dés, calculons l'espérance de la somme $S = X + Y$. La fonction est $g(X, Y) = X + Y$.

$$\begin{aligned} E[X + Y] &= \sum_{x=1}^6 \sum_{y=1}^6 (x + y) P(X = x, Y = y) \\ E[X + Y] &= \sum_{x=1}^6 \sum_{y=1}^6 (x + y) \frac{1}{36} \end{aligned}$$

Plutôt que de faire ce long calcul, on peut utiliser la linéarité de l'espérance (qui est un cas particulier de ce théorème) :

$$E[X + Y] = E[X] + E[Y] = 3.5 + 3.5 = 7.$$

5.3 Covariance et Corrélation

La linéarité $E[X + Y] = E[X] + E[Y]$ est un outil puissant. Mais l'espérance ne nous dit rien sur la *relation* entre X et Y . Pour cela, nous introduisons la covariance.

Définition : Covariance

La **covariance** entre deux variables aléatoires X et Y , avec pour moyennes respectives μ_X et μ_Y , mesure la façon dont elles varient ensemble.

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

Elle mesure la direction de leur relation.

Intuition

La covariance est positive si les variables ont tendance à "bouger" dans la même direction (quand X est au-dessus de sa moyenne, Y a tendance à l'être aussi). Elle est négative si elles bougent en sens opposé (quand X est au-dessus de sa moyenne, Y a tendance à être en dessous). Si elle est nulle, il n'y a pas de tendance linéaire entre elles.

La définition $E[(X - \mu_X)(Y - \mu_Y)]$ est bonne pour l'intuition, mais difficile à calculer. Une formule alternative est presque toujours utilisée.

Théorème : Formule de calcul de la covariance

Une formule computationnelle plus simple pour la covariance est :

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$$

La preuve est une simple expansion algébrique.

Preuve

Soit $\mu_X = E[X]$ et $\mu_Y = E[Y]$. On part de la définition :

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E[XY - X\mu_Y - Y\mu_X + \mu_X\mu_Y] \quad (\text{On développe}) \\ &= E[XY] - E[X\mu_Y] - E[Y\mu_X] + E[\mu_X\mu_Y] \quad (\text{Par linéarité}) \\ &= E[XY] - \mu_Y E[X] - \mu_X E[Y] + \mu_X\mu_Y \quad (\text{Les moyennes sont des constantes}) \\ &= E[XY] - \mu_Y\mu_X - \mu_X\mu_Y + \mu_X\mu_Y \\ &= E[XY] - \mu_X\mu_Y \\ &= E[XY] - E[X]E[Y]\end{aligned}$$

Voyons cette formule en action.

Exemple : Calcul de covariance

Cas 1 : Dés indépendants. X et Y sont les résultats de deux dés. $E[X] = 3.5$, $E[Y] = 3.5$. Calculons $E[XY]$. Puisqu'ils sont indépendants, $E[XY] = E[X]E[Y] = 3.5 \times 3.5 = 12.25$. $\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 12.25 - 12.25 = 0$. La covariance est nulle, ce qui est attendu pour des variables indépendantes.

Cas 2 : Variables dépendantes. Soit X un lancer de dé, et $Y = 2X$. $E[X] = 3.5$. $E[Y] = E[2X] = 2E[X] = 7$. $E[XY] = E[X \cdot 2X] = E[2X^2] = 2E[X^2]$. On sait que $E[X^2] = \frac{1^2 + \dots + 6^2}{6} = 91/6$. $E[XY] = 2(91/6) = 91/3$. $\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = \frac{91}{3} - (3.5)(7) = \frac{91}{3} - 24.5 = 30.33\ldots - 24.5 \approx 5.833$. La covariance est positive, ce qui est logique : si X est grand, Y l'est aussi.

La covariance est un bon indicateur de la direction de la relation, mais sa magnitude est difficile à interpréter. Pour cela, nous la normalisons.

Définition : Corrélation

La **corrélation** (ou coefficient de corrélation de Pearson, r) est une version normalisée de la covariance, qui se situe toujours entre -1 et 1.

$$\text{Corr}(X, Y) = r = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X\sigma_Y}$$

La corrélation résout le problème des unités.

Intuition

Le problème de la covariance est qu'elle dépend des unités de X et Y (par ex., $\text{kg} \cdot \text{cm}$). Si vous changez les unités (grammes et mètres), la valeur de la covariance change, même si la relation est identique. La corrélation résout ce problème : elle est sans unité. Un coefficient de +1 indique une relation linéaire positive parfaite, -1 une relation linéaire négative parfaite, et 0 une absence de relation linéaire.

Cette normalisation se comprend mieux en voyant la corrélation comme une covariance de variables standardisées.

Intuition : Interprétation de la formule

On peut voir la corrélation de Pearson comme un processus en 3 étapes :

1. **Centrer les variables** : On calcule l'écart de chaque valeur à sa moyenne ($x_i - \bar{x}$ et $y_i - \bar{y}$). Cela élimine "l'effet de base" (ex : une personne de 180cm vs 170cm ; la moyenne change mais les écarts relatifs restent les mêmes).
2. **Normaliser les variables** : On divise chaque écart par l'écart-type de sa variable ($z_{xi} =$

$(x_i - \bar{x})/\sigma_X$ et $z_{yi} = (y_i - \bar{y})/\sigma_Y$. Ces nouvelles variables Z_X et Z_Y sont **standardisées** : elles ont une moyenne de 0, un écart-type de 1, et sont sans unité.

3. **Calculer la covariance des variables standardisées** : La corrélation n'est rien d'autre que la covariance de ces deux nouvelles variables standardisées : $r = \text{Cov}(Z_X, Z_Y)$.

Parce que les deux variables sont maintenant sur la même échelle (écart-type de 1), leur covariance (la corrélation) ne peut pas dépasser 1 en valeur absolue.

Reprenons notre exemple de dépendance parfaite :

Exemple : Calcul de corrélation

Reprenons l'exemple $Y = 2X$, où X est un lancer de dé. On a $\text{Cov}(X, Y) = 5.833... = 35/6$.
 $\text{Var}(X) = E[X^2] - E[X]^2 = 91/6 - (3.5)^2 = 35/12$. $\text{Var}(Y) = \text{Var}(2X) = 2^2 \text{Var}(X) = 4(35/12) = 35/3$. $\sigma_X \sigma_Y = \sqrt{35/12} \cdot \sqrt{35/3} = \sqrt{(35 \cdot 35)/(12 \cdot 3)} = \sqrt{35^2/36} = 35/6$.

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{35/6}{35/6} = 1$$

La corrélation est de 1, ce qui est parfait : Y est une fonction linéaire parfaite de X .

5.4 Linéarité de la Covariance

Tout comme l'espérance, la covariance possède d'importantes propriétés de linéarité qui simplifient les calculs.

Définition : Linéarité de la Covariance

Pour des variables aléatoires X, Y, Z et des constantes a, b, c :

$$\begin{aligned}\text{Cov}(aX + bY + c, Z) &= a\text{Cov}(X, Z) + b\text{Cov}(Y, Z) \\ \text{Cov}(X, aY + bZ + c) &= a\text{Cov}(X, Y) + b\text{Cov}(X, Z)\end{aligned}$$

La covariance est linéaire pour chaque argument (elle est **bilinéaire**). Les constantes additives disparaissent.

5.5 Résultats sur la Corrélation

La propriété la plus importante de la corrélation, qui découle de sa normalisation, est qu'elle est bornée.

Théorème : Bornes du Coefficient de Corrélation de Pearson

Pour toutes variables aléatoires X et Y , le coefficient de corrélation $\text{Corr}(X, Y)$ est borné :

$$-1 \leq \text{Corr}(X, Y) \leq 1$$

De plus, si $\text{Corr}(X, Y) = \pm 1$, alors il existe des constantes a et b telles que $Y = aX + b$, indiquant une relation linéaire parfaite.

La preuve de ces bornes repose sur le fait que la variance est toujours positive.

Preuve : Démonstration des Bornes de la Corrélation

La preuve repose sur le fait que la variance d'une variable aléatoire est toujours positive ou nulle.

Étape 1 : Variables Standardisées On définit les versions standardisées de X et Y :

$$X^* = \frac{X - \mu_X}{\sigma_X} \quad ; \quad Y^* = \frac{Y - \mu_Y}{\sigma_Y}$$

Par construction, $E[X^*] = E[Y^*] = 0$ et $\text{Var}(X^*) = \text{Var}(Y^*) = 1$.

Étape 2 : Covariance des variables standardisées Calculons la covariance de X^* et Y^* ,

qui est, par définition, la corrélation de X et Y .

$$\begin{aligned}\text{Cov}(X^*, Y^*) &= \text{Cov}\left(\frac{X - \mu_X}{\sigma_X}, \frac{Y - \mu_Y}{\sigma_Y}\right) \\ &= \frac{1}{\sigma_X \sigma_Y} \text{Cov}(X - \mu_X, Y - \mu_Y) \\ &= \frac{1}{\sigma_X \sigma_Y} \text{Cov}(X, Y) \\ &= \text{Corr}(X, Y)\end{aligned}$$

Étape 3 : Variance de la somme et de la différence Considérons la variance de la somme et de la différence de ces variables standardisées.

$$\text{Var}(X^* + Y^*) = \text{Var}(X^*) + \text{Var}(Y^*) + 2\text{Cov}(X^*, Y^*)$$

$$\text{Var}(X^* + Y^*) = 1 + 1 + 2\text{Corr}(X, Y) = 2 + 2\text{Corr}(X, Y)$$

De même :

$$\text{Var}(X^* - Y^*) = \text{Var}(X^*) + \text{Var}(Y^*) - 2\text{Cov}(X^*, Y^*)$$

$$\text{Var}(X^* - Y^*) = 1 + 1 - 2\text{Corr}(X, Y) = 2 - 2\text{Corr}(X, Y)$$

Étape 4 : La variance est toujours ≥ 0 La variance d'une variable aléatoire ne peut pas être négative.

$$\text{Var}(X^* + Y^*) \geq 0 \implies 2 + 2\text{Corr}(X, Y) \geq 0 \implies \text{Corr}(X, Y) \geq -1$$

$$\text{Var}(X^* - Y^*) \geq 0 \implies 2 - 2\text{Corr}(X, Y) \geq 0 \implies \text{Corr}(X, Y) \leq 1$$

Ceci nous donne le résultat final :

$$-1 \leq \text{Corr}(X, Y) \leq 1$$

5.6 Standardisation et Non-Corrélation

Le processus de 'standardisation' utilisé dans la preuve de la corrélation et dans l'intuition est un concept fondamental en soi.

Définition : Variable Centrée Réduite

Soit X une variable aléatoire avec :

- moyenne $\mu_X = E[X]$
- écart-type $\sigma_X = \sqrt{\text{Var}(X)} > 0$

On définit sa version **centrée réduite** (standardisée) Z par :

$$Z = \frac{X - \mu_X}{\sigma_X}$$

Alors, Z a les propriétés suivantes :

1. **Centrée (moyenne nulle) :**

$$\begin{aligned}E[Z] &= E\left[\frac{X - \mu_X}{\sigma_X}\right] \\ &= \frac{1}{\sigma_X} E[X - \mu_X] \quad (\text{par linéarité, } \sigma_X \text{ est une constante}) \\ &= \frac{1}{\sigma_X} (E[X] - E[\mu_X]) \\ &= \frac{1}{\sigma_X} (E[X] - \mu_X) \quad (\text{car } \mu_X \text{ est une constante}) \\ &= \frac{\mu_X - \mu_X}{\sigma_X} = 0\end{aligned}$$

2. Réduite (écart-type égal à 1) :

$$\begin{aligned}\text{Var}(Z) &= \text{Var}\left(\frac{X - \mu_X}{\sigma_X}\right) \\ &= \left(\frac{1}{\sigma_X}\right)^2 \text{Var}(X - \mu_X) \quad (\text{propriété } \text{Var}(aY) = a^2 \text{Var}(Y)) \\ &= \frac{1}{\sigma_X^2} \text{Var}(X) \quad (\text{propriété } \text{Var}(Y + b) = \text{Var}(Y)) \\ &= \frac{1}{\sigma_X^2} \cdot \sigma_X^2 = 1\end{aligned}$$

L'écart-type est donc $\sigma_Z = \sqrt{\text{Var}(Z)} = \sqrt{1} = 1$.

Cette transformation permet de comparer des variables sur des échelles différentes.

Intuition : Que signifie centrer-réduire ?

Standardiser une variable se fait en deux temps, comme le montre la formule $Z = \frac{X - \mu_X}{\sigma_X}$:

1. **Centrer** ($X - \mu_X$) : C'est la première étape. On soustrait la moyenne μ_X . Cela revient à "déplacer" la distribution pour que son centre de gravité (sa moyenne) soit maintenant à 0. On ne regarde plus les valeurs brutes X , mais leurs **écarts** par rapport à la moyenne. (Propriété 1 : $E[Z] = 0$)
2. **Réduire** (\dots/σ_X) : C'est la deuxième étape. On divise ces écarts par l'écart-type σ_X . Cela revient à changer d'unité de mesure. L'ancienne unité (kg, cm, points...) est remplacée par une nouvelle unité universelle : "le nombre d'écarts-types". (Propriété 2 : $\text{Var}(Z) = 1$)

Au final, une variable Z avec une valeur de 1.5 signifie "cette observation est 1.5 écarts-types au-dessus de la moyenne de sa distribution d'origine", peu importe ce que X mesurait.

Intuition : Analogie simple

Imaginons 2 élèves :

- Alice a des notes entre 80 et 100 (moyenne 90, écart-type 5).
- Bob a des notes entre 0 et 20 (moyenne 10, écart-type 4).

Comparer leurs notes brutes n'a pas de sens. Mais si on les standardise, on peut se demander : "quand Alice est 1 écart-type au-dessus de sa moyenne (une note de 95), Bob est-il aussi 1 écart-type au-dessus de sa propre moyenne (une note de 14) ?". La standardisation permet cette comparaison.

Exemple : Centrer-réduire un dé

Pour un lancer de dé X , on a $\mu_X = 3.5$ et $\sigma_X = \sqrt{35/12} \approx 1.708$. Si on obtient $X = 6$: $Z = (6 - 3.5)/1.708 \approx 1.46$. Si on obtient $X = 1$: $Z = (1 - 3.5)/1.708 \approx -1.46$. Obtenir 6 est à 1.46 écarts-types au-dessus de la moyenne.

Maintenant, formalisons le concept d'une covariance nulle.

Définition : Variables Non Corrélées

On dit que deux variables aléatoires X et Y sont **non corrélées** si leur covariance est nulle :

$$\text{Cov}(X, Y) = 0$$

Cela est équivalent à dire que $E[XY] = E[X]E[Y]$.

Il est crucial de ne pas confondre "non corrélées" et "indépendantes".

Intuition

"Non corrélées" signifie qu'il n'y a **pas de relation linéaire** entre les variables. C'est plus faible que l'indépendance. Si X et Y sont indépendantes, elles sont forcément non corrélées. Mais l'inverse n'est pas vrai : X et Y peuvent être non corrélées ($\text{Cov}=0$) mais quand même dépendantes (par exemple si $Y = X^2$ pour un X centré).

5.7 Variance d'une Somme de Variables Aléatoires

Nous pouvons maintenant combiner nos connaissances de la variance et de la covariance pour répondre à une question cruciale : quelle est la variance d'une somme de variables, $X + Y$?

Théorème : Formules pour la variance d'une somme de deux variables

Pour deux variables aléatoires X et Y :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

La preuve découle de la définition de la variance et de la linéarité de l'espérance.

Preuve

Soit $\mu_X = E[X]$ et $\mu_Y = E[Y]$.

$$\begin{aligned}\text{Var}(X + Y) &= E [((X + Y) - E[X + Y])^2] \\ &= E [((X + Y) - (\mu_X + \mu_Y))^2] \quad (\text{Par linéarité de } E) \\ &= E [((X - \mu_X) + (Y - \mu_Y))^2] \quad (\text{On regroupe les termes})\end{aligned}$$

Posons $A = (X - \mu_X)$ et $B = (Y - \mu_Y)$.

$$\begin{aligned}&= E[(A + B)^2] = E[A^2 + 2AB + B^2] \\ &= E[A^2] + 2E[AB] + E[B^2] \quad (\text{Par linéarité de } E)\end{aligned}$$

Or, par définition :

$$E[A^2] = E[(X - \mu_X)^2] = \text{Var}(X)$$

$$E[B^2] = E[(Y - \mu_Y)^2] = \text{Var}(Y)$$

$$E[AB] = E[(X - \mu_X)(Y - \mu_Y)] = \text{Cov}(X, Y)$$

$$\text{Donc, } \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

Cette formule est fondamentale en finance et en ingénierie.

Intuition

La "volatilité" (variance) d'une somme n'est pas juste la somme des volatilités. Il faut ajouter le terme d'interaction (covariance). Si $\text{Cov}(X, Y) > 0$ (elles bougent ensemble), la somme est **plus** volatile que la somme des parties. Si $\text{Cov}(X, Y) < 0$ (elles bougent en sens inverse), elles s'amortissent mutuellement. La somme est **moins** volatile. C'est le principe de la diversification en finance.

Cela mène à un corollaire très important lorsque la covariance est nulle.

Théorème : Cas Particulier : Variables Non Corrélées

Si X et Y sont non corrélées ($\text{Cov}=0$), la formule se simplifie :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

Preuve

Cela découle directement du théorème précédent. Si X et Y sont non corrélées, alors $\text{Cov}(X, Y) = 0$. Le terme $2\text{Cov}(X, Y)$ dans la formule générale $\text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$ devient nul, laissant :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

C'est le cas pour nos dés indépendants.

Exemple : Variance d'une somme de dés

Soit $S = X + Y$ la somme de deux dés indépendants. Puisqu'ils sont indépendants, ils sont non corrélés ($\text{Cov}(X, Y) = 0$). On sait $\text{Var}(X) = 35/12$ et $\text{Var}(Y) = 35/12$.

$$\text{Var}(S) = \text{Var}(X) + \text{Var}(Y) = \frac{35}{12} + \frac{35}{12} = \frac{70}{12} = \frac{35}{6} \approx 5.833$$

C'est bien plus simple que de calculer $E[S^2]$ et $E[S]$.

On peut généraliser cette formule à N variables.

Théorème : Variance d'une somme de N variables

La formule générale pour la somme de N variables aléatoires X_1, \dots, X_n est :

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var}(X_i) + \sum_{i \neq j} \text{Cov}(X_i, X_j)$$

Preuve

On utilise la propriété $\text{Var}(S) = \text{Cov}(S, S)$ et la bilinéarité de la covariance. Soit $S = \sum_{i=1}^n X_i$.

$$\begin{aligned} \text{Var}(S) &= \text{Cov}(S, S) = \text{Cov} \left(\sum_{i=1}^n X_i, \sum_{j=1}^n X_j \right) \\ &= \sum_{i=1}^n \sum_{j=1}^n \text{Cov}(X_i, X_j) \quad (\text{Par bilinéarité}) \end{aligned}$$

On peut séparer cette double somme en deux parties : le cas où $i = j$ et le cas où $i \neq j$.

$$\text{Var}(S) = \sum_{i=1}^n \text{Cov}(X_i, X_i) + \sum_{i \neq j} \text{Cov}(X_i, X_j)$$

Puisque $\text{Cov}(X_i, X_i) = E[(X_i - \mu_i)(X_i - \mu_i)] = E[(X_i - \mu_i)^2] = \text{Var}(X_i)$, on obtient :

$$\text{Var}(S) = \sum_{i=1}^n \text{Var}(X_i) + \sum_{i \neq j} \text{Cov}(X_i, X_j)$$

Cette formule est au cœur de la théorie moderne du portefeuille.

Intuition

La variance totale d'un système (comme un portefeuille d'actions) est la somme de toutes les variances individuelles ("risques propres") plus la somme de **toutes** les paires de covariances ("risques d'interaction"). Dans un grand portefeuille, le nombre de termes de covariance (environ n^2) est bien plus grand que le nombre de termes de variance (n), donc le risque total est dominé par la façon dont les actifs interagissent.

5.8 Théorème sur la somme de lois de Poisson

Terminons avec un théorème très utile qui combine les idées d'indépendance et de somme de variables aléatoires pour une distribution spécifique.

Théorème : La Somme de v.a. de Poisson Indépendantes est Poisson

Soit X_1, \dots, X_k une séquence de variables aléatoires de Poisson indépendantes, avec des paramètres respectifs $\lambda_1, \dots, \lambda_k$.

$$X_i \sim \text{Poisson}(\lambda_i) \quad \text{pour } i = 1, \dots, k$$

Alors leur somme $Y = X_1 + \dots + X_k$ suit également une loi de Poisson, dont le paramètre est la somme des paramètres :

$$Y \sim \text{Poisson}(\lambda_1 + \dots + \lambda_k)$$

La preuve pour $k = 2$ (qui se généralise par récurrence) utilise l'indépendance et la formule du binôme de Newton.

Preuve : Preuve pour la somme de deux v.a.

Soit $X \sim \text{Poisson}(\lambda_1)$ et $Y \sim \text{Poisson}(\lambda_2)$, indépendantes. Soit $S = X + Y$. Nous cherchons $P(S = k)$. Pour que $S = k$, il faut que $X = j$ et $Y = k - j$, pour toutes les valeurs possibles de j (de 0 à k).

$$P(S = k) = \sum_{j=0}^k P(X = j, Y = k - j)$$

Par indépendance, $P(X = j, Y = k - j) = P(X = j)P(Y = k - j)$.

$$\begin{aligned} P(S = k) &= \sum_{j=0}^k \left(\frac{e^{-\lambda_1} \lambda_1^j}{j!} \right) \left(\frac{e^{-\lambda_2} \lambda_2^{k-j}}{(k-j)!} \right) \\ &= e^{-(\lambda_1 + \lambda_2)} \sum_{j=0}^k \frac{\lambda_1^j \lambda_2^{k-j}}{j!(k-j)!} \end{aligned}$$

On multiplie et on divise par $k!$ pour faire apparaître le coefficient binomial :

$$\begin{aligned} P(S = k) &= \frac{e^{-(\lambda_1 + \lambda_2)}}{k!} \sum_{j=0}^k \frac{k!}{j!(k-j)!} \lambda_1^j \lambda_2^{k-j} \\ &= \frac{e^{-(\lambda_1 + \lambda_2)}}{k!} \sum_{j=0}^k \binom{k}{j} \lambda_1^j \lambda_2^{k-j} \end{aligned}$$

La somme est l'expansion du binôme de Newton pour $(\lambda_1 + \lambda_2)^k$.

$$P(S = k) = \frac{e^{-(\lambda_1 + \lambda_2)} (\lambda_1 + \lambda_2)^k}{k!}$$

C'est la PMF d'une loi Poisson($\lambda_1 + \lambda_2$).

Ce résultat est très intuitif :

Intuition

Si des événements rares se produisent indépendamment à des taux constants, le nombre total d'événements se produisant est aussi un événement rare se produisant au taux total. Si les emails arrivent à $\lambda_1 = 5$ /heure et les appels à $\lambda_2 = 10$ /heure, les "communications totales" arrivent simplement à $\lambda = 5 + 10 = 15$ /heure.

Exemple : Centre d'appels

Un centre d'appels reçoit des appels "Ventes" selon $X_1 \sim \text{Poisson}(10 \text{ appels/heure})$ et des appels "Support" selon $X_2 \sim \text{Poisson}(15 \text{ appels/heure})$. Les deux types d'appels sont indépendants. Le nombre total d'appels $Y = X_1 + X_2$ suit une loi $Y \sim \text{Poisson}(10 + 15 = 25 \text{ appels/heure})$. La probabilité de recevoir exactement 20 appels en une heure est :

$$P(Y = 20) = \frac{e^{-25} 25^{20}}{20!}$$

5.9 Exercices

Exercice 1 : Loi Jointe et Marginales

Soit le tableau suivant représentant la loi de probabilité jointe $P(X = x, Y = y)$ d'un couple de variables aléatoires (X, Y) .

X \ Y	0	1	2
	0.1	0.2	0.1
1	0.3	0.1	0.2

1. Vérifiez qu'il s'agit bien d'une loi de probabilité.

2. Calculez la loi marginale de X , $P(X = x)$.
3. Calculez la loi marginale de Y , $P(Y = y)$.

Exercice 2 : Calcul de Probabilité Jointe

En utilisant la loi jointe de l'exercice 1 :

1. Calculez $P(X = 0, Y \leq 1)$.
2. Calculez $P(X = Y)$.
3. Calculez $P(X > Y)$.

Exercice 3 : Indépendance (Loi Jointe)

En utilisant la loi jointe de l'exercice 1 :

1. Calculez $P(X = 0) \times P(Y = 0)$.
2. Comparez ce résultat à $P(X = 0, Y = 0)$.
3. Les variables X et Y sont-elles indépendantes ? Justifiez.

Exercice 4 : Espérances Marginales

En utilisant les lois marginales calculées à l'exercice 1 :

1. Calculez l'espérance $E[X]$.
2. Calculez l'espérance $E[Y]$.

Exercice 5 : Espérance d'une Fonction (LOTUS)

En utilisant la loi jointe de l'exercice 1, calculez $E[XY]$. (Indice : $E[XY] = \sum_x \sum_y (xy)P(X = x, Y = y)$).

Exercice 6 : Covariance (Calcul)

En utilisant les résultats des exercices 4 et 5, calculez la covariance $\text{Cov}(X, Y)$.

Exercice 7 : Variances Marginales

En utilisant les lois marginales de l'exercice 1 et les espérances de l'exercice 4 :

1. Calculez $E[X^2]$ et $\text{Var}(X)$.
2. Calculez $E[Y^2]$ et $\text{Var}(Y)$.

Exercice 8 : Corrélation (Calcul)

En utilisant les résultats des exercices 6 et 7, calculez le coefficient de corrélation $\text{Corr}(X, Y)$.

Exercice 9 : Variance d'une Somme (Non Indépendant)

Soient X et Y deux variables aléatoires telles que $\text{Var}(X) = 10$, $\text{Var}(Y) = 5$ et $\text{Cov}(X, Y) = 2$. Calculez $\text{Var}(X + Y)$.

Exercice 10 : Variance d'une Différence (Indépendant)

Soient X et Y deux variables aléatoires **indépendantes** telles que $\text{Var}(X) = 16$ et $\text{Var}(Y) = 9$.

1. Que vaut $\text{Cov}(X, Y)$?
2. Calculez $\text{Var}(X - Y)$. (Rappel : $\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y)$).

Exercice 11 : Bilinéarité de la Covariance

Soient X, Y, Z trois variables aléatoires. Exprimez $\text{Cov}(X + Y, Z)$ en fonction des covariances des variables individuelles.

Exercice 12 : Variance d'une Combinaison Linéaire

Soient X et Y deux variables aléatoires indépendantes avec $\text{Var}(X) = 4$ et $\text{Var}(Y) = 2$. Calculez $\text{Var}(3X - 5Y + 1)$.

Exercice 13 : Variance d'une Somme (Dés)

On lance deux dés équilibrés D_1 et D_2 . Soit $S = D_1 + D_2$. On rappelle que pour un dé, $\text{Var}(D_i) = 35/12$.

1. Les variables D_1 et D_2 sont-elles indépendantes ?
2. Calculez $\text{Var}(S)$.

Exercice 14 : Covariance et Variance

Soit X une variable aléatoire. En utilisant la bilinéarité de la covariance, montrez que $\text{Cov}(X, X) = \text{Var}(X)$.

Exercice 15 : Covariance avec une Constante

Soit X une variable aléatoire et c une constante. Montrez que $\text{Cov}(X, c) = 0$. (Indice : $E[c] = c$ et $E[Xc] = cE[X]$).

Exercice 16 : Standardisation (Centrer-Réduire)

Soit X une variable aléatoire avec $E[X] = 10$ et $\text{Var}(X) = 4$. Soit $Z = \frac{X - E[X]}{\sqrt{\text{Var}(X)}} = \frac{X - 10}{2}$ la variable standardisée.

1. Calculez $E[Z]$.
2. Calculez $\text{Var}(Z)$.

Exercice 17 : Corrélation et Standardisation

Soit $\text{Corr}(X, Y) = 0.5$. Soient Z_X et Z_Y les versions standardisées de X et Y . Que vaut $\text{Cov}(Z_X, Z_Y)$? (Indice : regardez l'intuition de la corrélation).

Exercice 18 : Somme de Lois de Poisson

Un magasin reçoit des clients au comptoir A selon $X \sim \text{Poisson}(\lambda_1 = 5 \text{ clients/heure})$ et au comptoir B selon $Y \sim \text{Poisson}(\lambda_2 = 3 \text{ clients/heure})$. On suppose que X et Y sont indépendantes. Soit $S = X + Y$ le nombre total de clients arrivant au magasin en une heure.

1. Quelle est la loi de S ? Donnez son nom et son paramètre.
2. Quelle est la probabilité qu'exactly 6 clients au total arrivent en une heure, $P(S = 6)$?

Exercice 19 : Corrélation Nulle mais Dépendance

Soit X une variable aléatoire $X \in \{-1, 0, 1\}$, avec $P(X = -1) = 1/3$, $P(X = 0) = 1/3$, $P(X = 1) = 1/3$. Soit $Y = X^2$.

1. Calculez $E[X]$.
2. Calculez $E[XY]$. (Indice : $E[XY] = E[X^3]$).
3. Calculez $\text{Cov}(X, Y)$.
4. Les variables X et Y sont-elles indépendantes ?

Exercice 20 : Bornes de la Corrélation

Soit X une variable aléatoire et $Y = -3X + 5$. Sans faire de calcul, que vaut $\text{Corr}(X, Y)$? Justifiez.

5.10 Corrections des Exercices

Correction Exercice 1 : Loi Jointe et Marginales

1. On somme toutes les probabilités du tableau : $0.1 + 0.2 + 0.1 + 0.3 + 0.1 + 0.2 = 1.0$. Puisque la somme est 1 et toutes les probabilités sont non négatives, c'est une loi valide.
2. Loi marginale de X (somme des lignes) : $P(X = 0) = P(X = 0, Y = 0) + P(X = 0, Y = 1) + P(X = 0, Y = 2) = 0.1 + 0.2 + 0.1 = 0.4$. $P(X = 1) = P(X = 1, Y = 0) + P(X = 1, Y = 1) + P(X = 1, Y = 2) = 0.3 + 0.1 + 0.2 = 0.6$.
3. Loi marginale de Y (somme des colonnes) : $P(Y = 0) = P(X = 0, Y = 0) + P(X = 1, Y = 0) = 0.1 + 0.3 = 0.4$. $P(Y = 1) = P(X = 0, Y = 1) + P(X = 1, Y = 1) = 0.2 + 0.1 = 0.3$. $P(Y = 2) = P(X = 0, Y = 2) + P(X = 1, Y = 2) = 0.1 + 0.2 = 0.3$.

Correction Exercice 2 : Calcul de Probabilité Jointe

1. $P(X = 0, Y \leq 1) = P(X = 0, Y = 0) + P(X = 0, Y = 1) = 0.1 + 0.2 = 0.3$. 2. $P(X = Y) = P(X = 0, Y = 0) + P(X = 1, Y = 1) = 0.1 + 0.1 = 0.2$. 3. $P(X > Y) = P(X = 1, Y = 0) = 0.3$. (C'est la seule case où $x > y$).

Correction Exercice 3 : Indépendance (Loi Jointe)

On utilise les lois marginales de l'exercice 1 : $P(X = 0) = 0.4$ et $P(Y = 0) = 0.4$. 1. $P(X = 0) \times P(Y = 0) = 0.4 \times 0.4 = 0.16$. 2. Dans le tableau joint, $P(X = 0, Y = 0) = 0.1$. 3. Puisque $P(X = 0, Y = 0) \neq P(X = 0) \times P(Y = 0)$ (car $0.1 \neq 0.16$), les variables X et Y **ne sont pas indépendantes**. (Un seul contre-exemple suffit).

Correction Exercice 4 : Espérances Marginales

1. $E[X] = \sum_x xP(X = x) = (0)(P(X = 0)) + (1)(P(X = 1))$ $E[X] = (0)(0.4) + (1)(0.6) = 0.6$.
2. $E[Y] = \sum_y yP(Y = y) = (0)(P(Y = 0)) + (1)(P(Y = 1)) + (2)(P(Y = 2))$ $E[Y] = (0)(0.4) + (1)(0.3) + (2)(0.3) = 0 + 0.3 + 0.6 = 0.9$.

Correction Exercice 5 : Espérance d'une Fonction (LOTUS)

On somme $(xy)P(X = x, Y = y)$ sur les 6 cases. Les termes où $x = 0$ ou $y = 0$ sont nuls.
 $E[XY] = (0 \cdot 0)(0.1) + (0 \cdot 1)(0.2) + (0 \cdot 2)(0.1) + (1 \cdot 0)(0.3) + (1 \cdot 1)(0.1) + (1 \cdot 2)(0.2)$ $E[XY] = 0 + 0 + 0 + 0 + (1)(0.1) + (2)(0.2) = 0.1 + 0.4 = 0.5$.

Correction Exercice 6 : Covariance (Calcul)

On utilise la formule $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$.

$$\text{Cov}(X, Y) = 0.5 - (0.6)(0.9) = 0.5 - 0.54 = -0.04$$

Correction Exercice 7 : Variances Marginales

1. Pour X : $E[X^2] = (0^2)(0.4) + (1^2)(0.6) = 0.6$. $\text{Var}(X) = E[X^2] - (E[X])^2 = 0.6 - (0.6)^2 = 0.6 - 0.36 = 0.24$. 2. Pour Y : $E[Y^2] = (0^2)(0.4) + (1^2)(0.3) + (2^2)(0.3) = 0 + 0.3 + (4)(0.3) = 0.3 + 1.2 = 1.5$. $\text{Var}(Y) = E[Y^2] - (E[Y])^2 = 1.5 - (0.9)^2 = 1.5 - 0.81 = 0.69$.

Correction Exercice 8 : Corrélation (Calcul)

On utilise la formule $\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$.

$$\text{Corr}(X, Y) = \frac{-0.04}{\sqrt{0.24 \times 0.69}} = \frac{-0.04}{\sqrt{0.1656}} \approx \frac{-0.04}{0.4069} \approx -0.098$$

La corrélation est très faible et négative.

Correction Exercice 9 : Variance d'une Somme (Non Indépendant)

On utilise la formule générale :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

$$\text{Var}(X + Y) = 10 + 5 + 2(2) = 15 + 4 = 19$$

Correction Exercice 10 : Variance d'une Différence (Indépendant)

1. Puisque X et Y sont indépendantes, leur covariance est nulle : $\text{Cov}(X, Y) = 0$. 2. On utilise la formule générale :

$$\text{Var}(X - Y) = \text{Var}(X + (-1)Y) = \text{Var}(X) + \text{Var}(-1 \cdot Y) + 2\text{Cov}(X, -Y)$$

$$= \text{Var}(X) + (-1)^2\text{Var}(Y) - 2\text{Cov}(X, Y)$$

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2(0)$$

$$\text{Var}(X - Y) = 16 + 9 = 25$$

Correction Exercice 11 : Bilinearité de la Covariance

La covariance est linéaire sur son premier argument :

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$$

Correction Exercice 12 : Variance d'une Combinaison Linéaire

On utilise $\text{Var}(aX + bY + c) = a^2\text{Var}(X) + b^2\text{Var}(Y) + 2ab\text{Cov}(X, Y)$. Ici $a = 3$, $b = -5$, $c = 1$. X et Y sont indépendantes, donc $\text{Cov}(X, Y) = 0$.

$$\begin{aligned}\text{Var}(3X - 5Y + 1) &= (3)^2\text{Var}(X) + (-5)^2\text{Var}(Y) + 0 \\ &= 9 \times (4) + 25 \times (2) = 36 + 50 = 86\end{aligned}$$

(Note : la constante additive $c = 1$ ne change pas la variance).

Correction Exercice 13 : Variance d'une Somme (Dés)

1. Oui, les lancers de deux dés standards sont des événements physiquement indépendants. 2. Puisqu'ils sont indépendants, $\text{Cov}(D_1, D_2) = 0$.

$$\begin{aligned}\text{Var}(S) &= \text{Var}(D_1 + D_2) = \text{Var}(D_1) + \text{Var}(D_2) \\ \text{Var}(S) &= \frac{35}{12} + \frac{35}{12} = \frac{70}{12} = \frac{35}{6}\end{aligned}$$

Correction Exercice 14 : Covariance et Variance

Par définition, $\text{Cov}(A, B) = E[(A - \mu_A)(B - \mu_B)]$. Posons $A = X$ et $B = X$. Alors $\mu_A = \mu_X$ et $\mu_B = \mu_X$.

$$\text{Cov}(X, X) = E[(X - \mu_X)(X - \mu_X)] = E[(X - \mu_X)^2]$$

C'est la définition de $\text{Var}(X)$.

Correction Exercice 15 : Covariance avec une Constante

On utilise la formule de calcul $\text{Cov}(X, c) = E[Xc] - E[X]E[c]$. Par linéarité, $E[Xc] = cE[X]$. L'espérance d'une constante est la constante elle-même : $E[c] = c$.

$$\text{Cov}(X, c) = cE[X] - E[X]c = 0$$

Correction Exercice 16 : Standardisation (Centrer-Réduire)

$Z = \frac{X-10}{2} = \frac{1}{2}X - 5$. 1. Calcul de $E[Z]$ par linéarité :

$$E[Z] = E\left[\frac{1}{2}X - 5\right] = \frac{1}{2}E[X] - 5 = \frac{1}{2}(10) - 5 = 5 - 5 = 0$$

2. Calcul de $\text{Var}(Z)$ par les propriétés de la variance :

$$\begin{aligned}\text{Var}(Z) &= \text{Var}\left(\frac{1}{2}X - 5\right) = \left(\frac{1}{2}\right)^2 \text{Var}(X) = \frac{1}{4}\text{Var}(X) \\ \text{Var}(Z) &= \frac{1}{4}(4) = 1\end{aligned}$$

Par définition, une variable standardisée a une moyenne de 0 et une variance de 1.

Correction Exercice 17 : Corrélation et Standardisation

La corrélation $\text{Corr}(X, Y)$ EST, par définition, la covariance des versions standardisées Z_X et Z_Y .

$$\text{Cov}(Z_X, Z_Y) = \text{Corr}(X, Y) = 0.5$$

Correction Exercice 18 : Somme de Lois de Poisson

1. Puisque X et Y sont des v.a. de Poisson **indépendantes**, leur somme $S = X + Y$ suit aussi une **loi de Poisson**. Le nouveau paramètre est la somme des paramètres : $\lambda_S = \lambda_1 + \lambda_2 =$

$5 + 3 = 8$. Donc, $S \sim \text{Poisson}(\lambda = 8)$. 2. On cherche $P(S = 6)$ pour $S \sim \text{Poisson}(8)$.

$$P(S = 6) = \frac{e^{-8} 8^6}{6!} = \frac{e^{-8} \times 262144}{720} = 364.08 \times e^{-8} \approx 0.122$$

Correction Exercice 19 : Corrélation Nulle mais Dépendance

1. $E[X] = (-1)(1/3) + (0)(1/3) + (1)(1/3) = -1/3 + 0 + 1/3 = 0$. 2. $E[XY] = E[X(X^2)] = E[X^3]$. $E[X^3] = (-1)^3(1/3) + (0)^3(1/3) + (1)^3(1/3) = (-1)(1/3) + 0 + (1)(1/3) = 0$. 3. $\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 0 - (0)E[Y] = 0$. Les variables sont **non corrélées**. 4. Les variables X et Y sont-elles indépendantes? Non. Test : $P(X = 1, Y = 1) \stackrel{?}{=} P(X = 1)P(Y = 1)$.
- $P(X = 1, Y = 1) = P(X = 1, X^2 = 1) = P(X = 1) = 1/3$. - $P(X = 1) = 1/3$. - $P(Y = 1) = P(X^2 = 1) = P(X = 1) + P(X = -1) = 1/3 + 1/3 = 2/3$. - $P(X = 1)P(Y = 1) = (1/3)(2/3) = 2/9$. Puisque $1/3 \neq 2/9$, elles **ne sont pas indépendantes**. C'est un exemple classique de dépendance non linéaire avec covariance nulle.

Correction Exercice 20 : Bornes de la Corrélation

Y est une fonction linéaire parfaite de X : $Y = aX + b$ avec $a = -3$ et $b = 5$. La corrélation $\text{Corr}(X, Y)$ mesure la force de la relation *linéaire*. Puisqu'elle est parfaite, la corrélation doit être ± 1 . Le coefficient $a = -3$ est négatif, donc la relation est décroissante. Par conséquent, $\text{Corr}(X, Y) = -1$.

5.11 Exercices Pratiques (Python)

Nous allons maintenant utiliser Python et les bibliothèques **pandas**, **numpy** et **seaborn** pour explorer les concepts de distributions multivariées sur un jeu de données réel : le dataset "penguins".

Ces exercices vont nous permettre de calculer empiriquement :

- Les distributions jointes (discrètes)
- Les distributions marginales
- La covariance
- La corrélation
- L'effet de la standardisation

```
# Cellule d'installation et d'importation
pip install numpy pandas seaborn
```

```
import numpy as np
import pandas as pd
import seaborn as sns

# Charger le jeu de données et supprimer les lignes avec des valeurs manquantes
# pour simplifier les calculs.
penguins = sns.load_dataset('penguins').dropna()

print("Aperçu des données (penguins) :")
print(penguins.head())
```

Exercice 1 : Lois Jointe et Marginale (Données Discrètes)

Nous allons analyser la relation entre deux variables catégorielles : **species** (l'espèce) et **island** (l'île où vit le manchot).

Votre tâche :

1. Utiliser `pandas.crosstab` pour créer un tableau de contingence (les effectifs) de **species** et **island**.
2. Normaliser ce tableau par l'effectif total pour obtenir la **loi jointe** (PMF jointe) $P(\text{Species} = s, \text{Island} = i)$.
3. Calculer la **loi marginale** de **species** en sommant les probabilités jointes sur les colonnes (`axis=1`).

4. Calculer la **loi marginale** de **island** en sommant sur les lignes (**axis=0**).
5. Vérifier que la somme des lois marginales est bien égale à 1.

```
import pandas as pd

# 1. Tableau de contingence (effectifs)
joint_counts = pd.crosstab(penguins['species'], penguins['island'])
print("--- 1. Tableau de contingence (Effectifs) ---")
print(joint_counts)

# 2. Loi jointe (PMF)
total_penguins = len(penguins)
joint_pmf = joint_counts / total_penguins
print("\n--- 2. Loi Jointe (PMF) ---")
print(joint_pmf)

# 3. Loi marginale de 'species' (somme des lignes)
marginal_species = joint_pmf.sum(axis=1)
print("\n--- 3. Loi Marginale (Species) ---")
print(marginal_species)

# 4. Loi marginale de 'island' (somme des colonnes)
marginal_island = joint_pmf.sum(axis=0)
print("\n--- 4. Loi Marginale (Island) ---")
print(marginal_island)

# 5. Verification
print(f"\n--- 5. Verification ---")
print(f"Somme de la PMF jointe : {joint_pmf.sum().sum():.2f}")
print(f"Somme marginale (Species) : {marginal_species.sum():.2f}")
print(f"Somme marginale (Island) : {marginal_island.sum():.2f}")
```

Exercice 2 : Calcul de Covariance

Nous allons maintenant calculer la covariance entre deux variables numériques : **bill_length_mm** (longueur du bec) et **flipper_length_mm** (longueur de la nageoire). Nous utiliserons la formule : $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$.

Votre tâche :

1. Isoler les deux variables X (**bill_length_mm**) et Y (**flipper_length_mm**) dans des variables **pandas.Series**.
2. Calculer $E[X]$ et $E[Y]$ (en utilisant **.mean()**).
3. Calculer $E[XY]$ (Indice : **(X * Y).mean()**).
4. Appliquer la formule pour trouver la covariance.
5. Vérifier votre résultat en utilisant la matrice de covariance de NumPy : **np.cov(X, Y)**.

```

import numpy as np

# 1. Isoler les variables
X = penguins['bill_length_mm']
Y = penguins['flipper_length_mm']

# 2. Calculer E[X] et E[Y]
E_X = X.mean()
E_Y = Y.mean()

# 3. Calculer E[XY]
E_XY = (X * Y).mean()

# 4. Appliquer la formule
cov_calc = E_XY - E_X * E_Y
print(f"E[X] = {E_X:.2f}, E[Y] = {E_Y:.2f}, E[XY] = {E_XY:.2f}")
print(f"Covariance (calculée) : {cov_calc:.4f}")

# 5. Verifier avec NumPy
# np.cov retourne une matrice 2x2. La covariance est a [0,1] (ou [1,0])
# ddof=1 (par défaut) calcule la covariance d'échantillon, ce qui est
# standard.
cov_matrix_np = np.cov(X, Y)
print(f"Covariance (numpy) : {cov_matrix_np[0, 1]:.4f}")

```

Exercice 3 : Calcul de Corrélation

La covariance de l'exercice 2 est positive, mais sa valeur (ex : ≈ 50.38) est difficile à interpréter. Nous allons la normaliser pour obtenir la corrélation.

Nous utiliserons la formule : $\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$.

Votre tâche :

1. Récupérer la covariance calculée à l'exercice 2.
2. Calculer les écarts-types (d'échantillon, `ddof=1`) σ_X et σ_Y (en utilisant `.std()`).
3. Appliquer la formule pour trouver la corrélation.
4. Vérifier votre résultat en utilisant `pandas.Series.corr()` (ex : `X.corr(Y)`) ou `np.corrcoef(X, Y)`.

```

import numpy as np

# X, Y proviennent de l'exercice précédent
X = penguins['bill_length_mm']
Y = penguins['flipper_length_mm']
cov_calc = np.cov(X, Y)[0, 1] # Utilisons la valeur numpy pour la precision

# 2. Calculer les ecarts-types (pandas .std() utilise ddof=1 par défaut)
std_X = X.std()
std_Y = Y.std()

# 3. Appliquer la formule
corr_calc = cov_calc / (std_X * std_Y)
print(f"Sigma_X = {std_X:.2f}, Sigma_Y = {std_Y:.2f}")
print(f"Correlation (calculée) : {corr_calc:.4f}")

# 4. Verifier avec Pandas
corr_pandas = X.corr(Y)
print(f"Correlation (pandas) : {corr_pandas:.4f}")

# 4. Verifier avec NumPy
corr_matrix_np = np.corrcoef(X, Y)
print(f"Correlation (numpy) : {corr_matrix_np[0, 1]:.4f}")

```

Exercice 4 : Standardisation (Centrer-Réduire)

Vérifions empiriquement que la standardisation $Z = \frac{X - \mu_X}{\sigma_X}$ produit une nouvelle variable avec une moyenne de 0 et un écart-type de 1.

Votre tâche :

1. Isoler la variable $X = \text{body_mass_g}$.
2. Calculer sa moyenne μ_X et son écart-type σ_X . (Note : pour cette transformation, on utilise l'écart-type de la population, `ddof=0`, car on transforme le set de données lui-même).
3. Créer la variable standardisée $Z = (X - \mu_X) / \sigma_X$.
4. Calculer la moyenne et l'écart-type de Z et vérifier qu'ils sont (respectivement) très proches de 0 et 1.

```
import numpy as np

# 1. Isoler la variable
X_mass = penguins['body_mass_g']

# 2. Calculer la moyenne et l'écart-type (de la population, ddof=0)
mu_X = X_mass.mean()
std_X = X_mass.std(ddof=0)

print(f"--- Original ---")
print(f"Moyenne (X) : {mu_X:.4f}")
print(f"Ecart-type (X) : {std_X:.4f}")

# 3. Standardiser la variable
Z_mass = (X_mass - mu_X) / std_X

# 4. Verifier la moyenne et l'écart-type de Z
mean_Z = Z_mass.mean()
std_Z = Z_mass.std(ddof=0) # On utilise ddof=0 ici aussi

print(f"\n--- Standardise ---")
# La moyenne sera un tres petit nombre (ex: 1.23e-16) a cause de la
# precision
print(f"Moyenne (Z) : {mean_Z:.2e}")
print(f"Ecart-type (Z) : {std_Z:.4f}")
```

6 Variables Aléatoires Continues

6.1 Fonction de Densité de Probabilité (PDF)

Nous passons maintenant aux variables aléatoires qui peuvent prendre n'importe quelle valeur dans un intervalle, comme la taille d'une personne ou le temps d'attente exact. Pour ces variables, la notion de PMF n'a plus de sens, car la probabilité d'obtenir une valeur *exacte* est nulle. Nous introduisons donc le concept de densité.

Définition : Fonction de Densité de Probabilité (PDF)

Soit X une variable aléatoire continue. Une fonction f est une **fonction de densité de probabilité** (Probability Density Function, ou PDF) de X si, pour tout x :

1. $f(x) \geq 0$, pour tout $-\infty < x < \infty$
2. $\int_{-\infty}^{\infty} f(x) dx = 1$ (l'aire totale sous la courbe vaut 1)

Il est crucial de comprendre que $f(x)$ n'est *pas* une probabilité.

Intuition

Dans le cas discret, la PMF donnait une "masse" de probabilité à chaque point. Dans le cas continu, la probabilité en un point exact est nulle ($P(X = x) = 0$). La PDF, $f(x)$, n'est **pas** une probabilité.

Il faut voir $f(x)$ comme une **densité** : elle décrit la "concentration" de probabilité autour de x . Pour obtenir une probabilité (une "masse"), il faut intégrer cette densité sur un intervalle. La probabilité que X tombe dans un intervalle $[a, b]$ est l'aire sous la courbe de la PDF entre a et b :

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

Cette distinction est fondamentale.

Remarque : PDF vs Probabilité

Une erreur fréquente est de confondre la valeur $f(x)$ avec $P(X = x)$. Pour une variable continue, $P(X = x)$ est **toujours zéro**. La PDF $f(x)$ peut être supérieure à 1 (contrairement à une probabilité), tant que l'aire totale sous la courbe reste égale à 1. Pensez-y comme à une densité de population : elle peut être très élevée en un point, mais la "population" (probabilité) exacte en ce point infinitésimal est nulle.

Vérifions un exemple simple.

Exemple : Une PDF simple

Soit X une v.a. avec la PDF $f(x) = 2x$ pour $x \in [0, 1]$, et $f(x) = 0$ sinon.

1. Est-ce une PDF valide ?
 - (1) $f(x) \geq 0$ pour tout x dans $[0, 1]$.
 - (2) $\int_{-\infty}^{\infty} f(x) dx = \int_0^1 2x dx = [x^2]_0^1 = 1 - 0 = 1$.
Oui, c'est une PDF valide.
2. Quelle est la probabilité $P(X \leq 0.5)$?

$$P(X \leq 0.5) = \int_0^{0.5} 2x dx = [x^2]_0^{0.5} = (0.5)^2 - 0 = 0.25$$

6.2 Fonction de Répartition (CDF)

Comme dans le cas discret, nous pouvons définir une fonction qui accumule la probabilité. Pour le cas continu, cette accumulation se fait via une intégrale.

Définition : Fonction de Répartition Continue (CDF)

Soit X une variable aléatoire continue. La **fonction de répartition** (Cumulative Distribution Function, ou CDF) de X est la fonction F définie par :

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

Pour être une CDF valide, la fonction F doit respecter les propriétés suivantes :

1. $\lim_{x \rightarrow \infty} F(x) = 1$
2. $\lim_{x \rightarrow -\infty} F(x) = 0$
3. F est continue et non décroissante.

La CDF est l'intégrale de la PDF, et inversement, la PDF est la dérivée de la CDF.

Intuition

La CDF est "l'accumulateur" de probabilité. Elle part de 0 (à $-\infty$) et "accumule" l'aire sous la PDF à mesure qu'on avance sur l'axe des x , pour finalement atteindre 1 (à $+\infty$).

Le lien fondamental est que la PDF est la dérivée de la CDF (par le théorème fondamental de l'analyse) :

$$f(x) = F'(x)$$

Cela signifie que la valeur de la PDF $f(x)$ représente le **taux d'accumulation** de la probabilité au point x .

La CDF est souvent le moyen le plus simple de calculer des probabilités sur des intervalles.

Remarque : Calcul de Probabilités via la CDF

La CDF est très pratique pour calculer des probabilités sur des intervalles :

$$P(a < X \leq b) = F(b) - F(a)$$

Pour les variables continues, les inégalités strictes ou larges ne changent rien ($P(X = a) = 0$).

Calculons la CDF de notre exemple précédent.

Exemple : CDF de l'exemple précédent

Pour $f(x) = 2x$ sur $[0, 1]$, la CDF $F(x)$ est :

- Si $x < 0$: $F(x) = \int_{-\infty}^x 0 dt = 0$.
- Si $0 \leq x \leq 1$: $F(x) = \int_{-\infty}^0 f(t)dt + \int_0^x 2t dt = 0 + [t^2]_0^x = x^2$.
- Si $x > 1$: $F(x) = \int_{-\infty}^1 f(t)dt + \int_1^x 0 dt = \int_0^1 2t dt = 1$.

$$\text{Donc, } F(x) = \begin{cases} 0 & \text{si } x < 0 \\ x^2 & \text{si } 0 \leq x \leq 1 \\ 1 & \text{si } x > 1 \end{cases}$$

6.3 Espérance et Variance (Cas Continu)

Les concepts d'espérance et de variance s'étendent naturellement au cas continu, en remplaçant les sommes par des intégrales.

Définition : Espérance et Variance (Cas Continu)

Pour une variable aléatoire X de fonction de densité f :

L'**espérance** de X est le centre de gravité de la densité :

$$E[X] = \int_{-\infty}^{\infty} xf(x) dx$$

La **variance** de X est l'espérance du carré de l'écart à la moyenne :

$$\text{Var}(X) = E[(X - E[X])^2] = \int_{-\infty}^{\infty} (x - E[X])^2 f(x) dx$$

Comme dans le cas discret, une formule alternative existe pour la variance.

Théorème : Formule de calcul de la Variance

Une formule plus simple pour le calcul de la variance est :

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

où $E[X^2] = \int_{-\infty}^{\infty} x^2 f(x) dx$. (Ceci est une application de LOTUS).

La preuve est identique à celle du cas discret, en utilisant la linéarité de l'espérance.

Preuve

Soit $\mu = E(X)$. On part de la définition de la variance :

$$\begin{aligned} \text{Var}(X) &= E[(X - \mu)^2] \\ &= E[X^2 - 2X\mu + \mu^2] \quad (\text{On développe le carré}) \\ &= E(X^2) - E(2\mu X) + E(\mu^2) \quad (\text{Par linéarité de l'espérance, qui s'applique aussi au cas continu}) \\ &= E(X^2) - 2\mu E(X) + \mu^2 \quad (\text{Car } 2\mu \text{ et } \mu^2 \text{ sont des constantes}) \\ &= E(X^2) - 2\mu(\mu) + \mu^2 \quad (\text{Car } E(X) = \mu) \\ &= E(X^2) - 2\mu^2 + \mu^2 \\ &= E(X^2) - \mu^2 = E(X^2) - [E(X)]^2 \end{aligned}$$

Le calcul de $E[X^2]$ (et plus généralement de $E[g(X)]$) repose sur le théorème de transfert, adapté au cas continu.

Théorème : Théorème de Transfert (LOTUS)

Si X est une v.a. continue de densité $f(x)$, et g une fonction, alors :

$$E[g(X)] = \int_{-\infty}^{\infty} g(x)f(x) dx$$

La preuve formelle est plus avancée, mais l'idée est analogue au cas discret : on pondère chaque valeur $g(x)$ par la densité de probabilité $f(x)$ au voisinage de x .

Preuve : Idée de la preuve

La preuve formelle repose sur la théorie de la mesure ou sur un argument de changement de variable pour l'intégrale, en passant par la fonction de répartition de $Y = g(X)$. Intuitivement, pour un petit intervalle dx autour de x , la "masse" de probabilité est $f(x)dx$. Cette masse correspond à une valeur $g(x)$ pour la nouvelle variable. L'espérance est la somme (intégrale) de ces valeurs pondérées par leur masse : $\int g(x)f(x)dx$.

La propriété la plus importante de l'espérance reste valide.

Remarque : Linéarité de l'Espérance

Comme dans le cas discret, l'espérance reste linéaire pour les variables continues : $E[aX + bY] = aE[X] + bE[Y]$.

Calculons l'espérance et la variance pour notre exemple.

Exemple : Espérance et Variance de l'exemple précédent

Pour $f(x) = 2x$ sur $[0, 1]$:

$$E[X] = \int_0^1 x \cdot (2x) dx = \int_0^1 2x^2 dx = \left[\frac{2x^3}{3} \right]_0^1 = \frac{2}{3}.$$

$$E[X^2] = \int_0^1 x^2 \cdot (2x) dx = \int_0^1 2x^3 dx = \left[\frac{2x^4}{4} \right]_0^1 = \frac{1}{2}.$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = \frac{1}{2} - \left(\frac{2}{3}\right)^2 = \frac{1}{2} - \frac{4}{9} = \frac{9-8}{18} = \frac{1}{18}.$$

6.4 Loi Uniforme

La loi continue la plus simple est celle où la densité est constante sur un intervalle.

Définition : Loi Uniforme

Une variable aléatoire X est **uniformément distribuée** sur un intervalle $[a, b]$ si sa densité est une constante sur cet intervalle. Pour que l'aire totale soit 1, cette constante doit être $\frac{1}{b-a}$.

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{pour } x \in [a, b] \\ 0 & \text{sinon} \end{cases}$$

On note cela $X \sim \text{Unif}(a, b)$.

C'est le modèle du "hasard pur" sur un segment.

Intuition

C'est la distribution du "hasard pur" dans un intervalle borné. La probabilité de tomber dans un sous-intervalle ne dépend que de la **longueur** de ce sous-intervalle, pas de sa position (tant qu'il est dans $[a, b]$).

Les propriétés de cette loi sont faciles à dériver par intégration directe.

Théorème : Propriétés de la Loi Uniforme

Si $X \sim \text{Unif}(a, b)$:

- **CDF** : $F(x) = \frac{x-a}{b-a}$ pour $x \in [a, b]$.
- **Espérance** : $E[X] = \frac{a+b}{2}$ (le point milieu de l'intervalle).
- **Variance** : $\text{Var}(X) = \frac{(b-a)^2}{12}$.

Preuve : Dérivation des propriétés

Soit $f(x) = \frac{1}{b-a}$ pour $x \in [a, b]$ et 0 sinon.

CDF : Pour $x \in [a, b]$,

$$F(x) = \int_{-\infty}^x f(t) dt = \int_a^x \frac{1}{b-a} dt = \frac{1}{b-a} [t]_a^x = \frac{x-a}{b-a}$$

(Pour $x < a$, $F(x) = 0$. Pour $x > b$, $F(x) = 1$.)

Espérance :

$$E[X] = \int_a^b x \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{1}{b-a} \frac{b^2 - a^2}{2} = \frac{(b-a)(b+a)}{2(b-a)} = \frac{a+b}{2}$$

Variance : D'abord, calculons $E[X^2]$.

$$E[X^2] = \int_a^b x^2 \frac{1}{b-a} dx = \frac{1}{b-a} \left[\frac{x^3}{3} \right]_a^b = \frac{1}{b-a} \frac{b^3 - a^3}{3}$$

En utilisant $b^3 - a^3 = (b-a)(b^2 + ab + a^2)$, on obtient $E[X^2] = \frac{b^2 + ab + a^2}{3}$. Maintenant, appliquons

la formule $\text{Var}(X) = E[X^2] - (E[X])^2$:

$$\begin{aligned}\text{Var}(X) &= \frac{b^2 + ab + a^2}{3} - \left(\frac{a+b}{2}\right)^2 \\ &= \frac{b^2 + ab + a^2}{3} - \frac{a^2 + 2ab + b^2}{4} \\ &= \frac{4(b^2 + ab + a^2) - 3(a^2 + 2ab + b^2)}{12} \\ &= \frac{4b^2 + 4ab + 4a^2 - 3a^2 - 6ab - 3b^2}{12} \\ &= \frac{b^2 - 2ab + a^2}{12} = \frac{(b-a)^2}{12}\end{aligned}$$

6.5 Loi Exponentielle

Passons à une loi fondamentale pour modéliser les temps d'attente.

Définition : Loi Exponentielle

Une variable aléatoire X suit une **loi exponentielle** de paramètre $\lambda > 0$ si sa fonction de densité a la forme :

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{pour } x \geq 0 \\ 0 & \text{sinon} \end{cases}$$

On note $X \sim \text{Exp}(\lambda)$.

Cette loi est intimement liée au processus de Poisson.

Intuition : Lien entre les lois de Poisson et Exponentielle

La loi exponentielle modélise le temps d'attente *avant* le prochain événement dans un processus de Poisson.

Posons la question : « Si je commence à observer maintenant, combien de temps T vais-je devoir attendre avant de voir le prochain événement ? »

1. Dans un processus de Poisson de taux λ , le nombre d'événements $N(t)$ dans un intervalle de temps t suit une loi de Poisson de paramètre λt :

$$P(N(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}$$

2. La probabilité de ne voir **aucun** événement ($k = 0$) pendant une durée t est :

$$P(N(t) = 0) = \frac{(\lambda t)^0 e^{-\lambda t}}{0!} = e^{-\lambda t}$$

3. Mais ne voir aucun événement pendant un temps t , c'est exactement dire que le temps d'attente T du premier événement est *plus grand* que t .

$$P(T > t) = P(N(t) = 0) = e^{-\lambda t}$$

4. À partir de là, on déduit la fonction de répartition (CDF) de T :

$$F_T(t) = P(T \leq t) = 1 - P(T > t) = 1 - e^{-\lambda t} \quad (\text{pour } t \geq 0)$$

5. En dérivant la CDF pour obtenir la densité (PDF) :

$$f_T(t) = F'_T(t) = \frac{d}{dt}(1 - e^{-\lambda t}) = -(-\lambda e^{-\lambda t}) = \lambda e^{-\lambda t}$$

C'est exactement la densité de la loi exponentielle de paramètre λ .

Cette loi possède des propriétés remarquables.

Théorème : Propriétés de la Loi Exponentielle

Si $X \sim \text{Exp}(\lambda)$:

- **CDF** : $F(x) = 1 - e^{-\lambda x}$ pour $x \geq 0$.
- **Espérance** : $E[X] = \frac{1}{\lambda}$.
- **Variance** : $\text{Var}(X) = \frac{1}{\lambda^2}$.
- **Propriété de non-mémoire** : Pour $s, t \geq 0$, $P(X > s + t \mid X > s) = P(X > t)$.

Les preuves de l'espérance et de la variance nécessitent une intégration par parties. La preuve de la non-mémoire est plus directe.

Preuve : Dérivation des propriétés

Soit $f(x) = \lambda e^{-\lambda x}$ pour $x \geq 0$.

CDF : A été dérivée dans l'intuition ci-dessus.

$$F(x) = \int_0^x \lambda e^{-\lambda t} dt = [-e^{-\lambda t}]_0^x = -e^{-\lambda x} - (-e^0) = 1 - e^{-\lambda x}$$

Espérance : On utilise l'intégration par parties ($\int u dv = uv - \int v du$) avec $u = x$ et $dv = \lambda e^{-\lambda x} dx$. Alors $du = dx$ et $v = -e^{-\lambda x}$.

$$\begin{aligned} E[X] &= \int_0^\infty x(\lambda e^{-\lambda x}) dx \\ &= [x(-e^{-\lambda x})]_0^\infty - \int_0^\infty (-e^{-\lambda x}) dx \\ &= (0 - 0) + \int_0^\infty e^{-\lambda x} dx \quad (\text{car } \lim_{x \rightarrow \infty} -xe^{-\lambda x} = 0) \\ &= \left[-\frac{1}{\lambda} e^{-\lambda x} \right]_0^\infty = (0) - \left(-\frac{1}{\lambda} e^0 \right) = \frac{1}{\lambda} \end{aligned}$$

Variance : D'abord $E[X^2]$. Intégration par parties avec $u = x^2$, $dv = \lambda e^{-\lambda x} dx$. $du = 2x dx$, $v = -e^{-\lambda x}$.

$$\begin{aligned} E[X^2] &= \int_0^\infty x^2(\lambda e^{-\lambda x}) dx \\ &= [x^2(-e^{-\lambda x})]_0^\infty - \int_0^\infty (-e^{-\lambda x})(2x dx) \\ &= 0 + \int_0^\infty 2xe^{-\lambda x} dx \\ &= \frac{2}{\lambda} \int_0^\infty x(\lambda e^{-\lambda x}) dx \quad (\text{On fait apparaître } E[X]) \\ &= \frac{2}{\lambda} E[X] = \frac{2}{\lambda} \left(\frac{1}{\lambda} \right) = \frac{2}{\lambda^2} \end{aligned}$$

Donc, $\text{Var}(X) = E[X^2] - (E[X])^2 = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda} \right)^2 = \frac{1}{\lambda^2}$.

Propriété de non-mémoire : Rappelons que $P(X > t) = e^{-\lambda t}$.

$$\begin{aligned} P(X > s + t \mid X > s) &= \frac{P(X > s + t \text{ et } X > s)}{P(X > s)} \\ &= \frac{P(X > s + t)}{P(X > s)} \quad (\text{car si } X > s + t, \text{ alors } X > s) \\ &= \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = \frac{e^{-\lambda s} e^{-\lambda t}}{e^{-\lambda s}} = e^{-\lambda t} \\ &= P(X > t) \end{aligned}$$

Le paramètre λ a une interprétation concrète.

Remarque : Interprétation du paramètre λ

Le paramètre λ représente le **taux** moyen d'occurrence des événements dans le processus de Poisson sous-jacent (par exemple, nombre moyen d'appels par minute). L'espérance $1/\lambda$ est alors le **temps moyen entre les événements**.

La propriété de non-mémoire est unique à la loi exponentielle (dans le cas continu).

Intuition : La Propriété de Non-Mémoire

C'est la propriété la plus contre-intuitive et la plus importante de la loi exponentielle. Elle signifie que le processus "oublie" le passé. Si vous attendez un bus qui arrive selon un processus de Poisson (et donc le temps d'attente suit une loi exponentielle), et que vous avez déjà attendu 5 minutes ($X > 5$), la probabilité que vous deviez attendre encore au moins 2 minutes ($X > 5 + 2$) est la même que si vous veniez juste d'arriver à l'arrêt et deviez attendre au moins 2 minutes ($X > 2$). L'information "j'ai déjà attendu 5 minutes" est inutile pour prédire l'attente future.

6.6 Distributions Conjointes (Cas Continu)

Comme pour le cas discret, nous pouvons définir des lois conjointes pour plusieurs variables aléatoires continues.

Définition : Fonction de Densité Conjointe

Pour des variables aléatoires continues X et Y , la **fonction de densité conjointe** $f(x, y)$ décrit la densité de probabilité sur le plan (x, y) . Elle doit respecter :

1. $f(x, y) \geq 0$, pour tous x, y .
2. $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$.

Ici, la probabilité est associée à un volume sous la surface de densité.

Intuition : Volume = Probabilité

La probabilité que le couple (X, Y) tombe dans une région A du plan xy est le **volume** sous la surface $z = f(x, y)$ au-dessus de cette région A .

$$P((X, Y) \in A) = \iint_A f(x, y) dA$$

On retrouve les lois marginales en intégrant (en "écrasant" le volume).

Définition : Densités Marginales

On peut retrouver les densités individuelles (marginales) en "écrasant" le volume 3D sur un seul axe. Pour obtenir la PDF de X seul, on intègre $f(x, y)$ sur toutes les valeurs possibles de y :

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$
$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

La CDF conjointe accumule ce volume.

Définition : CDF Conjointe

La **fonction de répartition conjointe** (CDF) est :

$$F(x, y) = P(X \leq x, Y \leq y) = \int_{-\infty}^y \int_{-\infty}^x f(s, t) ds dt$$

Elle représente le volume "au sud-ouest" du point (x, y) .

6.7 Espérance, Indépendance et Covariance (Cas Conjoint)

Les concepts clés s'étendent naturellement au cas conjoint continu.

Théorème : LOTUS pour les v.a. conjointes

Si X et Y ont une densité conjointe $f(x, y)$, et $g(x, y)$ est une fonction :

$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy$$

La preuve est analogue à celle de LOTUS 1D, mais en dimension supérieure.

Preuve : Idée de la preuve

Comme pour LOTUS 1D, la preuve rigoureuse utilise des arguments de théorie de la mesure. L'intuition est que pour un petit rectangle $dx dy$ autour de (x, y) , la "masse" de probabilité est $f(x, y) dx dy$. Cette masse correspond à la valeur $g(x, y)$. L'espérance est la somme (double intégrale) de ces valeurs $g(x, y)$ pondérées par leur masse $f(x, y) dx dy$.

La condition d'indépendance s'exprime via la factorisation de la densité.

Définition : Indépendance et Densité

Les variables aléatoires continues X et Y sont **indépendantes** si et seulement si leur densité conjointe est le produit de leurs densités marginales :

$$f(x, y) = f_X(x) f_Y(y), \quad \text{pour tous } x, y$$

Cela signifie que le profil selon x ne dépend pas de y .

Intuition

Intuitivement, l'indépendance signifie que le "profil" de la densité en x ne change pas quelle que soit la valeur de y (et vice-versa). La surface de densité $z = f(x, y)$ peut être "séparée" en une fonction de x multipliée par une fonction de y .

La covariance se définit et se calcule de manière similaire.

Définition : Covariance (cas continu)

La **covariance** de X et Y mesure leur variation linéaire commune :

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_X)(y - \mu_Y) f(x, y) dx dy \end{aligned}$$

La formule de calcul reste la même.

Théorème : Formule de calcul de la Covariance

Une formule plus simple pour le calcul de la covariance est :

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$$

où $E[XY]$ est calculé via LOTUS : $E[XY] = \iint xy f(x, y) dx dy$.

La preuve est identique à celle du cas discret.

Preuve

La preuve est identique à celle vue pour les variables discrètes, car elle ne repose que sur la

linéarité de l'espérance, qui est vraie aussi dans le cas continu. Soit $\mu_X = E[X]$ et $\mu_Y = E[Y]$.

$$\begin{aligned}\text{Cov}(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E[XY - X\mu_Y - Y\mu_X + \mu_X\mu_Y] \\ &= E[XY] - E[X\mu_Y] - E[Y\mu_X] + E[\mu_X\mu_Y] \\ &= E[XY] - \mu_Y E[X] - \mu_X E[Y] + \mu_X\mu_Y \\ &= E[XY] - \mu_Y\mu_X - \mu_X\mu_Y + \mu_X\mu_Y \\ &= E[XY] - E[X]E[Y]\end{aligned}$$

La relation entre indépendance et covariance reste la même.

Remarque : Indépendance et Covariance

Si X et Y sont indépendantes, alors $\text{Cov}(X, Y) = 0$. Cependant, la réciproque n'est **pas** toujours vraie pour les variables aléatoires en général (bien qu'elle le soit dans certains cas importants comme pour les variables gaussiennes). Une covariance nulle signifie seulement une absence de *relation linéaire*, mais il peut exister d'autres formes de dépendance.

6.8 Exercices

Exercice 1 : Validation d'une PDF

Soit X une variable aléatoire continue. On propose la fonction $f(x) = cx^2$ pour $x \in [0, 1]$ et $f(x) = 0$ sinon.

1. Trouvez la constante c pour que $f(x)$ soit une fonction de densité de probabilité (PDF) valide.
2. En utilisant la valeur de c trouvée, calculez $P(X \leq 0.5)$.

Exercice 2 : PDF à partir d'une CDF

La fonction de répartition (CDF) d'une variable aléatoire Y est donnée par :

$$F(y) = \begin{cases} 0 & \text{si } y < 0 \\ y^3 & \text{si } 0 \leq y \leq 1 \\ 1 & \text{si } y > 1 \end{cases}$$

1. Trouvez la fonction de densité de probabilité (PDF) $f(y)$ de Y .
2. Calculez $P(0.1 \leq Y \leq 0.5)$ en utilisant la CDF.

Exercice 3 : Calcul d'Espérance et Variance (PDF Simple)

Utilisez la PDF $f(x)$ trouvée dans l'exercice 1 ($f(x) = 3x^2$ pour $x \in [0, 1]$).

1. Calculez l'espérance $E[X]$.
2. Calculez $E[X^2]$ en utilisant le théorème de transfert (LOTUS).
3. Déduisez-en la variance $\text{Var}(X)$.

Exercice 4 : PDF Triangulaire

Soit X une v.a. avec la PDF $f(x) = 1 - |x|$ pour $x \in [-1, 1]$ et $f(x) = 0$ sinon.

1. Vérifiez que l'aire totale sous la courbe est 1. (Indice : c'est un triangle).
2. Calculez $E[X]$. (Indice : utilisez la symétrie).
3. Calculez $P(X > 0.5)$.

Exercice 5 : Loi Uniforme (Bus)

Un bus arrive à un arrêt toutes les 15 minutes. Vous arrivez à l'arrêt à un moment aléatoire. Soit X votre temps d'attente. On suppose $X \sim \text{Unif}(0, 15)$.

1. Quelle est la PDF $f(x)$ de X ?
2. Quelle est la probabilité que vous attendiez moins de 5 minutes ?

3. Quelle est l'espérance de votre temps d'attente $E[X]$?

Exercice 6 : Loi Uniforme (Variance)

Soit $X \sim \text{Unif}(a, b)$. On rappelle que $\text{Var}(X) = \frac{(b-a)^2}{12}$. Un signal est uniformément distribué entre 5 Volts et 10 Volts.

1. Quelle est l'espérance du signal ?
2. Quelle est la variance du signal ?

Exercice 7 : Loi Uniforme (CDF)

Soit $X \sim \text{Unif}(-1, 3)$.

1. Calculez la CDF $F(x) = P(X \leq x)$. (N'oubliez pas les 3 parties : $x < -1$, $-1 \leq x \leq 3$, $x > 3$).
2. Utilisez la CDF pour calculer $P(0 \leq X \leq 2)$.

Exercice 8 : Loi Exponentielle (Durée de vie)

La durée de vie (en heures) d'un composant électronique suit une loi exponentielle avec $\lambda = 0.01$. $X \sim \text{Exp}(0.01)$.

1. Quelle est l'espérance de la durée de vie $E[X]$?
2. Quelle est la probabilité que le composant dure plus de 100 heures ? (Rappel : $P(X > t) = e^{-\lambda t}$).

Exercice 9 : Loi Exponentielle (Propriété de non-mémoire)

On reprend le composant de l'exercice 8 ($X \sim \text{Exp}(0.01)$).

1. Calculez la probabilité que le composant dure plus de 50 heures, $P(X > 50)$.
2. Calculez la probabilité qu'il dure plus de 150 heures, sachant qu'il a déjà duré 100 heures : $P(X > 150 | X > 100)$.
3. Comparez vos résultats de (1) et (2) et commentez.

Exercice 10 : Loi Exponentielle (CDF)

Le temps d'attente T (en minutes) à un guichet suit $T \sim \text{Exp}(\lambda = 0.5)$.

1. Quelle est la CDF $F(t)$ de T ?
2. Quelle est la probabilité d'attendre entre 1 et 3 minutes, $P(1 \leq T \leq 3)$?

Exercice 11 : Trouver λ

La durée de vie moyenne d'une ampoule suit une loi exponentielle avec une espérance de 800 heures.

1. Trouvez le paramètre λ .
2. Quelle est la probabilité qu'une ampoule meure avant 500 heures ?

Exercice 12 : Validation d'une PDF Conjointe

On considère la fonction $f(x, y) = c(x + y)$ pour $0 \leq x \leq 1$ et $0 \leq y \leq 1$, et $f(x, y) = 0$ sinon.

1. Mettez en place la double intégrale pour $\int_0^1 \int_0^1 c(x + y) dx dy$.
2. Calculez l'intégrale et trouvez la valeur de c qui en fait une PDF valide.

Exercice 13 : Calcul de Densités Marginales

En utilisant la PDF $f(x, y)$ et la constante c de l'exercice 12 :

1. Calculez la densité marginale $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$. (Définie pour $x \in [0, 1]$).
2. Calculez la densité marginale $f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$. (Définie pour $y \in [0, 1]$).

Exercice 14 : Indépendance (Continu)

En utilisant les résultats des exercices 12 et 13 :

1. Calculez le produit $f_X(x)f_Y(y)$.
2. Comparez $f(x, y)$ et $f_X(x)f_Y(y)$. X et Y sont-elles indépendantes ?

Exercice 15 : Calcul de Probabilité Conjointe

On utilise toujours $f(x, y) = x + y$ pour $x, y \in [0, 1]$ (on a trouvé $c = 1$). Calculez $P(X \leq 0.5 \text{ et } Y \leq 0.5)$.

Exercice 16 : PDF Conjointe Uniforme

Soit (X, Y) un couple uniformément distribué sur le carré $[0, 2] \times [0, 2]$.

1. Quelle est la surface du carré ?
2. Quelle est la valeur de la PDF $f(x, y)$ à l'intérieur de ce carré ?
3. Calculez $P(0 \leq X \leq 1 \text{ et } 1 \leq Y \leq 2)$. (Indice : c'est le volume d'un pavé).

Exercice 17 : Indépendance (Uniforme)

Pour la PDF de l'exercice 16 ($f(x, y) = 1/4$ sur le carré $[0, 2] \times [0, 2]$) :

1. Calculez les marginales $f_X(x)$ et $f_Y(y)$.
2. X et Y sont-elles indépendantes ?

Exercice 18 : Espérances Marginales

En utilisant les lois marginales $f_X(x)$ et $f_Y(y)$ de l'exercice 13 :

1. Calculez $E[X]$.
2. Calculez $E[Y]$.

Exercice 19 : LOTUS Conjoint et Covariance

En utilisant la PDF $f(x, y) = x + y$ sur le carré $[0, 1] \times [0, 1]$:

1. Calculez $E[XY] = \int_0^1 \int_0^1 (xy)(x + y) dx dy$.
2. En utilisant $E[X]$ et $E[Y]$ de l'exercice 18, calculez $\text{Cov}(X, Y)$.

Exercice 20 : Covariance et Indépendance

Soient X et Y les variables de l'exercice 16 (uniformes sur $[0, 2] \times [0, 2]$).

1. X et Y sont-elles indépendantes (d'après Ex. 17) ?
2. Que vaut $\text{Cov}(X, Y)$? (Sans calcul).

6.9 Corrections des Exercices

Correction Exercice 1 : Validation d'une PDF

$f(x) = cx^2$ pour $x \in [0, 1]$. 1. On doit avoir $\int_{-\infty}^{\infty} f(x) dx = 1$.

$$\int_0^1 cx^2 dx = c \left[\frac{x^3}{3} \right]_0^1 = c \left(\frac{1^3}{3} - 0 \right) = \frac{c}{3}$$

Pour que l'intégrale vaille 1, il faut $c/3 = 1$, donc $c = 3$. 2. On utilise $f(x) = 3x^2$.

$$P(X \leq 0.5) = \int_0^{0.5} 3x^2 dx = [x^3]_0^{0.5} = (0.5)^3 - 0 = 0.125$$

Correction Exercice 2 : PDF à partir d'une CDF

1. La PDF $f(y)$ est la dérivée de la CDF $F(y)$. - Si $y < 0$, $f(y) = \frac{d}{dy}(0) = 0$. - Si $0 \leq y \leq 1$, $f(y) = \frac{d}{dy}(y^3) = 3y^2$. - Si $y > 1$, $f(y) = \frac{d}{dy}(1) = 0$. Donc, $f(y) = 3y^2$ pour $y \in [0, 1]$ et 0 sinon.

2. On utilise la propriété $P(a \leq Y \leq b) = F(b) - F(a)$.

$$\begin{aligned} P(0.1 \leq Y \leq 0.5) &= F(0.5) - F(0.1) = (0.5)^3 - (0.1)^3 \\ &= 0.125 - 0.001 = 0.124 \end{aligned}$$

Correction Exercice 3 : Calcul d'Espérance et Variance

On utilise $f(x) = 3x^2$ pour $x \in [0, 1]$. 1. $E[X] = \int_{-\infty}^{\infty} xf(x) dx = \int_0^1 x(3x^2) dx = \int_0^1 3x^3 dx$
 $E[X] = \left[\frac{3x^4}{4} \right]_0^1 = 3/4$. 2. $E[X^2] = \int_{-\infty}^{\infty} x^2 f(x) dx = \int_0^1 x^2(3x^2) dx = \int_0^1 3x^4 dx$ $E[X^2] = \left[\frac{3x^5}{5} \right]_0^1 = 3/5$. 3. $\text{Var}(X) = E[X^2] - (E[X])^2 = \frac{3}{5} - \left(\frac{3}{4}\right)^2 = \frac{3}{5} - \frac{9}{16}$ $\text{Var}(X) = \frac{3 \times 16 - 9 \times 5}{80} = \frac{48 - 45}{80} = 3/80$.

Correction Exercice 4 : PDF Triangulaire

$f(x) = 1 - |x|$ pour $x \in [-1, 1]$. 1. La PDF est un triangle de base 2 (de -1 à 1) et de hauteur $f(0) = 1$. Aire = $\frac{1}{2} \times \text{base} \times \text{hauteur} = \frac{1}{2} \times 2 \times 1 = 1$. C'est bien une PDF valide. 2. La fonction $f(x)$ est symétrique autour de $x = 0$. L'espérance est donc le centre de symétrie. $E[X] = 0$. (Calcul : $E[X] = \int_{-1}^1 x(1 - |x|) dx = 0$ car l'intégrande est une fonction impaire sur un intervalle symétrique). 3. $P(X > 0.5) = \int_{0.5}^1 f(x) dx$. Pour $x > 0$, $f(x) = 1 - x$. $P(X > 0.5) = \int_{0.5}^1 (1 - x) dx = \left[x - \frac{x^2}{2} \right]_{0.5}^1 = \left(1 - \frac{1}{2}\right) - \left(0.5 - \frac{(0.5)^2}{2}\right) = 0.5 - (0.5 - 0.125) = 0.125$ (ou 1/8).

Correction Exercice 5 : Loi Uniforme (Bus)

$X \sim \text{Unif}(a = 0, b = 15)$. 1. $f(x) = \frac{1}{b-a} = \frac{1}{15}$ pour $x \in [0, 15]$, et 0 sinon. 2. $P(X < 5) = \int_0^5 \frac{1}{15} dx = \frac{1}{15}[x]_0^5 = \frac{5-0}{15} = 1/3$. (C'est la longueur de l'intervalle $[0, 5]$ divisée par la longueur totale $[0, 15]$). 3. $E[X] = \frac{a+b}{2} = \frac{0+15}{2} = 7.5$ minutes.

Correction Exercice 6 : Loi Uniforme (Variance)

Signal $X \sim \text{Unif}(a = 5, b = 10)$. 1. $E[X] = \frac{a+b}{2} = \frac{5+10}{2} = 7.5$ Volts. 2. $\text{Var}(X) = \frac{(b-a)^2}{12} = \frac{(10-5)^2}{12} = \frac{5^2}{12} = 25/12$ Volts².

Correction Exercice 7 : Loi Uniforme (CDF)

$X \sim \text{Unif}(a = -1, b = 3)$. $f(x) = \frac{1}{3-(-1)} = 1/4$ sur $[-1, 3]$. 1. CDF $F(x) = \int_{-\infty}^x f(t) dt$. - Si $x < -1$: $F(x) = \int_{-\infty}^x 0 dt = 0$. - Si $-1 \leq x \leq 3$: $F(x) = \int_{-1}^x \frac{1}{4} dt = \frac{1}{4}[t]_{-1}^x = \frac{x-(-1)}{4} = \frac{x+1}{4}$. - Si $x > 3$: $F(x) = P(X \leq 3) = 1$. 2. $P(0 \leq X \leq 2) = F(2) - F(0) = \frac{2+1}{4} - \frac{0+1}{4} = \frac{3}{4} - \frac{1}{4} = \frac{2}{4} = 0.5$.

Correction Exercice 8 : Loi Exponentielle (Durée de vie)

$X \sim \text{Exp}(\lambda = 0.01)$. 1. $E[X] = \frac{1}{\lambda} = \frac{1}{0.01} = 100$ heures. 2. $P(X > t) = e^{-\lambda t}$. $P(X > 100) = e^{-0.01 \times 100} = e^{-1} \approx 0.3679$.

Correction Exercice 9 : Loi Exponentielle (Propriété de non-mémoire)

$X \sim \text{Exp}(\lambda = 0.01)$. 1. $P(X > 50) = e^{-0.01 \times 50} = e^{-0.5} \approx 0.6065$. 2. Par la propriété de non-mémoire, le fait d'avoir déjà duré 100 heures est "oublié". $P(X > 150 | X > 100) = P(X > 100 + 50 | X > 100) = P(X > 50)$. Résultat = $e^{-0.5} \approx 0.6065$. 3. Les probabilités sont identiques. Le fait que le composant ait survécu 100 heures ne donne aucune information sur sa probabilité de survivre 50 heures de plus.

Correction Exercice 10 : Loi Exponentielle (CDF)

$T \sim \text{Exp}(\lambda = 0.5)$. 1. $F(t) = P(T \leq t) = 1 - e^{-\lambda t} = 1 - e^{-0.5t}$ (pour $t \geq 0$). 2. $P(1 \leq T \leq 3) = F(3) - F(1) = (1 - e^{-0.5 \times 3}) - (1 - e^{-0.5 \times 1}) = 1 - e^{-1.5} - 1 + e^{-0.5} = e^{-0.5} - e^{-1.5} \approx 0.6065 - 0.2231 = 0.3834$.

Correction Exercice 11 : Trouver λ

1. On sait que $E[X] = 1/\lambda$. $800 = 1/\lambda \implies \lambda = 1/800 = \mathbf{0.00125}$. 2. On cherche $P(X < 500) = F(500)$. $P(X < 500) = 1 - e^{-\lambda \times 500} = 1 - e^{-0.00125 \times 500} = 1 - e^{-0.625} \approx 1 - 0.5353 = \mathbf{0.4647}$.

Correction Exercice 12 : Validation d'une PDF Conjointe

1. $\int_0^1 \int_0^1 c(x+y) dx dy = 1$. 2. Calcul de l'intégrale interne (par rapport à x) : $\int_0^1 c(x+y) dx = c \left[\frac{x^2}{2} + xy \right]_0^1 = c \left(\left(\frac{1}{2} + y \right) - (0) \right) = c \left(\frac{1}{2} + y \right)$. Calcul de l'intégrale externe (par rapport à y) : $\int_0^1 c \left(\frac{1}{2} + y \right) dy = c \left[\frac{y}{2} + \frac{y^2}{2} \right]_0^1 = c \left(\left(\frac{1}{2} + \frac{1}{2} \right) - (0) \right) = c(1)$. On doit avoir $c(1) = 1$, donc $\mathbf{c = 1}$.

Correction Exercice 13 : Calcul de Densités Marginales

On utilise $f(x, y) = x + y$ pour $x, y \in [0, 1]$. 1. Marginale $f_X(x)$: On intègre par rapport à y . $f_X(x) = \int_0^1 (x+y) dy = \left[xy + \frac{y^2}{2} \right]_0^1 = (x + \frac{1}{2}) - (0) = \mathbf{x + 0.5}$ (pour $x \in [0, 1]$). 2. Marginale $f_Y(y)$: On intègre par rapport à x . $f_Y(y) = \int_0^1 (x+y) dx = \left[\frac{x^2}{2} + xy \right]_0^1 = (\frac{1}{2} + y) - (0) = \mathbf{y + 0.5}$ (pour $y \in [0, 1]$).

Correction Exercice 14 : Indépendance (Continu)

1. $f_X(x)f_Y(y) = (x+0.5)(y+0.5) = xy + 0.5x + 0.5y + 0.25$. 2. La PDF conjointe est $f(x, y) = x + y$. Puisque $f(x, y) \neq f_X(x)f_Y(y)$, les variables X et Y **ne sont pas indépendantes**.

Correction Exercice 15 : Calcul de Probabilité Conjointe

$f(x, y) = x + y$. On cherche $P(X \leq 0.5, Y \leq 0.5)$.

$$\int_0^{0.5} \int_0^{0.5} (x+y) dx dy$$

Intégrale interne (sur x) : $\int_0^{0.5} (x+y) dx = \left[\frac{x^2}{2} + xy \right]_0^{0.5} = \frac{(0.5)^2}{2} + 0.5y = \frac{0.25}{2} + 0.5y = 0.125 + 0.5y$. Intégrale externe (sur y) : $\int_0^{0.5} (0.125 + 0.5y) dy = \left[0.125y + \frac{0.5y^2}{2} \right]_0^{0.5} = [0.125y + 0.25y^2]_0^{0.5} = (0.125)(0.5) + (0.25)(0.5)^2 = 0.0625 + (0.25)(0.25) = 0.0625 + 0.0625 = \mathbf{0.125}$ (ou $1/8$).

Correction Exercice 16 : PDF Conjointe Uniforme

(X, Y) uniforme sur le carré $[0, 2] \times [0, 2]$. 1. Surface = $2 \times 2 = \mathbf{4}$. 2. La densité est $f(x, y) = 1/\text{Surface} = \mathbf{1/4}$ pour $x, y \in [0, 2]$, et 0 sinon. 3. On cherche $P(0 \leq X \leq 1, 1 \leq Y \leq 2)$. C'est le volume sous $f(x, y) = 1/4$ au-dessus du rectangle $[0, 1] \times [1, 2]$. Volume = Hauteur \times Surface de la base = $(1 - 0) \times (2 - 1) = 1$. Volume = $(1/4) \times 1 = \mathbf{1/4}$.

Correction Exercice 17 : Indépendance (Uniforme)

$f(x, y) = 1/4$ sur $[0, 2] \times [0, 2]$. 1. Marginale $f_X(x)$ (pour $x \in [0, 2]$) : $f_X(x) = \int_0^2 (1/4) dy = (1/4)[y]_0^2 = (1/4)(2) = \mathbf{1/2}$. Marginale $f_Y(y)$ (pour $y \in [0, 2]$) : $f_Y(y) = \int_0^2 (1/4) dx = (1/4)[x]_0^2 = (1/4)(2) = \mathbf{1/2}$. (Ce sont des lois $\text{Unif}(0, 2)$). 2. On vérifie $f(x, y) \stackrel{?}{=} f_X(x)f_Y(y)$. $f_X(x)f_Y(y) = (1/2) \times (1/2) = 1/4$. C'est égal à $f(x, y) = 1/4$. Oui, X et Y **sont indépendantes**. (C'est toujours le cas pour une densité uniforme sur un rectangle aligné sur les axes).

Correction Exercice 18 : Espérances Marginales

On utilise $f_X(x) = x + 0.5$ et $f_Y(y) = y + 0.5$ (pour $x, y \in [0, 1]$). 1. $E[X] = \int_0^1 xf_X(x) dx = \int_0^1 x(x + 0.5) dx = \int_0^1 (x^2 + 0.5x) dx = \left[\frac{x^3}{3} + \frac{0.5x^2}{2} \right]_0^1 = \left[\frac{x^3}{3} + \frac{x^2}{4} \right]_0^1 = \frac{1}{3} + \frac{1}{4} = \mathbf{7/12}$. 2. Par symétrie, $f_Y(y)$ a la même forme que $f_X(x)$, donc $E[Y] = \mathbf{7/12}$.

Correction Exercice 19 : LOTUS Conjoint et Covariance

1. $E[XY] = \int_0^1 \int_0^1 (xy)(x+y) dx dy = \int_0^1 \int_0^1 (x^2y + xy^2) dx dy$ Intégrale interne (sur x) : $\int_0^1 (x^2y + xy^2) dx = \left[\frac{x^3y}{3} + \frac{x^2y^2}{2} \right]_0^1 = \frac{y}{3} + \frac{y^2}{2}$. Intégrale externe (sur y) : $\int_0^1 \left(\frac{y}{3} + \frac{y^2}{2} \right) dy = \left[\frac{y^2}{6} + \frac{y^3}{6} \right]_0^1 = \frac{1}{6} + \frac{1}{6} = \frac{2}{6} = \frac{1}{3}$. 2. $\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = \frac{1}{3} - \left(\frac{7}{12} \right) \left(\frac{7}{12} \right) = \frac{1}{3} - \frac{49}{144} = \frac{48}{144} - \frac{49}{144} = -1/144$.

Correction Exercice 20 : Covariance et Indépendance

1. D'après l'exercice 17, X et Y **sont indépendantes**. 2. Puisque X et Y sont indépendantes, leur covariance est nulle. $\text{Cov}(X, Y) = 0$.

6.10 Exercices Pratiques (Python)

Ces exercices vous aideront à visualiser les concepts de PDF, CDF, espérance et variance pour les lois Uniforme et Exponentielle en utilisant des simulations avec `numpy` et `matplotlib`.

```
pip install numpy matplotlib scipy
```

(`scipy` n'est pas strictement nécessaire ici, mais souvent utile pour les stats)

Exercice 1 : PDF vs Histogramme (Loi Uniforme)

Nous allons simuler une loi uniforme $X \sim \text{Unif}(a, b)$ et comparer l'histogramme des données simulées à la PDF théorique.

Votre tâche :

- Définissez $a = 2$, $b = 8$. Calculez la hauteur de la PDF théorique ($1/(b-a)$).
- Simulez 100 000 échantillons d'une loi uniforme $\text{Unif}(a, b)$ avec `numpy.random.uniform(a, b, N)`.
- Tracez l'histogramme de ces échantillons. Utilisez `bins=50` et `density=True`.
- Sur le même graphique, tracez une ligne horizontale représentant la PDF théorique (de a à b , à la hauteur calculée).

```
import numpy as np
import matplotlib.pyplot as plt

N_simulations = 100000
a, b = 2, 8

# 1. Calculer la hauteur de la PDF
# ... votre code ...

# 2. Simuler les échantillons
# ... votre code ...

# 3. Tracer l'histogramme normalisé
# ... votre code ...

# 4. Tracer la PDF théorique
# ... votre code ...
plt.legend()
plt.title("Loi Uniforme: Histogramme vs PDF")
plt.show()
```

Exercice 2 : CDF Empirique vs CDF Théorique (Loi Uniforme)

Comparons la fonction de répartition (CDF) empirique des données simulées à la CDF théorique $F(x) = (x-a)/(b-a)$.

Votre tâche :

- Reprenez les échantillons simulés de l'exercice 1 ($a = 2, b = 8$).
- Tracez la CDF empirique des échantillons. Utilisez `plt.hist(echantillons,`

bins=1000, density=True, cumulative=True, histtype='step').

3. Sur le même graphique, tracez la CDF théorique. (Indice : Créez un `np.linspace` de a à b , puis calculez $y = (x - a)/(b - a)$). N'oubliez pas que la CDF vaut 0 avant a et 1 après b .

```
import numpy as np
import matplotlib.pyplot as plt

# (Regenez les echantillons si necessaire)
# N_simulations = 100000
# a, b = 2, 8
# echantillons = ...

# 2. Tracer la CDF empirique
# ... votre code ...

# 3. Tracer la CDF theorique
# x_theorique = np.linspace(a - 1, b + 1, 400) # Un peu avant et apres
# y_cdf_theorique = ... # Calculer la CDF theorique
# (Attention aux 3 parties : < a, entre a et b, > b)
# ... votre code ...

# plt.title("Loi Uniforme: CDF Empirique vs Theorique")
# plt.xlabel("Valeur x")
# plt.ylabel("Probabilite Cumulative P(X <= x)")
# plt.legend()
# plt.grid(True)
# plt.show()
```

Exercice 3 : Espérance et Variance (Loi Uniforme)

Vérifions les formules $E[X] = (a + b)/2$ et $\text{Var}(X) = (b - a)^2/12$.

Votre tâche :

1. Reprenez les échantillons simulés de l'exercice 1 ($a = 2, b = 8$).
2. Calculez les valeurs théoriques pour $E[X]$ et $\text{Var}(X)$.
3. Calculez les valeurs empiriques en utilisant `.mean()` et `.var(ddof=0)` sur vos échantillons.
4. Comparez les résultats théoriques et empiriques.

```
import numpy as np

# (Regenez les echantillons si necessaire)
# N_simulations = 100000
# a, b = 2, 8
# echantillons = ...

# 2. Calculs theoriques
# ... votre code ...
# print(f"Theorique: E(X)=..., Var(X)=...")

# 3. Calculs empiriques
# ... votre code ...
# print(f"Empirique: E(X)=..., Var(X)=...")
```

Exercice 4 : PDF et CDF (Loi Exponentielle)

Nous allons simuler une loi exponentielle $X \sim \text{Exp}(\lambda)$ et comparer les histogrammes empiriques de la PDF et de la CDF à leurs formes théoriques.

Votre tâche :

1. Définissez $\lambda = 0.5$.
2. Simulez 100 000 échantillons d'une loi $\text{Exp}(\lambda)$ avec `numpy.random.exponential(scale=1/lmbda, size=N)`.

3. Tracez l'histogramme PDF (`density=True`).
4. Sur le même graphique, tracez la PDF théorique $f(x) = \lambda e^{-\lambda x}$.
5. Tracez l'histogramme CDF (`density=True, cumulative=True`).
6. Sur ce second graphique, tracez la CDF théorique $F(x) = 1 - e^{-\lambda x}$.

```
import numpy as np
import matplotlib.pyplot as plt

N_simulations = 100000
lambda = 0.5
scale = 1 / lambda

# 2. Simuler les echantillons
# ... votre code ...

# 3. & 4. PDF (Graphique 1)
# plt.figure(figsize=(10, 4))
# plt.subplot(1, 2, 1)
# ... votre code histogramme ...
x_theorique = np.linspace(0, np.max(echantillons), 200)
y_pdf_theorique = ... # Calculer la PDF theorique
# ... votre code plot ...
plt.title("PDF Exponentielle")

# 5. & 6. CDF (Graphique 2)
# plt.subplot(1, 2, 2)
# ... votre code histogramme cumulatif ...
y_cdf_theorique = ... # Calculer la CDF theorique
# ... votre code plot ...
plt.title("CDF Exponentielle")
plt.show()
```

Exercice 5 : Espérance et Variance (Loi Exponentielle)

Vérifions empiriquement les formules $E[X] = 1/\lambda$ et $\text{Var}(X) = 1/\lambda^2$ pour la loi exponentielle.

Votre tâche :

1. Reprenez les échantillons simulés de l'exercice 4 ($\lambda = 0.5$).
2. Calculez les valeurs théoriques pour $E[X]$ et $\text{Var}(X)$.
3. Calculez les valeurs empiriques en utilisant `.mean()` et `.var(ddof=0)`.
4. Comparez les résultats théoriques et empiriques.

```
import numpy as np

# (Regenez les echantillons si necessaire)
# N_simulations = 100000
# lambda = 0.5
# echantillons = ...

# 2. Calculs theoriques
# E_theorique = ...
# Var_theorique = ...
# print(f"Theorique: E(X)=..., Var(X)=...")

# 3. Calculs empiriques
# E_empirique = ...
# Var_empirique = ...
# print(f"Empirique: E(X)=..., Var(X)=...")
```

7 La Loi Normale (ou Gaussienne)

7.1 Introduction et Fonction de Densité (PDF)

Après les lois discrètes et les lois continues de base (Uniforme, Exponentielle), nous abordons la distribution la plus célèbre et la plus utilisée en probabilités et statistiques.

Définition : Loi Normale

Une variable aléatoire continue X suit une **loi normale** (ou loi de Gauss) de paramètres μ (l'espérance) et σ^2 (la variance), notée $X \sim \mathcal{N}(\mu, \sigma^2)$, si sa fonction de densité de probabilité (PDF) est donnée par :

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

pour tout $x \in (-\infty, \infty)$, où $\sigma > 0$.

Cette formule, bien qu'imposante, décrit une forme très familière : la courbe en cloche.

Intuition : La Courbe en Cloche


La loi normale est sans doute la distribution la plus importante en probabilités et statistiques. Pourquoi ? Parce qu'elle modélise remarquablement bien de nombreux phénomènes naturels et processus aléatoires où les valeurs tendent à se regrouper autour d'une moyenne, avec des écarts symétriques devenant de plus en plus rares à mesure qu'on s'éloigne de cette moyenne. Pensez à la taille des individus dans une population, aux erreurs de mesure répétées, ou même aux notes d'un grand groupe d'étudiants à un examen bien conçu.

Sa densité a une forme caractéristique de **cloche symétrique** :

- **Le Centre (μ)** : Le paramètre μ représente l'**espérance** (la moyenne) de la distribution. C'est le centre de symétrie de la courbe, là où la cloche atteint son **sommet**. C'est la valeur la plus probable (le mode) et aussi la valeur qui coupe la distribution en deux moitiés égales (la médiane). Changer μ *translate* la cloche horizontalement sans changer sa forme.
- **La Dispersion (σ)** : Le paramètre σ est l'**écart-type** (σ^2 est la variance). Il mesure la **dispersion** des valeurs autour de la moyenne μ . Géométriquement, σ contrôle la **largeur** de la cloche.
 - Un *petit* σ signifie que les données sont très concentrées autour de la moyenne, donnant une cloche **étroite et pointue**.
 - Un *grand* σ signifie que les données sont plus étalées, donnant une cloche **large et aplatie**.

Les points d'inflexion de la courbe (là où la courbure change de sens) se situent exactement à $\mu \pm \sigma$.

La Courbe en Cloche (PDF de la Loi Normale)




Influence de μ (position) et σ (largeur) sur la forme de la cloche.

Mais d'où vient cette formule spécifique ? Il existe une dérivation fascinante à partir d'hypothèses fondamentales sur les erreurs aléatoires (argument d'Herschel-Maxwell).

Preuve : Dérivation de la Densité Normale à partir des Principes Fondamentaux

Contexte Visuel : Imaginons un nuage de points dispersés autour d'une cible à l'origine $(0, 0)$, comme des impacts de fléchettes. Le graphique ci-dessous illustre cette dispersion. On s'intéresse à la probabilité de tomber dans une petite zone, comme dA , autour d'un point (x, y) .



Objectif : Expliquer comment arriver à la formule mathématique de la courbe en cloche (densité de probabilité normale) en partant de principes fondamentaux sur les erreurs aléatoires.

1. Le Point de Départ : Densité et Aire dA Dans une distribution continue, la probabilité de tomber *exactement* sur un point (x, y) est nulle. On ne peut donc pas parler de "probabilité d'un point". On parle de la probabilité de tomber *dans une petite zone*, comme un rectangle $dA = dx \cdot dy$ autour du point (x, y) . Cette probabilité, notée $P(\text{dans } dA)$, est *proportionnelle* à l'aire de la zone dA . La *constante de proportionnalité* est la **fonction de densité de probabilité** $p(x, y)$ évaluée en ce point. En d'autres termes, la densité $p(x, y)$ *représente* localement la concentration de probabilité. Ainsi, la probabilité de tomber dans la zone dA est approximativement :

$$P(\text{dans } dA) \approx p(x, y) \cdot dA$$

2. Les Hypothèses Fondamentales On pose deux hypothèses sur la nature de ces erreurs (représentées par la densité $p(x, y)$) :

1. **Indépendance des axes** : L'erreur horizontale (x) est indépendante de l'erreur verticale (y). Cela implique que la densité jointe $p(x, y)$ peut s'écrire comme le produit de la densité marginale sur x , notée $f(x)$, et de la densité marginale sur y , notée $f(y)$. Donc, $p(x, y) = f(x) \cdot f(y)$.
2. **Symétrie de rotation (Isotropie)** : La densité ne dépend que de la distance $r = \sqrt{x^2 + y^2}$ au centre, pas de l'angle. Il existe donc une fonction $\phi(r)$ telle que la densité en (x, y) est $p(x, y) = \phi(\sqrt{x^2 + y^2})$.

3. L'Équation Fonctionnelle En égalant les deux expressions pour la même densité $p(x, y)$ (à une constante près), on obtient :

$$f(x) \cdot f(y) = \phi(\sqrt{x^2 + y^2})$$

Pour $y = 0$, on a $f(x) \cdot f(0) = \phi(x)$. Posons $f(0) = \lambda$. Alors $\phi(x) = \lambda f(x)$. L'équation devient :

$$f(x) \cdot f(y) = \lambda f(\sqrt{x^2 + y^2})$$

4. Résolution de l'Équation Fonctionnelle Posons $g(x) = f(x)/\lambda$, avec $g(0) = 1$. L'équation se simplifie en :

$$g(x)g(y) = g(\sqrt{x^2 + y^2})$$

Posons $g(x) = h(x^2)$. L'équation devient $h(x^2)h(y^2) = h(x^2 + y^2)$. Avec $a = x^2$ et $b = y^2$, on a :

$$h(a)h(b) = h(a + b)$$

La solution continue de cette équation de Cauchy est $h(a) = e^{Aa}$ pour une constante A . Retour aux fonctions : $g(x) = h(x^2) = e^{Ax^2}$. $f(x) = \lambda g(x) = \lambda e^{Ax^2}$. Comme la densité doit diminuer loin du centre, A doit être négative. Posons $A = -k$ avec $k > 0$.

$$f(x) = \lambda e^{-kx^2}$$

5. Normalisation et Identification des Paramètres

1. **Condition** $\int_{-\infty}^{\infty} f(x)dx = 1$: L'intégrale Gaussienne $\int_{-\infty}^{\infty} e^{-kx^2} dx = \sqrt{\frac{\pi}{k}}$. Donc, $\int_{-\infty}^{\infty} f(x)dx = \lambda \sqrt{\frac{\pi}{k}} = 1 \implies \lambda = \sqrt{\frac{k}{\pi}}$.
2. **Lien avec la Variance** (σ^2) : Pour une distribution centrée, $\sigma^2 = E[X^2] = \int x^2 f(x)dx$.

$$\sigma^2 = \int_{-\infty}^{\infty} x^2 \left(\sqrt{\frac{k}{\pi}} e^{-kx^2} \right) dx = \sqrt{\frac{k}{\pi}} \left(\frac{1}{2k} \sqrt{\frac{\pi}{k}} \right) = \frac{1}{2k}$$

Donc, $k = \frac{1}{2\sigma^2}$.

3. **Substitution Finale** : Remplaçons k dans λ et $f(x)$.

$$\lambda = \sqrt{\frac{1/(2\sigma^2)}{\pi}} = \frac{1}{\sigma\sqrt{2\pi}}$$

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}x^2} = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}}$$

4. **Généralisation (Moyenne μ)** : Pour centrer la distribution sur μ , on remplace x par $(x - \mu)$ dans l'exposant :

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

C'est la fonction de densité de la loi normale $\mathcal{N}(\mu, \sigma^2)$.

7.2 La Loi Normale Centrée Réduite $\mathcal{N}(0, 1)$

Avant d'explorer les propriétés de la loi normale générale, concentrons-nous sur son cas le plus simple et le plus fondamental.

Définition : Loi Normale Standard (ou Centrée Réduite)

Un cas particulier extraordinairement utile est la loi normale avec une moyenne $\mu = 0$ et une variance $\sigma^2 = 1$ (donc $\sigma = 1$). On l'appelle la **loi normale standard** ou **centrée réduite**, et on la note souvent Z . Sa PDF est traditionnellement notée $\phi(z)$:

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$$

Sa fonction de répartition (CDF), qui donne $P(Z \leq z)$, est notée $\Phi(z)$:

$$\Phi(z) = P(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

Pourquoi cette version standard est-elle si importante ? Elle sert de référence universelle.

Intuition : La Référence Universelle et le Changement d'Unités

Pourquoi cette loi $\mathcal{N}(0, 1)$ est-elle si centrale ? Imaginez que vous ayez des mesures en degrés Celsius ($\mathcal{N}(\mu_C, \sigma_C^2)$) et d'autres en degrés Fahrenheit ($\mathcal{N}(\mu_F, \sigma_F^2)$). Comment les comparer ? La loi normale standard fournit un **système d'unités universel**.

Toute variable normale $X \sim \mathcal{N}(\mu, \sigma^2)$ peut être transformée ("standardisée") en une variable $Z \sim \mathcal{N}(0, 1)$ par un simple changement d'échelle et de position : $Z = (X - \mu)/\sigma$.

Cela signifie qu'au lieu de devoir calculer des aires (probabilités) pour une infinité de courbes en cloche différentes (une pour chaque paire (μ, σ)), on peut tout ramener à **une seule courbe de référence**, $\mathcal{N}(0, 1)$. Les aires sous cette courbe standard ($\Phi(z)$) ont été calculées une fois pour toutes et sont disponibles dans des tables ou des logiciels. On n'a plus qu'à convertir notre problème dans cette "langue" standard, trouver la probabilité, et interpréter le résultat.

La notation est très standardisée pour cette loi.

Remarque : Notation ϕ et Φ

Les symboles ϕ (phi minuscule) pour la PDF et Φ (phi majuscule) pour la CDF de la loi normale standard sont quasi universels. Il est important de ne pas les confondre. $\phi(z)$ est la *hauteur* de la courbe en z , tandis que $\Phi(z)$ est l'*aire* sous la courbe à gauche de z .

Un détail technique important concerne le calcul de $\Phi(z)$.

Remarque : Absence de Primitive Simple

L'intégrale $\int e^{-t^2/2} dt$, nécessaire pour calculer $\Phi(z)$, n'a **pas d'expression analytique** en termes de fonctions élémentaires (polynômes, exponentielles, log, sin, cos...). C'est une fonction spéciale, connue sous le nom de **fonction d'erreur** (liée à Φ par une transformation simple). C'est la raison pour laquelle on dépend de tables ou de calculs numériques pour obtenir les valeurs de $\Phi(z)$. Heureusement, ces outils sont omniprésents aujourd'hui.

7.3 Standardisation : Le Score Z

Formalisons cette transformation clé qui relie toute loi normale à la loi standard.

Théorème : Standardisation d'une Variable Normale

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors la variable Z définie par :

$$Z = \frac{X - \mu}{\sigma}$$

suit la loi normale standard, $Z \sim \mathcal{N}(0, 1)$.

La preuve formelle utilise un changement de variable dans la fonction de répartition.

Preuve

Soit $F_X(x)$ la CDF de X et $F_Z(z)$ la CDF de Z . Nous voulons montrer que $F_Z(z) = \Phi(z)$.

$$\begin{aligned} F_Z(z) &= P(Z \leq z) \\ &= P\left(\frac{X - \mu}{\sigma} \leq z\right) \\ &= P(X - \mu \leq z\sigma) \\ &= P(X \leq \mu + z\sigma) \\ &= F_X(\mu + z\sigma) \end{aligned}$$

Par définition de la CDF de X :

$$F_X(x) = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2} dt$$

Donc,

$$F_Z(z) = \int_{-\infty}^{\mu+z\sigma} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2} dt$$

Effectuons le changement de variable $u = (t - \mu)/\sigma$. Alors $t = \mu + u\sigma$ et $dt = \sigma du$. Les bornes d'intégration changent :

- Quand $t \rightarrow -\infty$, $u \rightarrow -\infty$.
- Quand $t = \mu + z\sigma$, $u = ((\mu + z\sigma) - \mu)/\sigma = z$.

L'intégrale devient :

$$\begin{aligned} F_Z(z) &= \int_{-\infty}^z \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}u^2} (\sigma du) \\ F_Z(z) &= \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du \end{aligned}$$

C'est exactement la définition de $\Phi(z)$, la CDF de la loi normale standard. Ainsi, $Z \sim \mathcal{N}(0, 1)$.

Cette transformation a une interprétation très concrète.

Intuition : Mesurer en "Unités d'Écart-Type"

Transformer X en Z s'appelle **standardiser** la variable. Le résultat, $z = \frac{x-\mu}{\sigma}$, est appelé le **Score Z** (ou cote Z). Ce score Z est une mesure *sans unité* qui indique **à combien d'écarts-types** une valeur observée x se situe par rapport à la moyenne μ de sa distribution.

- $z = 0$: x est exactement à la moyenne ($x = \mu$).
- $z = +1$: x est un écart-type *au-dessus* de la moyenne ($x = \mu + \sigma$).
- $z = -2$: x est deux écarts-types *en dessous* de la moyenne ($x = \mu - 2\sigma$).

Cette transformation est extrêmement utile pour :

1. **Comparer des valeurs** issues de distributions normales différentes. Un score Z de +1.5 a toujours la même signification relative, que l'on parle de QI, de taille, ou de température.
2. **Calculer des probabilités** en utilisant la table unique de la loi $\mathcal{N}(0, 1)$.

Un exemple classique est la comparaison de notes.

Exemple : Comparaison de Performances

Un étudiant A obtient 80 points à un examen où la moyenne est $\mu_A = 70$ et l'écart-type $\sigma_A = 5$. Un étudiant B obtient 85 points à un autre examen où $\mu_B = 75$ et $\sigma_B = 10$. Qui a le mieux réussi relativement à son groupe ?

Calculons les Z-scores :

$$\begin{aligned} Z_A &= \frac{80 - 70}{5} = \frac{10}{5} = +2.0 \\ Z_B &= \frac{85 - 75}{10} = \frac{10}{10} = +1.0 \end{aligned}$$

L'étudiant A a un score Z plus élevé (+2.0 contre +1.0), ce qui signifie qu'il se situe plus d'écart-types au-dessus de la moyenne de son groupe que l'étudiant B. L'étudiant A a donc relativement mieux réussi.

7.4 Propriétés Importantes de la Loi Normale

La loi normale possède des propriétés de stabilité remarquables sous certaines transformations.

Théorème : Stabilité par Transformation Linéaire

Si $X \sim \mathcal{N}(\mu, \sigma^2)$ et $Y = aX + b$ (avec $a \neq 0$), alors Y suit aussi une loi normale :

$$Y \sim \mathcal{N}(a\mu + b, (a\sigma)^2)$$

L'espérance est transformée linéairement ($E[aX + b] = aE[X] + b$), et la variance est multipliée par a^2 ($\text{Var}(aX + b) = a^2\text{Var}(X)$).

Preuve

Nous utilisons le fait que si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$. Exprimons X en fonction de Z : $X = \mu + \sigma Z$. Substituons cela dans l'expression de Y :

$$Y = a(\mu + \sigma Z) + b = (a\mu + b) + (a\sigma)Z$$

Posons $\mu_Y = a\mu + b$ et $\sigma_Y = |a|\sigma$. Alors $Y = \mu_Y + \sigma_Y Z$ (si $a > 0$) ou $Y = \mu_Y - \sigma_Y Z$ (si $a < 0$). Dans les deux cas, Y est une transformation linéaire d'une variable normale standard Z . La CDF de Y peut être exprimée en termes de la CDF Φ de Z . Si $a > 0$:

$$P(Y \leq y) = P(\mu_Y + a\sigma Z \leq y) = P(a\sigma Z \leq y - \mu_Y) = P\left(Z \leq \frac{y - \mu_Y}{a\sigma}\right) = \Phi\left(\frac{y - \mu_Y}{a\sigma}\right)$$

C'est la CDF d'une loi $\mathcal{N}(\mu_Y, (a\sigma)^2)$. Le cas $a < 0$ est similaire et mène au même résultat pour la distribution (la variance dépend de a^2). Ainsi, $Y \sim \mathcal{N}(a\mu + b, (a\sigma)^2)$.

Cette propriété est très utile pour les changements d'unités.

Exemple : Changement d'Unités

Si la température en Celsius T_C suit $\mathcal{N}(20, 5^2)$, quelle est la loi de la température en Fahrenheit $T_F = \frac{9}{5}T_C + 32$?

$a = 9/5$, $b = 32$.

Nouvelle moyenne : $E[T_F] = \frac{9}{5}(20) + 32 = 36 + 32 = 68$.

Nouvel écart-type : $\sigma_{T_F} = |a|\sigma_{T_C} = \frac{9}{5}(5) = 9$. Nouvelle variance : $\sigma_{T_F}^2 = 9^2 = 81$.

Donc, $T_F \sim \mathcal{N}(68, 9^2)$.

Une autre propriété cruciale concerne la somme de variables normales indépendantes.

Théorème : Stabilité par Addition (Indépendance)

Si $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$ et $Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$ sont des variables aléatoires **indépendantes**, alors leur somme $S = X + Y$ suit aussi une loi normale :

$$S \sim \mathcal{N}(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$$

Les moyennes s'ajoutent, et (grâce à l'indépendance) les variances s'ajoutent.

La preuve formelle de ce théorème est plus avancée et utilise généralement les fonctions caractéristiques ou les fonctions génératrices des moments.

Preuve : Idée de la preuve (via Fonctions Caractéristiques)

La fonction caractéristique $\varphi_X(t)$ d'une variable aléatoire X est définie comme $\varphi_X(t) = E[e^{itX}]$. Pour une loi normale $X \sim \mathcal{N}(\mu, \sigma^2)$, sa fonction caractéristique est $\varphi_X(t) = e^{i\mu t - \frac{1}{2}\sigma^2 t^2}$. Si X et Y sont indépendantes, la fonction caractéristique de leur somme $S = X + Y$ est le produit

de leurs fonctions caractéristiques : $\varphi_S(t) = \varphi_X(t)\varphi_Y(t)$.

$$\begin{aligned}\varphi_S(t) &= \left(e^{i\mu_X t - \frac{1}{2}\sigma_X^2 t^2}\right) \left(e^{i\mu_Y t - \frac{1}{2}\sigma_Y^2 t^2}\right) \\ &= e^{i(\mu_X + \mu_Y)t - \frac{1}{2}(\sigma_X^2 + \sigma_Y^2)t^2}\end{aligned}$$

On reconnaît ici la fonction caractéristique d'une loi normale avec pour moyenne $\mu_X + \mu_Y$ et pour variance $\sigma_X^2 + \sigma_Y^2$. Comme la fonction caractéristique détermine de manière unique la distribution, on conclut que $S \sim \mathcal{N}(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$.

Il est essentiel de se souvenir de la condition d'indépendance pour l'addition des variances.

Remarque : Attention à l'Indépendance

La propriété d'addition des variances ($\sigma_S^2 = \sigma_X^2 + \sigma_Y^2$) est cruciale et ne tient **que si X et Y sont indépendantes**. Si elles ne le sont pas, la variance de la somme inclut un terme de covariance : $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$. Cependant, la somme de variables normales (même dépendantes) reste normale (si elles sont conjointement normales).

Appliquons ce théorème à un exemple concret.

Exemple : Poids Total

Le poids d'une pomme suit $\mathcal{N}(150g, 10^2)$. Le poids d'une orange suit $\mathcal{N}(200g, 15^2)$. On suppose les poids indépendants. Quel est la loi du poids total d'une pomme et d'une orange ?

Soit P le poids de la pomme, O celui de l'orange. $T = P + O$.

$$E[T] = E[P] + E[O] = 150 + 200 = 350g.$$

$$\text{Var}(T) = \text{Var}(P) + \text{Var}(O) = 10^2 + 15^2 = 100 + 225 = 325.$$

Donc, $T \sim \mathcal{N}(350, 325)$. L'écart-type du poids total est $\sqrt{325} \approx 18.03g$.

7.5 La Règle Empirique (68-95-99.7)

Une conséquence directe des aires sous la courbe normale standard est une règle approximative très utile.

Théorème : Règle Empirique

Pour toute variable $X \sim \mathcal{N}(\mu, \sigma^2)$:

- $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 0.6827$ (Environ **68%** des valeurs dans $\mu \pm \sigma$).
- $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0.9545$ (Environ **95%** des valeurs dans $\mu \pm 2\sigma$).
- $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 0.9973$ (Environ **99.7%** des valeurs dans $\mu \pm 3\sigma$).

Preuve : Dérivation à partir de $\Phi(z)$

Ces valeurs sont obtenues en calculant les aires sous la PDF de la loi normale standard $\mathcal{N}(0, 1)$ entre les Z-scores correspondants.

- $P(-1 \leq Z \leq 1) = \Phi(1) - \Phi(-1) = \Phi(1) - (1 - \Phi(1)) = 2\Phi(1) - 1$. Avec $\Phi(1) \approx 0.8413$, on obtient $2(0.8413) - 1 \approx 0.6826$.
- $P(-2 \leq Z \leq 2) = \Phi(2) - \Phi(-2) = 2\Phi(2) - 1$. Avec $\Phi(2) \approx 0.9772$, on obtient $2(0.9772) - 1 \approx 0.9544$.
- $P(-3 \leq Z \leq 3) = \Phi(3) - \Phi(-3) = 2\Phi(3) - 1$. Avec $\Phi(3) \approx 0.99865$, on obtient $2(0.99865) - 1 \approx 0.9973$.

Ces valeurs sont souvent arrondies à 68

Cette règle fournit des repères très pratiques.

Intuition : Repères Essentiels sur la Cloche

Cette règle, dérivée directement des aires sous la courbe $\mathcal{N}(0, 1)$ entre $z = \pm 1$, $z = \pm 2$ et $z = \pm 3$, fournit des repères extrêmement utiles pour interpréter l'écart-type σ . Elle nous dit où se trouve la grande majorité des données.

Une observation qui tombe en dehors de l'intervalle $\mu \pm 3\sigma$ est très inhabituelle (elle n'a que

7.6 Calcul de Probabilités Normales

En pratique, pour calculer une probabilité $P(a \leq X \leq b)$ pour une loi $\mathcal{N}(\mu, \sigma^2)$, on utilise systématiquement la standardisation.

Exemple : Utilisation du Z-score

Supposons que le QI d'une population suit $\mathcal{N}(100, 15^2)$. Quelle est la probabilité $P(X > 130)$?

1. **Standardiser** : $z = \frac{130-100}{15} = 2$. On cherche $P(Z > 2)$.
2. **Utiliser la CDF Standard** : $P(Z > 2) = 1 - P(Z \leq 2) = 1 - \Phi(2)$.
3. **Chercher dans la table / Calculer** : $\Phi(2) \approx 0.9772$.
4. **Résultat** : $P(X > 130) = 1 - 0.9772 = 0.0228$. Environ 2.3

Pour les intervalles, on utilise la propriété $P(a \leq Z \leq b) = \Phi(b) - \Phi(a)$.

Exemple : Probabilité entre deux valeurs

Quelle est la probabilité $P(85 \leq X \leq 115)$? ($\mu = 100, \sigma = 15$)

1. **Standardiser** : $z_1 = \frac{85-100}{15} = -1$, $z_2 = \frac{115-100}{15} = 1$. On cherche $P(-1 \leq Z \leq 1)$.
2. **Utiliser la CDF Standard** : $P(-1 \leq Z \leq 1) = \Phi(1) - \Phi(-1)$.
3. **Utiliser la symétrie** : $\Phi(-z) = 1 - \Phi(z)$. Donc $\Phi(-1) = 1 - \Phi(1)$. $P(-1 \leq Z \leq 1) = \Phi(1) - (1 - \Phi(1)) = 2\Phi(1) - 1$.
4. **Chercher dans la table / Calculer** : $\Phi(1) \approx 0.8413$.
5. **Résultat** : $P(85 \leq X \leq 115) \approx 2(0.8413) - 1 = 1.6826 - 1 = 0.6826$. (On retrouve la règle des 68

On peut aussi inverser le processus : trouver la valeur x correspondant à une probabilité donnée.

Exemple : Trouver une valeur pour une probabilité donnée (Problème Inverse)

Quel est le QI minimum requis pour être dans le top 10% de la population ? ($\mu = 100, \sigma = 15$).

1. **Trouver le Z-score correspondant** : On cherche x tel que $P(X > x) = 0.10$. Cela équivaut à $P(Z > z) = 0.10$, où $z = (x - 100)/15$. Si $P(Z > z) = 0.10$, alors $P(Z \leq z) = \Phi(z) = 1 - 0.10 = 0.90$.
2. **Chercher dans la table inverse / Calculer** : On cherche la valeur z pour laquelle l'aire à gauche est 0.90 (le 90ème percentile). On trouve $z \approx 1.28$.
3. **Convertir en X** : On utilise la relation $z = (x - \mu)/\sigma$ pour trouver x : $1.28 = \frac{x-100}{15}$
 $x = 100 + 1.28 \times 15 = 100 + 19.2 = 119.2$. Il faut un QI d'environ 119.2 pour être dans le top 10%.

7.7 Exercices

Exercice 1 : Concepts de Base $\Phi(z)$

Soit $Z \sim \mathcal{N}(0, 1)$ la loi normale standard. Sa CDF est $\Phi(z)$. Exprimez les probabilités suivantes en termes de $\Phi(z)$:

1. $P(Z \leq 1.5)$
2. $P(Z > 1)$
3. $P(Z \leq -1.5)$ (Indice : utilisez la symétrie $\Phi(-z) = 1 - \Phi(z)$)
4. $P(-1.5 \leq Z \leq 1.5)$

Exercice 2 : Utilisation d'une Table $\Phi(z)$

En utilisant une table ou une calculatrice pour la loi $\mathcal{N}(0, 1)$, on sait que $\Phi(1) \approx 0.8413$, $\Phi(1.96) \approx 0.975$ et $\Phi(2) \approx 0.9772$. Calculez :

1. $P(Z > 1)$
2. $P(Z \leq -2)$
3. $P(-1.96 \leq Z \leq 1.96)$

Exercice 3 : Propriétés de la PDF $\phi(z)$

Soit $\phi(z)$ la PDF de la loi $\mathcal{N}(0, 1)$.

1. Quelle est la valeur de $\phi(0)$? (Le pic de la courbe).

2. Que vaut $\phi(z)$ par rapport à $\phi(-z)$?
3. Que vaut $\int_{-\infty}^{\infty} \phi(z) dz$?

Exercice 4 : Calcul de Z-scores

Une variable aléatoire X suit une loi normale $\mathcal{N}(\mu = 50, \sigma^2 = 100)$. Notez que $\sigma = 10$. Calculez le Z-score pour les valeurs suivantes de X :

1. $x = 60$
2. $x = 50$
3. $x = 35$

Exercice 5 : Calcul de Probabilité (Général)

La taille des hommes adultes dans un pays suit une loi normale $\mathcal{N}(175 \text{ cm}, 7^2 \text{ cm}^2)$. Soit X la taille d'un homme choisi au hasard. Calculez :

1. $P(X \leq 182 \text{ cm})$ (Indice : Standardisez $x = 182$ et utilisez $\Phi(1) \approx 0.8413$)
2. $P(X > 168 \text{ cm})$

Exercice 6 : Calcul de Probabilité (Intervalle)

Les scores à un test de QI suivent une loi normale $\mathcal{N}(100, 15^2)$. Quelle est la probabilité qu'une personne choisie au hasard ait un QI compris entre 85 et 115 ? (Indice : Standardisez les deux bornes).

Exercice 7 : Calcul de Probabilité (Queue Extrême)

En utilisant la même loi $\mathcal{N}(100, 15^2)$ pour le QI : Quelle est la probabilité qu'une personne ait un QI supérieur à 130 ? (Indice : Utilisez $\Phi(2) \approx 0.9772$).

Exercice 8 : Problème Inverse (Z-score)

Soit $Z \sim \mathcal{N}(0, 1)$. Trouvez la valeur z telle que : (Utilisez $\Phi(1.28) \approx 0.90$ et $\Phi(1.645) \approx 0.95$)

1. $P(Z \leq z) = 0.90$
2. $P(Z > z) = 0.05$ (Indice : si $P(Z > z) = 0.05$, que vaut $P(Z \leq z)$?)
3. $P(Z \leq z) = 0.10$ (Indice : utilisez la symétrie)

Exercice 9 : Problème Inverse (Général)

Les scores au test $\mathcal{N}(100, 15^2)$ sont utilisés pour sélectionner des candidats. Seul le top 5% des scores est accepté. Quel est le score minimum requis pour être accepté ? (Indice : Utilisez $z \approx 1.645$ pour le top 5%).

Exercice 10 : Problème Inverse (Intervalle Central)

Soit $Z \sim \mathcal{N}(0, 1)$. Trouvez la valeur z telle que $P(-z \leq Z \leq z) = 0.95$. (Indice : si 95% est au centre, combien reste-t-il dans chaque queue ? Utilisez $\Phi(1.96) \approx 0.975$).

Exercice 11 : Problème Inverse (Général)

La durée de vie d'une batterie suit $\mathcal{N}(500 \text{ heures}, 50^2 \text{ heures}^2)$. Le fabricant veut offrir une garantie. Il ne veut remplacer que 2.5% des batteries. Quelle durée de garantie (en heures) doit-il proposer ? (Indice : $P(Z \leq -1.96) \approx 0.025$).

Exercice 12 : Règle Empirique (Application)

Le poids de paquets de café suit $\mathcal{N}(250g, 5^2g^2)$. En utilisant la règle empirique (68-95-99.7), donnez un intervalle qui contient :

1. Environ 68% des poids.
2. Environ 95% des poids.
3. Environ 99.7% des poids.

Exercice 13 : Règle Empirique (Probabilité)

En utilisant la situation de l'exercice 12 ($\mathcal{N}(250, 5^2)$) et la règle empirique :

1. Estimez $P(245 \leq X \leq 255)$.
2. Estimez $P(X \leq 240)$. (Indice : L'intervalle $\mu \pm 2\sigma$ est $[240, 260]$ et contient 95%. Utilisez la symétrie).

Exercice 14 : Transformation Linéaire (Celsius -> Fahrenheit)

La température T_C à midi en été dans une ville suit $\mathcal{N}(25, 3^2)$ (en degrés Celsius). On convertit la température en Fahrenheit : $T_F = 1.8 \times T_C + 32$. Quelle est la loi de T_F ? (Donnez sa moyenne et sa variance).

Exercice 15 : Transformation Linéaire (Z-score)

Soit $X \sim \mathcal{N}(\mu, \sigma^2)$. Soit $Y = aX + b$. Trouvez a et b (en fonction de μ et σ) tels que $Y \sim \mathcal{N}(0, 1)$.

Exercice 16 : Somme de Normales Indépendantes

Soit $X \sim \mathcal{N}(10, 3^2)$ et $Y \sim \mathcal{N}(20, 4^2)$. X et Y sont indépendantes. Soit $S = X + Y$.

1. Quelle est la loi de S ? (Donnez sa moyenne et sa variance).
2. Quel est l'écart-type de S ?

Exercice 17 : Différence de Normales Indépendantes

En utilisant X et Y de l'exercice 16, soit $D = Y - X$.

1. Quelle est la loi de D ? (Donnez sa moyenne et sa variance).
2. Quel est l'écart-type de D ? (Comparez-le à celui de S).

Exercice 18 : Application (Somme)

Le poids d'une boîte vide B suit $\mathcal{N}(100g, 5^2)$. Le poids du contenu C suit $\mathcal{N}(800g, 10^2)$. B et C sont indépendants. Soit $T = B + C$ le poids total.

1. Quelle est la loi de T ?
2. Calculez $P(T > 925g)$. (Utilisez $\Phi(2) \approx 0.9772$).

Exercice 19 : Moyenne d'un Échantillon (Avancé)

Soient X_1, X_2, X_3, X_4 quatre observations indépendantes de la loi $\mathcal{N}(10, 4^2)$. Soit $\bar{X} = \frac{X_1 + X_2 + X_3 + X_4}{4}$ la moyenne de l'échantillon.

1. Soit $S = X_1 + X_2 + X_3 + X_4$. Quelle est la loi de S ?
2. En utilisant la transformation linéaire $\bar{X} = \frac{1}{4}S$, quelle est la loi de \bar{X} ?

Exercice 20 : Comparaison (Différence)

Alice et Bob passent un examen. Les notes d'Alice A suivent $\mathcal{N}(80, 5^2)$. Les notes de Bob B suivent $\mathcal{N}(78, 3^2)$. On suppose leurs notes indépendantes. Quelle est la probabilité que Bob ait une meilleure note qu'Alice ? (Indice : Calculez $P(B > A)$, ce qui est équivalent à $P(B - A > 0)$).

7.8 Corrections des Exercices

Correction Exercice 1 : Concepts de Base $\Phi(z)$

1. $P(Z \leq 1.5) = \Phi(1.5)$. 2. $P(Z > 1) = 1 - P(Z \leq 1) = 1 - \Phi(1)$. 3. $P(Z \leq -1.5) = 1 - P(Z \leq 1.5) = 1 - \Phi(1.5)$. 4. $P(-1.5 \leq Z \leq 1.5) = P(Z \leq 1.5) - P(Z \leq -1.5) = \Phi(1.5) - (1 - \Phi(1.5)) = 2\Phi(1.5) - 1$.

Correction Exercice 2 : Utilisation d'une Table $\Phi(z)$

Données : $\Phi(1) \approx 0.8413$, $\Phi(1.96) \approx 0.975$, $\Phi(2) \approx 0.9772$. 1. $P(Z > 1) = 1 - \Phi(1) \approx 1 - 0.8413 = 0.1587$. 2. $P(Z \leq -2) = 1 - \Phi(2) \approx 1 - 0.9772 = 0.0228$. 3. $P(-1.96 \leq Z \leq 1.96) = \Phi(1.96) - \Phi(-1.96) = \Phi(1.96) - (1 - \Phi(1.96)) = 2\Phi(1.96) - 1 \approx 2(0.975) - 1 = 1.95 - 1 = 0.95$.

(C'est l'intervalle de confiance à 95%).

Correction Exercice 3 : Propriétés de la PDF $\phi(z)$

$\phi(z) = \frac{1}{\sqrt{2\pi}}e^{-z^2/2}$. 1. $\phi(0) = \frac{1}{\sqrt{2\pi}}e^0 = \frac{1}{\sqrt{2\pi}} \approx 0.3989$. 2. Puisque $z^2 = (-z)^2$, on a $\phi(z) = \phi(-z)$. La fonction est paire (symétrique par rapport à l'axe y). 3. Par définition d'une PDF, l'aire totale sous la courbe doit être 1. $\int_{-\infty}^{\infty} \phi(z) dz = 1$.

Correction Exercice 4 : Calcul de Z-scores

$X \sim \mathcal{N}(\mu = 50, \sigma^2 = 100) \implies \sigma = 10$. $Z = \frac{X - \mu}{\sigma}$. 1. $x = 60 \implies z = (60 - 50)/10 = 10/10 = 1$. 2. $x = 50 \implies z = (50 - 50)/10 = 0/10 = 0$. 3. $x = 35 \implies z = (35 - 50)/10 = -15/10 = -1.5$.

Correction Exercice 5 : Calcul de Probabilité (Général)

$X \sim \mathcal{N}(175, 7^2)$. $\mu = 175, \sigma = 7$. 1. $P(X \leq 182) = P(Z \leq \frac{182-175}{7}) = P(Z \leq \frac{7}{7}) = P(Z \leq 1) = \Phi(1) \approx 0.8413$. 2. $P(X > 168) = P(Z > \frac{168-175}{7}) = P(Z > -\frac{7}{7}) = P(Z > -1)$. Par symétrie, $P(Z > -1) = P(Z < 1) = \Phi(1) \approx 0.8413$.

Correction Exercice 6 : Calcul de Probabilité (Intervalle)

$X \sim \mathcal{N}(100, 15^2)$. $\mu = 100, \sigma = 15$. On cherche $P(85 \leq X \leq 115)$. $z_1 = (85 - 100)/15 = -15/15 = -1$. $z_2 = (115 - 100)/15 = 15/15 = 1$. $P(-1 \leq Z \leq 1) = \Phi(1) - \Phi(-1) = \Phi(1) - (1 - \Phi(1)) = 2\Phi(1) - 1$. En utilisant $\Phi(1) \approx 0.8413$, $P \approx 2(0.8413) - 1 = 1.6826 - 1 = 0.6826$. (On retrouve la règle des 68%).

Correction Exercice 7 : Calcul de Probabilité (Queue Extrême)

$X \sim \mathcal{N}(100, 15^2)$. On cherche $P(X > 130)$. $z = (130 - 100)/15 = 30/15 = 2$. $P(X > 130) = P(Z > 2) = 1 - P(Z \leq 2) = 1 - \Phi(2)$. En utilisant $\Phi(2) \approx 0.9772$, $P \approx 1 - 0.9772 = 0.0228$.

Correction Exercice 8 : Problème Inverse (Z-score)

1. $P(Z \leq z) = 0.90 \implies z = \Phi^{-1}(0.90) \approx 1.28$. 2. $P(Z > z) = 0.05 \implies P(Z \leq z) = 1 - 0.05 = 0.95$. $z = \Phi^{-1}(0.95) \approx 1.645$. 3. $P(Z \leq z) = 0.10$. C'est dans la queue gauche. Par symétrie, $z = -\Phi^{-1}(1 - 0.10) = -\Phi^{-1}(0.90)$. $z \approx -1.28$.

Correction Exercice 9 : Problème Inverse (Général)

$X \sim \mathcal{N}(100, 15^2)$. On cherche x tel que $P(X > x) = 0.05$. 1. Trouver le Z-score : $P(Z > z) = 0.05 \implies P(Z \leq z) = 0.95 \implies z \approx 1.645$. 2. Convertir en x : $z = (x - \mu)/\sigma \implies x = \mu + z\sigma$. $x = 100 + (1.645)(15) = 100 + 24.675 = 124.675$. Le score minimum est d'environ 125.

Correction Exercice 10 : Problème Inverse (Intervalle Central)

$P(-z \leq Z \leq z) = 0.95$. Si 95% est au centre, il reste $1 - 0.95 = 0.05$ (ou 5%) dans les deux queues. Par symétrie, chaque queue a $0.05/2 = 0.025$. La probabilité à gauche de z est $P(Z \leq z) = 0.95 + 0.025 = 0.975$. On cherche $z = \Phi^{-1}(0.975)$. En utilisant l'indice, $z \approx 1.96$.

Correction Exercice 11 : Problème Inverse (Général)

$X \sim \mathcal{N}(500, 50^2)$. On cherche x tel que $P(X \leq x) = 0.025$. 1. Trouver le Z-score : $P(Z \leq z) = 0.025$. C'est la queue gauche. En utilisant l'indice $P(Z \leq -1.96) \approx 0.025$, on a $z \approx -1.96$. 2. Convertir en x : $x = \mu + z\sigma$. $x = 500 + (-1.96)(50) = 500 - 98 = 402$. Le fabricant doit proposer une garantie de 402 heures.

Correction Exercice 12 : Règle Empirique (Application)

$X \sim \mathcal{N}(\mu = 250, \sigma = 5)$. 1. 68% $\implies \mu \pm 1\sigma = 250 \pm 5 \implies [245, 255]$. 2. 95% $\implies \mu \pm 2\sigma = 250 \pm 2(5) = 250 \pm 10 \implies [240, 260]$. 3. 99.7% $\implies \mu \pm 3\sigma = 250 \pm 3(5) = 250 \pm 15 \implies [235, 265]$.

Correction Exercice 13 : Règle Empirique (Probabilité)

1. $P(245 \leq X \leq 255)$ est l'intervalle $\mu \pm 1\sigma$. La probabilité est d'environ 68% ou 0.68. 2. L'intervalle $\mu \pm 2\sigma$ est $[240, 260]$ et contient 95% des données. Il reste $100\% - 95\% = 5\%$ dans les deux queues (i.e., $P(X < 240) + P(X > 260) = 0.05$). Par symétrie, la queue gauche $P(X < 240)$ est $0.05/2 = 0.025$. La probabilité est d'environ 2.5% ou 0.025.

Correction Exercice 14 : Transformation Linéaire

$T_C \sim \mathcal{N}(25, 3^2)$. $T_F = aT_C + b$ avec $a = 1.8$ et $b = 32$. Loi de T_F : $T_F \sim \mathcal{N}(a\mu + b, (a\sigma)^2)$. Moyenne : $E[T_F] = 1.8(25) + 32 = 45 + 32 = 77$. Variance : $\text{Var}(T_F) = (1.8)^2 \text{Var}(T_C) = (1.8)^2(3^2) = (1.8 \times 3)^2 = (5.4)^2 = 29.16$. Donc, $T_F \sim \mathcal{N}(77, 29.16)$.

Correction Exercice 15 : Transformation Linéaire (Z-score)

On veut $Y = aX + b \sim \mathcal{N}(0, 1)$. $E[Y] = aE[X] + b = a\mu + b$. On veut $a\mu + b = 0$. $\text{Var}(Y) = a^2 \text{Var}(X) = a^2 \sigma^2$. On veut $a^2 \sigma^2 = 1$. De $\text{Var}(Y) = 1 \implies a^2 = 1/\sigma^2 \implies a = 1/\sigma$ (en supposant $a > 0$). De $E[Y] = 0 \implies (1/\sigma)\mu + b = 0 \implies b = -\mu/\sigma$. Les constantes sont $a = 1/\sigma$ et $b = -\mu/\sigma$. (C'est la définition de la standardisation).

Correction Exercice 16 : Somme de Normales Indépendantes

$X \sim \mathcal{N}(10, 9)$ et $Y \sim \mathcal{N}(20, 16)$. $S = X + Y$. 1. La somme de normales indépendantes est une normale. $E[S] = E[X] + E[Y] = 10 + 20 = 30$. $\text{Var}(S) = \text{Var}(X) + \text{Var}(Y) = 9 + 16 = 25$. Donc, $S \sim \mathcal{N}(30, 25)$. 2. $\text{Var}(S) = 25 \implies \sigma_S = \sqrt{25} = 5$.

Correction Exercice 17 : Différence de Normales Indépendantes

$D = Y - X$. 1. La différence est aussi une normale. $E[D] = E[Y] - E[X] = 20 - 10 = 10$. $\text{Var}(D) = \text{Var}(Y + (-1)X) = \text{Var}(Y) + (-1)^2 \text{Var}(X) = \text{Var}(Y) + \text{Var}(X)$. $\text{Var}(D) = 16 + 9 = 25$. Donc, $D \sim \mathcal{N}(10, 25)$. 2. $\sigma_D = \sqrt{25} = 5$. (Identique à σ_S . La variance s'additionne toujours).

Correction Exercice 18 : Application (Somme)

$B \sim \mathcal{N}(100, 25)$, $C \sim \mathcal{N}(800, 100)$. $T = B + C$. 1. $E[T] = E[B] + E[C] = 100 + 800 = 900$. $\text{Var}(T) = \text{Var}(B) + \text{Var}(C) = 25 + 100 = 125$. $T \sim \mathcal{N}(900, 125)$. 2. $P(T > 925)$. $\sigma_T = \sqrt{125} = \sqrt{25 \times 5} = 5\sqrt{5} \approx 11.18$. $z = (925 - 900)/\sqrt{125} = 25/(5\sqrt{5}) = 5/\sqrt{5} = \sqrt{5} \approx 2.236$. $P(T > 925) = P(Z > 2.236) = 1 - \Phi(2.236) \approx 1 - 0.9873 = 0.0127$. (Note : L'indice $\Phi(2) \approx 0.9772$ semble être une approximation pour un z de 2, qui n'est pas le bon z ici).

Correction Exercice 19 : Moyenne d'un Échantillon (Avancé)

$X_i \sim \mathcal{N}(10, 16)$ (indép.). $\bar{X} = \frac{1}{4}S$ où $S = X_1 + X_2 + X_3 + X_4$. 1. S est une somme de normales indépendantes. $E[S] = E[X_1] + \dots + E[X_4] = 4 \times 10 = 40$. $\text{Var}(S) = \text{Var}(X_1) + \dots + \text{Var}(X_4) = 4 \times 16 = 64$. $S \sim \mathcal{N}(40, 64)$. 2. \bar{X} est une transformation linéaire de S . $E[\bar{X}] = E[\frac{1}{4}S] = \frac{1}{4}E[S] = \frac{1}{4}(40) = 10$. $\text{Var}(\bar{X}) = \text{Var}(\frac{1}{4}S) = (\frac{1}{4})^2 \text{Var}(S) = \frac{1}{16}(64) = 4$. $\bar{X} \sim \mathcal{N}(10, 4)$.

Correction Exercice 20 : Comparaison (Différence)

$A \sim \mathcal{N}(80, 25)$, $B \sim \mathcal{N}(78, 9)$. Indép. On cherche $P(B > A)$, ce qui est $P(B - A > 0)$. Soit $D = B - A$. D suit une loi normale. $E[D] = E[B] - E[A] = 78 - 80 = -2$. $\text{Var}(D) = \text{Var}(B) + \text{Var}(A) = 9 + 25 = 34$. Donc $D \sim \mathcal{N}(-2, 34)$. $\sigma_D = \sqrt{34} \approx 5.83$. On cherche $P(D > 0)$. $z = (0 - (-2))/\sqrt{34} = 2/\sqrt{34} \approx 0.342$. $P(D > 0) = P(Z > 0.342) = 1 - \Phi(0.342) \approx 1 - 0.6338 = 0.3662$. Il y a environ 36.6% de chance que Bob ait une meilleure note.

7.9 Exercices Pratiques (Python)

L'une des applications les plus célèbres de la loi normale est la modélisation des rendements financiers. Bien que ce modèle ne soit pas parfait (les krachs boursiers sont plus fréquents que ne le prédit la loi normale), il constitue la pierre angulaire de la finance moderne.

Nous allons supposer que les **rendements logarithmiques** quotidiens d'un actif financier (comme l'indice S&P 500) suivent une loi normale $X \sim \mathcal{N}(\mu, \sigma^2)$.

- μ est le rendement moyen quotidien (souvent proche de zéro).

- σ est la volatilité quotidienne (l'écart-type du rendement).

Nous utiliserons `yfinance` pour obtenir des données réelles, `numpy` pour les calculs, et `scipy.stats` pour les fonctions Φ (CDF) et Φ^{-1} (PPF).

```
# Cellule d'installation et d'importation
pip install numpy pandas yfinance scipy
```

```
import numpy as np
import pandas as pd
import yfinance as yf
from scipy.stats import norm
```

Exercice 1 : Modélisation des Rendements du S&P 500

Notre première étape est d'obtenir les données de l'indice S&P 500 (ticker : GSPC) et d'estimer les paramètres μ et σ de notre modèle normal.

Votre tâche :

1. Télécharger les données du GSPC des 5 dernières années.
2. Calculer les rendements logarithmiques quotidiens. La formule est $R = \log(P_t/P_{t-1})$. (Indice : utilisez `np.log(data['Close'] / data['Close'].shift(1))`).
3. Estimer μ (la moyenne) et σ (l'écart-type) de ces rendements.
4. Afficher μ et σ . Vous avez maintenant votre modèle $X \sim \mathcal{N}(\mu, \sigma^2)$!

```
import numpy as np
import yfinance as yf

ticker = '^GSPC'
data = yf.download(ticker, period='5y')

# 1. Calculer les rendements log (log(P_t / P_{t-1}))
# Indice : utilisez .shift(1) pour P_{t-1}
# log_returns = ...
log_returns = log_returns.dropna() # On enleve la premiere valeur (NaN)

# 2. Estimer mu (moyenne) et sigma (ecart-type)
# mu = ...
# sigma = ...

# 3. Afficher les parametres
# print(f"Modele N(mu={mu:.6f}, sigma={sigma:.6f})")
```

Exercice 2 : Calcul de Probabilité (Z-score)

Utilisons notre modèle $\mathcal{N}(\mu, \sigma^2)$ de l'exercice 1. Un "krach" pourrait être défini comme une baisse de plus de 3% en une seule journée.

Quelle est la probabilité que cela se produise, selon notre modèle ?

Votre tâche :

1. Définir la valeur x d'une baisse de 3% (en rendement log) : $x = \log(0.97)$.
2. Standardiser x pour obtenir le Z-score : $z = (x - \mu)/\sigma$.
3. Utiliser `scipy.stats.norm.cdf(z)` (qui est $\Phi(z)$) pour trouver la probabilité $P(X \leq x)$.

```

from scipy.stats import norm

# Supposons que mu et sigma sont definis (de l'Ex 1)
# mu = ... (copiez votre valeur de l'Ex 1)
# sigma = ... (copiez votre valeur de l'Ex 1)

# 1. Definir x pour une baisse de 3%
# x = np.log(...)

# 2. Standardiser x pour obtenir le Z-score
# z_score = ...

# 3. Utiliser norm.cdf(z) pour trouver P(X <= x)
# probabilite = ...

# print(f"Probabilite d'une baisse > 3% : {probabilite:.8f}")

```

Exercice 3 : Problème Inverse (Value at Risk - VaR)

Le "Value at Risk" (VaR) est un concept financier qui répond à la question : "Quel est le montant minimum que je peux m'attendre à perdre avec une probabilité p ?"

Calculons le 5% VaR quotidien. C'est la valeur x (rendement) telle que $P(X \leq x) = 0.05$.

Votre tâche :

1. Trouver le Z-score z qui correspond au 5ème percentile (probabilité 0.05). (Indice : utilisez `scipy.stats.norm.ppf(0.05)`, qui est $\Phi^{-1}(0.05)$).
2. "Dé-standardiser" ce Z-score pour trouver la valeur x : $x = \mu + z \cdot \sigma$.
3. Interpréter le résultat (convertir x en pourcentage : $np.exp(x) - 1$).

```

from scipy.stats import norm

# Supposons que mu et sigma sont definis (de l'Ex 1)
# mu = ...
# sigma = ...

probabilite = 0.05

# 1. Trouver le Z-score pour 5% (Indice: norm.ppf)
# z_score_var = ...

# 2. De-standardiser pour trouver x (x = mu + z*sigma)
# x_var = ...

# 3. Convertir en pourcentage (Indice: np.exp(x_var) - 1)
# percent_loss = ...

# print(f"Le 5% VaR est une perte de {abs(percent_loss):.2f}%")

```

Exercice 4 : Règle Empirique (68-95-99.7)

Vérifions à quel point la règle empirique (68-95-99.7) s'applique à nos données réelles de `log_returns`.

Votre tâche :

1. Définir les intervalles 1σ , 2σ , et 3σ autour de la moyenne μ .
2. Calculer le pourcentage réel de rendements (dans `log_returns`) qui tombent dans chacun de ces trois intervalles.
3. Comparer ces pourcentages empiriques aux valeurs théoriques (68.3%, 95.4%, 99.7%).

```

# Supposons que mu, sigma, et log_returns sont definis

# 1. Definir les bornes
borne_1s_inf = mu - 1 * sigma
borne_1s_sup = mu + 1 * sigma
# ... faire de meme pour 2s et 3s ...
borne_2s_inf = ...
borne_2s_sup = ...
borne_3s_inf = ...
borne_3s_sup = ...

# 2. Compter le pourcentage de 'log_returns' dans chaque intervalle
# Indice: ((log_returns > borne_inf) & (log_returns < borne_sup)).mean()
# within_1s = ...
# within_2s = ...
# within_3s = ...

# print(f"Empirique 1-sigma: {within_1s:.4f} (Theorique: 0.6827)")
# print(f"Empirique 2-sigma: {within_2s:.4f} (Theorique: 0.9545)")
# print(f"Empirique 3-sigma: {within_3s:.4f} (Theorique: 0.9973)")

```

Exercice 5 : Stabilité par Addition (Portfolio Simple)

Un portfolio est composé de 50% de S&P 500 (GSPC) et 50% d'Or (GC=F). Nous allons modéliser la loi du rendement de ce portfolio, $P = 0.5X_S + 0.5X_G$.

Nous utiliserons les théorèmes $E[aX+bY] = aE[X]+bE[Y]$ et, en supposant (pour cet exercice) l'indépendance : $\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y)$.

Votre tâche :

1. Télécharger les données de l'Or ('GC=F') et calculer μ_G et σ_G^2 (variance) de ses rendements log.
2. Récupérer μ_S et σ_S^2 (variance) du S&P 500 de l'exercice 1.
3. Calculer la moyenne du portfolio $\mu_P = 0.5\mu_S + 0.5\mu_G$.
4. Calculer la variance du portfolio $\sigma_P^2 = (0.5)^2\sigma_S^2 + (0.5)^2\sigma_G^2$.
5. Afficher l'écart-type σ_P et le comparer à σ_S et σ_G .

```

# mu_S et sigma_S de l'Ex 1
# mu_S = ...
# var_S = sigma_S**2

# 1. Obtenir les donnees pour l'Or ('GC=F') et calculer mu_G, var_G
# gold_data = ...
# gold_returns = ...
# mu_G = ...
# var_G = ...

# 2. Poids
w_S = 0.5
w_G = 0.5

# 3. Calculer mu_P (moyenne du portfolio)
# mu_P = ...

# 4. Calculer var_P (en supposant l'indépendance)
# var_P = ...
# sigma_P = np.sqrt(var_P)

# print(f"Volatilite S&P 500: {sigma_S:.6f}")
# print(f"Volatilite Or: {np.sqrt(var_G):.6f}")
# print(f"Volatilite Portfolio (indep): {sigma_P:.6f}")

```

8 Moments d'une distribution

8.1 Définitions fondamentales des moments

Après avoir défini l'espérance (μ) et la variance (σ^2), qui sont les moments d'ordre 1 et 2, nous pouvons généraliser cette idée pour capturer des informations plus subtiles sur la forme d'une distribution.

Définition : Types de Moments

Soit X une variable aléatoire ayant une espérance μ et une variance σ^2 . Pour tout entier positif m , on définit les moments suivants :

- **m -ième moment (non centré)** : $E[X^m]$.
- **m -ième moment centré** : $E[(X - \mu)^m]$.
- **m -ième moment standardisé** : $E\left[\left(\frac{X - \mu}{\sigma}\right)^m\right]$.

Les moments centrés et standardisés permettent d'étudier les propriétés de la distribution indépendamment de sa position (μ) et de son échelle (σ).

8.2 Asymétrie (Skewness)

Le premier moment nous donne la tendance centrale. Le deuxième moment (la variance) nous donne la dispersion. Le troisième moment, lui, va nous renseigner sur la *symétrie* de la distribution.

Définition : Asymétrie (Skewness)

L'**asymétrie** (ou *skewness*) d'une variable aléatoire X de moyenne μ et d'écart-type σ est définie comme le **troisième moment standardisé** :

$$\text{Skew}(X) = E\left[\left(\frac{X - \mu}{\sigma}\right)^3\right].$$

Intuition : Comprendre la Formule du Skewness

Pour une variable aléatoire X de moyenne μ et d'écart-type σ , le **skewness** est défini comme :

$$\text{Skew}(X) = \frac{E[(X - \mu)^3]}{\sigma^3}$$

Logique du numérateur : le moment centré d'ordre 3

- Le terme $(X - \mu)^3$ est le **cube de l'écart à la moyenne**
- Contrairement à $(X - \mu)^2$ (toujours positif), le cube **conserve le signe** de l'écart
- Il pondère différemment les observations à gauche et à droite de la moyenne

Interprétation intuitive

- **Skewness = 0 (Symétrique)** : La distribution est symétrique. Les écarts positifs et négatifs s'annulent. Typiquement : Moyenne = Médiane = Mode.
- **Skewness > 0 (Queue à droite)** : La distribution présente une queue longue à droite. Les grandes valeurs positives sont amplifiées par le cube. Les valeurs extrêmes tirent la moyenne vers la droite.
- **Skewness < 0 (Queue à gauche)** : La distribution présente une queue longue à gauche. Les écarts négatifs dominent. Les valeurs extrêmes tirent la moyenne vers la gauche.

Pourquoi σ^3 au dénominateur ?

- Le moment d'ordre 3 est homogène à des unités au cube
- On divise par σ^3 pour obtenir un coefficient **sans dimension**
- Permet la comparaison entre distributions de différentes échelles

Remarque : Pourquoi Standardiser ?

En standardisant d'abord $\left(\frac{X-\mu}{\sigma}\right)$, la définition de $\text{Skew}(X)$ ne dépend ni de la position (μ) ni de l'échelle (σ) de la distribution, ce qui est raisonnable puisque ces informations sont déjà fournies par la moyenne et l'écart-type. De plus, cette standardisation garantit que l'asymétrie est invariante par changement d'unité de mesure (par exemple, passer des pouces aux mètres n'affecte pas la valeur de l'asymétrie).

8.3 Propriétés de symétrie

Le skewness est une mesure numérique de l'asymétrie. Mais nous pouvons aussi définir la symétrie de manière formelle.

Définition : Symétrie d'une Variable Aléatoire

On dit qu'une variable aléatoire X a une distribution **symétrique** autour de μ si la variable $X - \mu$ a la même distribution que $\mu - X$. On dit aussi que X est symétrique ou que sa distribution est symétrique. Ces trois formulations ont le même sens.

Théorème : Symétrie en Termes de Fonction de Densité

Soit X une variable aléatoire continue de fonction de densité de probabilité (PDF) f . Alors, X est symétrique autour de μ si et seulement si :

$$f(x) = f(2\mu - x) \quad \text{pour tout } x.$$

Preuve : Preuve du Théorème de Symétrie

Soit F la fonction de répartition (CDF) de X . Si la symétrie tient, alors :

$$F(x) = P(X \leq x) = P(X - \mu \leq x - \mu) = P(\mu - X \leq x - \mu) = P(X \geq 2\mu - x) = 1 - F(2\mu - x).$$

En prenant la dérivée des deux côtés par rapport à x , on obtient :

$$f(x) = \frac{d}{dx}F(x) = \frac{d}{dx}[1 - F(2\mu - x)] = f(2\mu - x).$$

Cela démontre que la condition $f(x) = f(2\mu - x)$ est nécessaire et suffisante pour la symétrie.

8.4 Aplatissement (Kurtosis)

Après l'asymétrie (ordre 3), le moment d'ordre 4 nous informe sur "l'épaisseur" des queues de la distribution, c'est-à-dire la probabilité d'obtenir des valeurs très éloignées de la moyenne.

Définition : Kurtosis (Aplatissement)

Pour une variable aléatoire X de moyenne μ et d'écart-type σ , le **kurtosis** est défini comme le **quatrième moment standardisé** :

$$\text{Kurtosis}(X) = E \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right].$$

Dans la pratique, on utilise plus souvent le **kurtosis excessif** (ou excès de kurtosis), défini comme :

$$\text{Excess Kurtosis}(X) = E \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] - 3.$$

La soustraction de 3 fait en sorte que le kurtosis d'une loi normale soit égal à 0.

Intuition : Comprendre la Kurtosis

Pour une variable aléatoire X , le **kurtosis** est défini comme :

$$\text{Kurt}(X) = \frac{E[(X - \mu)^4]}{\sigma^4}$$

et l'**excess kurtosis** (kurtosis excédentaire) comme : $\text{Excess Kurtosis} = \text{Kurt}(X) - 3$.

Pourquoi le moment d'ordre 4 ?

- Comme la variance, on utilise une puissance paire (pas d'effet de signe)
- La puissance 4 **amplifie énormément les écarts extrêmes**
- Mesure le **poids des queues** et la **concentration autour de la moyenne**

Interprétation intuitive (basée sur l'Excess Kurtosis)

- **Leptokurtique (Excess Kurtosis > 0)** : Kurtosis total > 3. Distribution pointue avec des queues épaisses. Les événements extrêmes sont plus probables que pour une loi normale.
- **Mésokurtique (Excess Kurtosis = 0)** : Kurtosis total = 3. C'est la référence (loi normale).
- **Platykurtique (Excess Kurtosis < 0)** : Kurtosis total < 3. Distribution aplatie avec des queues légères et un centre large. Les événements extrêmes sont moins probables.

Application en finance

- Les rendements financiers ont souvent un excès de kurtosis positif
- Indique une probabilité plus élevée d'événements extrêmes que la loi normale
- Justifie le "vol smile" dans les options


Pourquoi σ^4 au dénominateur ?

- Le moment d'ordre 4 est homogène à des unités⁴
- On divise par σ^4 pour un coefficient **sans dimension**

8.5 Exemples de distributions

Pour bien fixer les idées, comparons le skewness et le kurtosis de plusieurs distributions classiques. Notez que dans les graphiques suivants, le "Kurtosis" affiché est l'*excess kurtosis* (centré à 0).


Exemple : La Distribution Normale (Mésokurtique)



La distribution normale est l'archétype de la courbe en cloche. Imaginez une cible : la majorité des flèches touchent le centre, et plus on s'éloigne du centre, moins il y a de chances d'être touché. C'est une distribution parfaitement symétrique, ce qui se traduit par un **skewness nul (0.00)**. Son pic est ni trop pointu, ni trop plat : c'est notre point de référence, on dit qu'elle est **mésokurtique**, d'où son kurtosis de **0.00**. C'est la base de nombreuses analyses statistiques car elle modélise naturellement beaucoup de phénomènes.

Exemple : La Distribution Exponentielle (Asymétrique à Droite)

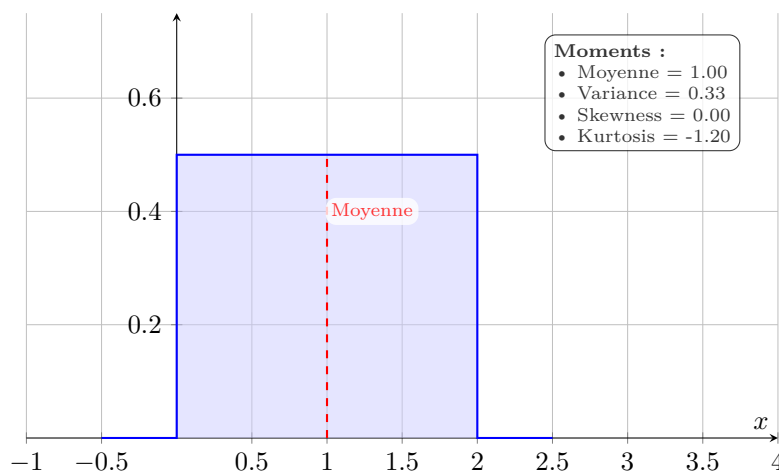
Densité Exponentielle ($\lambda = 1$)



Imaginez le temps d'attente avant un événement rare, comme un appel téléphonique. La plupart du temps, l'appel arrive vite, mais il peut parfois y avoir de longues attentes. C'est exactement ce que modélise la distribution exponentielle : un pic à gauche et une longue queue à droite. Cela se traduit par un **skewness positif élevé (2.00)**, indiquant une asymétrie marquée. Elle est aussi **leptokurtique (kurtosis = 6.00)** : son pic est pointu, et la longue queue droite signifie qu'il y a une probabilité non négligeable de valeurs extrêmes.


Exemple : La Distribution Uniforme (Platykurtique)

Densité Uniforme ($a = 0, b = 2$)



La distribution uniforme, c'est le "tirage au sort parfait" : chaque valeur sur un intervalle a la même chance d'être tirée. Visuellement, c'est un rectangle, donc aucune valeur n'est privilégiée. Elle est symétrique (**skewness = 0.00**), mais contrairement à la normale, elle est "plate", sans pic central. Cela se traduit par un **kurtosis négatif (-1.20)**, ce qui signifie qu'elle est **platykurtique**. Elle est donc très différente des distributions avec un pic central comme la normale.

Exemple : La Distribution Log-Normale (Fortement Leptokurtique)



La log-normale est une distribution très asymétrique. Imaginez la richesse d'une population : la majorité est modeste, mais il existe une petite proportion de très riches, ce qui "étire" la droite de la courbe. Cela donne un **skewness très élevé (2.89)**. Elle est extrêmement **leptokurtique (kurtosis = 20.78)** : un pic très aigu et une queue droite très lourde. Cela signifie qu'il y a un risque élevé de valeurs extrêmement grandes, ce qui la rend très utile pour modéliser des phénomènes avec de rares événements extrêmes.

8.6 Exercices

Exercice 1 : Associer les Moments

Associez chaque description au moment correspondant :

1. $E[X]$
2. $\sqrt{E[(X - \mu)^2]}$
3. $E[(X - \mu)^2]$
4. $E\left[\left(\frac{X - \mu}{\sigma}\right)^3\right]$
5. $E\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] - 3$

Termes : Variance, Asymétrie (Skewness), Espérance (Moyenne), Écart-type, Excès de Kurtosis.

Exercice 2 : Calcul des Moments Centrés

Soit X une v.a. avec $\mu = 2$. La PMF de X est : $P(X = 0) = 0.2$, $P(X = 2) = 0.6$, $P(X = 4) = 0.2$.

1. Vérifiez que $E[X] = 2$.
2. Calculez le 2ème moment centré, $E[(X - \mu)^2]$ (la Variance).
3. Calculez le 3ème moment centré, $E[(X - \mu)^3]$.

Exercice 3 : Calcul des Moments Standardisés

En utilisant la v.a. X de l'exercice 2 (avec $\mu = 2$ et $\text{Var}(X) = 1.6$) :

1. Calculez le Skewness, $\text{Skew}(X)$.
2. Que pouvez-vous conclure sur la symétrie de cette distribution ?

(Rappel : $\sigma = \sqrt{1.6} \approx 1.265$).

Exercice 4 : Interprétation Visuelle du Skewness

Pour chacune des distributions décrites, indiquez si le skewness est **positif** (> 0), **négatif** (< 0) ou **nul** ($= 0$).

1. La distribution $\text{Exp}(\lambda)$ (queue longue à droite).
2. Une distribution où Moyenne = 10, Médiane = 12, Mode = 13 (queue longue à gauche).
3. La distribution $\mathcal{N}(\mu, \sigma^2)$.
4. La distribution des revenus dans un pays (beaucoup de salaires bas, quelques salaires très élevés).

Exercice 5 : Skewness d'une Distribution Simple

Soit X une v.a. : $P(X = 0) = 0.1$, $P(X = 1) = 0.8$, $P(X = 10) = 0.1$.

1. Calculez $\mu = E[X]$.
2. Calculez $\sigma^2 = \text{Var}(X)$.
3. Calculez $E[(X - \mu)^3]$.
4. Le skewness est-il positif, négatif ou nul ? (Le calcul complet n'est pas nécessaire si vous justifiez).

Exercice 6 : Skewness d'une Variable de Bernoulli

Soit $X \sim \text{Bern}(p)$. On rappelle que $\mu = p$ et $\sigma^2 = p(1 - p)$.

1. Calculez $E[X^3]$. (Indice : $X^3 = X$).
2. Calculez le 3ème moment centré $E[(X - p)^3]$ en développant l'expression.
3. Calculez le skewness $\text{Skew}(X) = \frac{E[(X - p)^3]}{\sigma^3}$.
4. Pour quelle valeur de p cette distribution est-elle symétrique ?

Exercice 7 : Définition de la Symétrie

Soit $X \sim \text{Unif}(-5, 5)$.

1. Autour de quel point μ cette distribution est-elle symétrique ?
2. Montrez que $f(x) = f(2\mu - x)$ en utilisant la PDF de la loi uniforme.

Exercice 8 : Symétrie et Moments Centrés

Soit X une v.a. symétrique autour de sa moyenne μ . Montrez que tous ses moments centrés d'ordre impair sont nuls, c'est-à-dire $E[(X - \mu)^k] = 0$ pour $k = 1, 3, 5, \dots$ (Indice : Soit $Y = X - \mu$. Y est symétrique autour de 0. Que vaut $E[Y^k]$?).

Exercice 9 : Symétrie de la Loi Normale

Soit $X \sim \mathcal{N}(\mu, \sigma^2)$.

1. La distribution est-elle symétrique ?
2. Que vaut $\text{Skew}(X)$? (Sans calcul, en utilisant le résultat de l'exercice 8).

Exercice 10 : Symétrie et Skewness

Si $\text{Skew}(X) = 0$, peut-on affirmer que la distribution de X est symétrique ? (Indice : Pensez à une distribution qui n'est pas symétrique mais où les asymétries se compensent, ex : $P(X = -4) = 0.1$, $P(X = -1) = 0.4$, $P(X = 2) = 0.5$).

Exercice 11 : Interprétation du Kurtosis

Associez chaque type de distribution à sa description du kurtosis (excédentaire) :

1. **Leptokurtique**
2. **Mésokurtique**
3. **Platykurtique**

Descriptions : A. Excès de Kurtosis = 0 (Référence de la loi normale). B. Excès de Kurtosis < 0 (Distribution "plate" avec des queues fines). C. Excès de Kurtosis > 0 (Distribution "pointue" avec des queues épaisses).

Exercice 12 : Kurtosis et queues

Une distribution A a un excès de kurtosis de 5. Une distribution B a un excès de kurtosis de 1. Laquelle des deux distributions est la plus susceptible de produire des valeurs "extrêmes" (très loin de la moyenne) ?

Exercice 13 : Kurtosis de la Loi Normale

Soit $Z \sim \mathcal{N}(0, 1)$.

1. Que vaut le 4ème moment standardisé $E[Z^4]$? (Indice : Pour une $\mathcal{N}(0, 1)$, $E[Z^4] = 3$).
2. Que vaut l'excès de kurtosis de Z ?

Exercice 14 : Kurtosis de la Loi Uniforme

D'après les exemples du cours, la loi $\text{Unif}(a, b)$ a un excès de kurtosis de -1.2. Est-elle leptokurtique, mésokurtique ou platykurtique ?

Exercice 15 : Invariance des Moments Standardisés

Soit X une v.a. avec $\mu = 10$, $\sigma = 2$, $\text{Skew}(X) = 0.5$ et $\text{Excess Kurtosis}(X) = 1$. Soit $Y = 3X + 5$.

1. Calculez $E[Y]$ et $\text{Var}(Y)$.
2. Que vaut $\text{Skew}(Y)$?
3. Que vaut $\text{Excess Kurtosis}(Y)$?

(Indice : Les moments standardisés sont invariants par transformation linéaire $aX + b$ avec $a > 0$).

Exercice 16 : Moments d'une Distribution Inconnue

Une v.a. Z a été standardisée ($E[Z] = 0$, $\text{Var}(Z) = 1$). On sait que $E[Z^3] = 0.8$ et $E[Z^4] = 4.5$.

1. Calculez le skewness de Z .
2. Calculez l'excès de kurtosis de Z .

Exercice 17 : Identifier la Distribution

Une distribution X est analysée. On trouve : $\text{Skew}(X) = 0$ et $\text{Excess Kurtosis}(X) = 0$. Quelle distribution célèbre partage ces deux propriétés ?

Exercice 18 : Identifier la Distribution (2)

Une distribution Y est analysée. On trouve : $\text{Skew}(Y) = 2.0$ et $\text{Excess Kurtosis}(Y) = 6.0$. Quelle distribution vue en cours (et dans les exemples) correspond à ces valeurs ?

Exercice 19 : Moments non centrés vs centrés

Soit X une v.a. avec $E[X] = \mu$. Exprimez le 2ème moment centré $E[(X - \mu)^2]$ en fonction des moments non centrés $E[X^2]$ et $E[X]$. (C'est la formule de calcul de la variance).

Exercice 20 : Moments centrés vs non centrés

Soit X une v.a. avec $E[X] = \mu$. Exprimez le 3ème moment centré $E[(X - \mu)^3]$ en fonction des moments non centrés ($E[X^3]$, $E[X^2]$, $E[X]$). (Indice : Développez $(X - \mu)^3 = X^3 - 3X^2\mu + 3X\mu^2 - \mu^3$ et prenez l'espérance).

8.7 Corrections des Exercices

Correction Exercice 1 : Associer les Moments

1. $E[X] \rightarrow$ **Espérance (Moyenne)** 2. $\sqrt{E[(X - \mu)^2]} \rightarrow$ **Écart-type** 3. $E[(X - \mu)^2] \rightarrow$ **Variance** 4. $E\left[\left(\frac{X - \mu}{\sigma}\right)^3\right] \rightarrow$ **Asymétrie (Skewness)** 5. $E\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] - 3 \rightarrow$ **Excès de Kurtosis**

Correction Exercice 2 : Calcul des Moments Centrés

$P(X = 0) = 0.2$, $P(X = 2) = 0.6$, $P(X = 4) = 0.2$. 1. $E[X] = (0)(0.2) + (2)(0.6) + (4)(0.2) = 0 + 1.2 + 0.8 = 2.0$. $\mu = 2$. 2. Variance = $E[(X - 2)^2] = (0 - 2)^2(0.2) + (2 - 2)^2(0.6) + (4 - 2)^2(0.2) = (-2)^2(0.2) + (0)^2(0.6) + (2)^2(0.2) = 4(0.2) + 0 + 4(0.2) = 0.8 + 0.8 = 1.6$. 3. 3ème moment centré = $E[(X - 2)^3] = (0 - 2)^3(0.2) + (2 - 2)^3(0.6) + (4 - 2)^3(0.2) = (-8)(0.2) + (0)(0.6) + (8)(0.2)$

$$= -1.6 + 0 + 1.6 = 0.$$

Correction Exercice 3 : Calcul des Moments Standardisés

De l'exercice 2, $\mu = 2$, $\text{Var}(X) = 1.6$ et $E[(X - \mu)^3] = 0$. 1. $\text{Skew}(X) = \frac{E[(X - \mu)^3]}{\sigma^3} = \frac{0}{(1.6)^{3/2}} = 0$. 2. Le skewness est nul. Cela indique que la distribution est symétrique, ce que l'on peut vérifier (les probabilités $P(\mu - 2k)$ et $P(\mu + 2k)$ sont égales).

Correction Exercice 4 : Interprétation Visuelle du Skewness

1. **Positif (> 0)**. La loi exponentielle a une queue longue à droite. 2. **Négatif (< 0)**. L'ordre Moyenne $<$ Médiane $<$ Mode est caractéristique d'une queue à gauche. 3. **Nul ($= 0$)**. La loi normale est parfaitement symétrique. 4. **Positif (> 0)**. La grande majorité des gens a un revenu bas/moyen, et une petite minorité a un revenu très élevé, créant une queue longue à droite.

Correction Exercice 5 : Skewness d'une Distribution Simple

$P(X = 0) = 0.1$, $P(X = 1) = 0.8$, $P(X = 10) = 0.1$. 1. $\mu = E[X] = (0)(0.1) + (1)(0.8) + (10)(0.1) = 0 + 0.8 + 1.0 = 1.8$. 2. $E[X^2] = (0^2)(0.1) + (1^2)(0.8) + (10^2)(0.1) = 0 + 0.8 + 10 = 10.8$. $\sigma^2 = E[X^2] - \mu^2 = 10.8 - (1.8)^2 = 10.8 - 3.24 = 7.56$. 3. $E[(X - \mu)^3] = (0 - 1.8)^3(0.1) + (1 - 1.8)^3(0.8) + (10 - 1.8)^3(0.1) = (-5.832)(0.1) + (-0.512)(0.8) + (551.368)(0.1) = -0.5832 - 0.4096 + 55.1368 = 54.144$. 4. Puisque $E[(X - \mu)^3] = 54.144 > 0$, le skewness est **positif**. Cela est dû à la valeur extrême $X = 10$ qui tire la distribution vers la droite.

Correction Exercice 6 : Skewness d'une Variable de Bernoulli

$X \sim \text{Bern}(p)$, $\mu = p$, $\sigma^2 = p(1 - p)$. 1. X ne vaut que 0 ou 1, donc $X^3 = X$. $E[X^3] = E[X] = p$. 2. $E[(X - p)^3] = E[X^3 - 3X^2p + 3Xp^2 - p^3] = E[X^3] - 3pE[X^2] + 3p^2E[X] - p^3$ (Car $X^2 = X$ et $X^3 = X$) $= E[X] - 3pE[X] + 3p^2E[X] - p^3 = p - 3p(p) + 3p^2(p) - p^3 = p - 3p^2 + 3p^3 - p^3 = p - 3p^2 + 2p^3 = p(1 - 3p + 2p^2) = p(1 - p)(1 - 2p)$. 3. $\text{Skew}(X) = \frac{E[(X - p)^3]}{\sigma^3} = \frac{p(1 - p)(1 - 2p)}{[p(1 - p)]^{3/2}} = \frac{1 - 2p}{\sqrt{p(1 - p)}}$. 4. La distribution est symétrique si $\text{Skew}(X) = 0$. Cela se produit si $1 - 2p = 0$, donc $p = 0.5$.

Correction Exercice 7 : Définition de la Symétrie

$X \sim \text{Unif}(-5, 5)$. 1. La moyenne est $\mu = (-5 + 5)/2 = 0$. La distribution est symétrique autour de $\mu = 0$. 2. On doit montrer $f(x) = f(2\mu - x) = f(-x)$. La PDF est $f(x) = 1/10$ si $x \in [-5, 5]$ et 0 sinon. - Si $x \in [-5, 5]$, alors $-x \in [-5, 5]$. $f(x) = 1/10$ et $f(-x) = 1/10$. Ils sont égaux. - Si $x > 5$, $f(x) = 0$. Alors $-x < -5$, $f(-x) = 0$. Ils sont égaux. La condition est vérifiée pour tout x .

Correction Exercice 8 : Symétrie et Moments Centrés

Soit $Y = X - \mu$. Si X est symétrique autour de μ , Y est symétrique autour de 0. Sa PDF $f_Y(y)$ est paire : $f_Y(y) = f_Y(-y)$. On veut calculer $E[Y^k] = \int_{-\infty}^{\infty} y^k f_Y(y) dy$ pour k impair. La fonction y^k est impaire (car k est impair). La fonction $f_Y(y)$ est paire. Le produit d'une fonction impaire et d'une fonction paire est une fonction impaire. L'intégrale d'une fonction impaire sur un intervalle symétrique $(-\infty, \infty)$ est 0. Donc, $E[(X - \mu)^k] = E[Y^k] = 0$ pour $k = 1, 3, 5, \dots$.

Correction Exercice 9 : Symétrie de la Loi Normale

1. Oui, la PDF de la loi normale est parfaitement symétrique autour de sa moyenne μ . 2. Le Skewness est basé sur le 3ème moment centré ($k = 3$, qui est impair). D'après l'exercice 8, tous les moments centrés impairs d'une distribution symétrique sont nuls. Donc $\text{Skew}(X) = 0$.

Correction Exercice 10 : Symétrie et Skewness

Non. $\text{Skew}(X) = 0$ est une condition nécessaire mais non suffisante pour la symétrie. Une distribution peut avoir un skewness nul tout en n'étant pas symétrique, si les asymétries de gauche et de droite "s'annulent" dans le calcul du 3ème moment.

Correction Exercice 11 : Interprétation du Kurtosis

1. **Leptokurtique** \rightarrow **C**. Excès de Kurtosis > 0 (Pointue, queues épaisses). 2. **Mésokurtique** \rightarrow **A**. Excès de Kurtosis $= 0$ (Référence normale). 3. **Platykurtique** \rightarrow **B**. Excès de Kurtosis

< 0 (Plate, queues fines).

Correction Exercice 12 : Kurtosis et queues

Un excès de kurtosis plus élevé signifie des queues plus épaisses. La **Distribution A** (kurtosis=5) est beaucoup plus susceptible de produire des valeurs extrêmes que la Distribution B (kurtosis=1).

Correction Exercice 13 : Kurtosis de la Loi Normale

$Z \sim \mathcal{N}(0, 1)$. 1. $E[Z^4]$ est le 4ème moment standardisé. Par définition, c'est le kurtosis (non excessif). Pour la loi normale, Kurtosis(Z) = 3. Donc $E[Z^4] = 3$. 2. Excès de Kurtosis = Kurtosis(Z) - 3 = 3 - 3 = 0.

Correction Exercice 14 : Kurtosis de la Loi Uniforme

L'excès de kurtosis est -1.2, ce qui est négatif. La distribution uniforme est **platykurtique** (plus "plate" que la normale).

Correction Exercice 15 : Invariance des Moments Standardisés

$Y = 3X + 5$. 1. $E[Y] = 3E[X] + 5 = 3(10) + 5 = 35$. $\text{Var}(Y) = 3^2\text{Var}(X) = 9(2^2) = 36$. 2. Le skewness est invariant par transformation linéaire affine (si $a > 0$). $\text{Skew}(Y) = \text{Skew}(X) = 0.5$. 3. L'excès de kurtosis est invariant par transformation linéaire affine. $\text{Excess Kurtosis}(Y) = \text{Excess Kurtosis}(X) = 1$.

Correction Exercice 16 : Moments d'une Distribution Inconnue

Z est déjà standardisée ($\mu = 0, \sigma = 1$). 1. $\text{Skew}(Z) = E\left[\left(\frac{Z-0}{1}\right)^3\right] = E[Z^3] = 0.8$. 2. $\text{Excess Kurtosis}(Z) = E\left[\left(\frac{Z-0}{1}\right)^4\right] - 3 = E[Z^4] - 3 = 4.5 - 3 = 1.5$.

Correction Exercice 17 : Identifier la Distribution

La **Loi Normale** $\mathcal{N}(\mu, \sigma^2)$ est la distribution de référence qui est symétrique (Skew = 0) et mésokurtique (Excess Kurtosis = 0).

Correction Exercice 18 : Identifier la Distribution (2)

La **Loi Exponentielle** $\text{Exp}(\lambda)$ (pour n'importe quel λ) a un skewness de 2.0 et un excès de kurtosis de 6.0.

Correction Exercice 19 : Moments non centrés vs centrés

C'est la dérivation de la formule de calcul de la variance. $E[(X - \mu)^2] = E[X^2 - 2X\mu + \mu^2] = E[X^2] - E[2X\mu] + E[\mu^2]$ (par linéarité) $= E[X^2] - 2\mu E[X] + \mu^2$ (car μ est une constante) $= E[X^2] - 2\mu(\mu) + \mu^2 = E[X^2] - 2\mu^2 + \mu^2 = E[X^2] - \mu^2 = E[X^2] - (E[X])^2$.

Correction Exercice 20 : Moments centrés vs non centrés

On développe et on utilise la linéarité de l'espérance, en se rappelant que $\mu = E[X]$ est une constante. $E[(X - \mu)^3] = E[X^3 - 3X^2\mu + 3X\mu^2 - \mu^3] = E[X^3] - E[3X^2\mu] + E[3X\mu^2] - E[\mu^3] = E[X^3] - 3\mu E[X^2] + 3\mu^2 E[X] - \mu^3$ En remplaçant $E[X]$ par μ : $= E[X^3] - 3\mu E[X^2] + 3\mu^2(\mu) - \mu^3 = E[X^3] - 3\mu E[X^2] + 3\mu^3 - \mu^3 = E[X^3] - 3E[X]E[X^2] + 2(E[X])^3$.

8.8 Exercices Pratiques (Python)

Dans ce chapitre, nous avons vu que le 3ème moment (skewness) et le 4ème moment (kurtosis) décrivent la forme d'une distribution. En finance, ces mesures sont cruciales pour évaluer le risque.

Un rendement avec un **skewness négatif** signifie que les pertes extrêmes sont plus probables que les gains extrêmes. Un **excès de kurtosis positif** (leptokurtique) signifie que les "queues" de la distribution sont épaisses, indiquant qu'il y a une probabilité plus élevée d'événements extrêmes (gains ou pertes majeurs) que ne le prédit une loi normale.

Nous allons calculer ces moments pour des actifs financiers réels.

```
# Cellule d'installation et d'importation
pip install numpy pandas yfinance scipy
```

```
import numpy as np
import pandas as pd
import yfinance as yf
from scipy import stats
```

Exercice 1 : Calcul Manuel des Moments

Calculons les 4 moments des rendements quotidiens de l'action Tesla (TSLA), connue pour sa volatilité.

Votre tâche :

1. Télécharger 5 ans de données pour TSLA.
2. Calculer les rendements logarithmiques quotidiens X .
3. Calculer la moyenne $\mu = E[X]$ et l'écart-type σ .
4. Standardiser les rendements : $Z = (X - \mu)/\sigma$.
5. Calculer le Skewness (3ème moment standardisé) : $E[Z^3]$.
6. Calculer l'Excès de Kurtosis (4ème moment standardisé - 3) : $E[Z^4] - 3$.

```
# 1. Telecharger les donnees
ticker = 'TSLA'
data = yf.download(ticker, period='5y')

# 2. Calculer les rendements log
log_returns = np.log(data['Close'] / data['Close'].shift(1)).dropna()

# 3. Calculer mu et sigma
# mu = ...
# sigma = ...

# 4. Standardiser les rendements
# z_scores = ...

# 5. Calculer le Skewness
# Indice : (z_scores**3).mean()
# skewness_manuel = ...

# 6. Calculer l'Excès de Kurtosis
# Indice : (z_scores**4).mean() - 3
# kurtosis_manuel = ...

# print(f"--- Calculs Manuels pour {ticker} ---")
# print(f"Skewness: {skewness_manuel:.4f}")
# print(f"Excès de Kurtosis: {kurtosis_manuel:.4f}")
```

Exercice 2 : Vérification avec SciPy

Vérifions nos calculs manuels de l'exercice 1 en utilisant les fonctions optimisées de la bibliothèque `scipy.stats`.

Votre tâche :

1. Utiliser `stats.skew(log_returns)` pour calculer le skewness.
2. Utiliser `stats.kurtosis(log_returns)` pour calculer l'excès de kurtosis. (Note : cette fonction calcule l'excès de kurtosis par défaut, en soustrayant 3).
3. Afficher et comparer les résultats avec ceux de l'exercice 1.


```

from scipy import stats

# log_returns de l'exercice 1

# 1. Calculer le skewness avec scipy
# skew_scipy = ...

# 2. Calculer l'excès de kurtosis avec scipy
# kurtosis_scipy = ...

# print(f"--- Verification avec SciPy pour {ticker} ---")
# print(f"Skewness: {skew_scipy:.4f}")
# print(f"Excès de Kurtosis: {kurtosis_scipy:.4f}")

```

Exercice 3 : Interprétation des Moments

Cet exercice est purement théorique et ne nécessite pas de code. Répondez en vous basant sur les résultats (probablement) obtenus aux exercices 1 et 2 pour TSLA.

1. Le skewness calculé est-il positif, négatif ou proche de zéro ? Que cela implique-t-il sur la probabilité des gains quotidiens extrêmes par rapport aux pertes quotidiennes extrêmes ?
2. L'excès de kurtosis est-il positif, négatif ou proche de zéro ? La distribution est-elle leptokurtique, mésokurtique ou platykurtique ?
3. Que signifie cette valeur de kurtosis pour un investisseur en termes de risque, comparé à une distribution normale ?

Exercice 4 : Comparaison de Distributions

Comparons les moments de TSLA (actif volatil) à ceux d'un indice large comme le S&P 500 (GSPC) (actif plus stable).

Votre tâche :

1. Télécharger 5 ans de données pour GSPC.
2. Calculer ses rendements logarithmiques (log_returns_sp500).
3. Calculer le skewness et l'excès de kurtosis pour GSPC en utilisant scipy.stats
4. Comparer les kurtosis de TSLA et GSPC. Lequel a les "queues les plus épaisses" (fatter tails) ?

```

# 1. Télécharger les données pour S&P 500
ticker_sp500 = 'GSPC'
# data_sp500 = ...

# 2. Calculer les rendements log
# log_returns_sp500 = ...
log_returns_sp500 = log_returns_sp500.dropna()

# 3. Calculer skew et kurtosis pour S&P 500
# skew_sp500 = ...
# kurtosis_sp500 = ...

# print(f"--- Comparaison des Moments (5 ans) ---")
# print(f"TSLA Skew: {skew_scipy:.4f} | Kurtosis: {kurtosis_scipy:.4f}")
# print(f"SP500 Skew: {skew_sp500:.4f} | Kurtosis: {kurtosis_sp500:.4f}")

```

9 Appendice A : Séries de Taylor et Maclaurin

Définition : Séries de Taylor et Maclaurin

Si une fonction f est indéfiniment dérivable au voisinage d'un point a , sa **série de Taylor** centrée en a est définie par :

$$f(x) = \sum_{k=0}^{\infty} \frac{f^{(k)}(a)}{k!} (x-a)^k$$

où $f^{(k)}(a)$ est la k -ième dérivée de f évaluée en a .

Dans le cas particulier où $a = 0$, la série est appelée une **série de Maclaurin**. C'est la forme la plus courante, car elle approxime les fonctions autour de l'origine.

9.1 Construction pas à pas d'une série de Taylor

Intuition : La logique de la correspondance des dérivées

L'objectif fondamental d'une série de Taylor est de construire un polynôme, $P(x)$, qui soit une "copie conforme" d'une fonction $f(x)$ autour d'un point a . Pour ce faire, on force le polynôme à avoir exactement les mêmes propriétés locales que la fonction : même valeur, même pente, même courbure, etc. Cela se traduit mathématiquement par une exigence : **la n -ième dérivée du polynôme en a doit être égale à la n -ième dérivée de la fonction en a** , et ce pour tous les ordres n .

Prenons l'exemple de $f(x) = e^x$ et construisons sa série de Maclaurin (centrée en $a = 0$), où $f^{(k)}(0) = 1$ pour tout k .

1. Ordre 0 : Faire correspondre la valeur

Objectif : Le polynôme $P_0(x)$ doit avoir la même valeur que $f(x)$ en $x = 0$. On veut $P_0(0) = f(0)$.

Solution : On choisit le polynôme le plus simple, une constante : $P_0(x) = f(0)$. Pour e^x , $f(0) = 1$, donc $\mathbf{P_0(x) = 1}$.

Vérification : $P_0(0) = 1$. L'objectif est atteint.

2. Ordre 1 : Faire correspondre la première dérivée

Objectif : On veut un nouveau polynôme $P_1(x)$ qui préserve la correspondance précédente ($P_1(0) = f(0)$) ET qui a la même pente, c'est-à-dire $P_1'(0) = f'(0)$.

Solution : On ajoute un terme en x à notre polynôme précédent : $P_1(x) = P_0(x) + c_1x = 1 + c_1x$.

Vérification :

- $P_1(0) = 1 + c_1(0) = 1$. La valeur correspond toujours, car le nouveau terme s'annule en 0.
- On dérive : $P_1'(x) = c_1$. Pour que les pentes correspondent en 0, il faut $P_1'(0) = c_1 = f'(0)$. Comme $f'(0) = 1$, on doit choisir $\mathbf{c_1 = 1}$.

Notre polynôme est maintenant $\mathbf{P_1(x) = 1 + x}$.

3. Ordre 2 : Faire correspondre la deuxième dérivée

Objectif : On veut $P_2(x)$ tel que $P_2(0) = f(0)$, $P_2'(0) = f'(0)$ ET $P_2''(0) = f''(0)$.

Solution : On ajoute un terme en x^2 : $P_2(x) = P_1(x) + c_2x^2 = 1 + x + c_2x^2$.

Vérification :

- Les dérivées d'ordre 0 et 1 en $x = 0$ ne sont pas affectées, car la dérivée de c_2x^2 (soit $2c_2x$) et le terme lui-même s'annulent en 0. Les objectifs précédents sont préservés.
- On dérive deux fois : $P_2'(x) = 1 + 2c_2x$ et $P_2''(x) = 2c_2$.
- Pour que les courbures correspondent, il faut $P_2''(0) = 2c_2 = f''(0)$. Comme $f''(0) = 1$, on doit choisir $\mathbf{c_2 = 1/2}$.

Notre polynôme est $\mathbf{P_2(x) = 1 + x + \frac{1}{2}x^2}$.

4. Le schéma général : L'importance de la factorielle

Pour faire correspondre la k -ième dérivée, on ajoute un terme c_kx^k .


Quand on dérive $c_k x^k$ exactement k fois, on obtient $c_k \times k!$.
Toutes les dérivées d'ordre inférieur s'annulent en $x = 0$. On doit donc avoir :

$$P_k^{(k)}(0) = c_k \cdot k! = f^{(k)}(0)$$

Cela nous donne la règle pour trouver chaque coefficient :

$$c_k = \frac{f^{(k)}(0)}{k!}$$

C'est précisément le coefficient qui apparaît dans la formule de Taylor, et il est choisi pour cette unique raison : forcer la k -ième dérivée du polynôme à correspondre parfaitement à celle de la fonction au point de développement.



Visualisation de la construction progressive de la série de Maclaurin pour e^x .

9.2 Intuition de la série de Taylor en un point quelconque a

Intuition : Construire une approximation loin de l'origine

La série de Maclaurin est puissante, mais elle nous contraint à approximer une fonction uniquement autour de $x = 0$. Que faire si l'on s'intéresse au comportement d'une fonction ailleurs, par exemple $f(x) = \ln(x)$ autour de $x = 1$ (puisque $\ln(0)$ n'est pas défini) ? C'est là qu'intervient la série de Taylor générale.

L'objectif reste le même : construire un polynôme $P(x)$ qui est une "copie conforme" de $f(x)$ au point a . Pour cela, on force les dérivées du polynôme à correspondre à celles de la fonction en ce point a . La seule différence est que notre "variable" de base n'est plus x , mais l'écart par rapport au centre, c'est-à-dire $(x - a)$.

Prenons l'exemple de $f(x) = \ln(x)$ et construisons sa série centrée en $a = 1$.

1. Ordre 0 : Faire correspondre la valeur

Objectif : $P_0(a) = f(a)$.

Solution : On calcule $f(1) = \ln(1) = 0$. Le polynôme est la constante $P_0(x) = 0$.

2. Ordre 1 : Faire correspondre la pente

Objectif : $P_1(a) = f(a)$ et $P_1'(a) = f'(a)$.

Solution : On ajoute un terme proportionnel à l'écart $(x - a)$: $P_1(x) = f(a) + c_1(x - a)$.

Vérification :

- $P_1(1) = 0 + c_1(1 - 1) = 0$. La valeur correspond.
- On dérive : $P_1'(x) = c_1$. On veut $P_1'(1) = c_1 = f'(1)$.
- La dérivée de $f(x) = \ln(x)$ est $f'(x) = 1/x$, donc $f'(1) = 1$. On doit choisir $c_1 = 1$.

Notre polynôme est $P_1(x) = (x - 1)$. C'est la tangente à $\ln(x)$ en $x = 1$.

3. Ordre 2 : Faire correspondre la courbure

Objectif : Les dérivées jusqu'à l'ordre 2 doivent correspondre en $a = 1$.

Solution : On ajoute un terme en $(x - a)^2$: $P_2(x) = (x - 1) + c_2(x - 1)^2$.


Vérification :

- Les correspondances d'ordre 0 et 1 sont préservées.
- On dérive deux fois : $P_2'(x) = 1 + 2c_2(x - 1)$ et $P_2''(x) = 2c_2$.
- On veut $P_2''(1) = 2c_2 = f''(1)$.
- La dérivée seconde de $f(x)$ est $f''(x) = -1/x^2$, donc $f''(1) = -1$. On choisit $c_2 = -1/2$.

Notre polynôme est $P_2(x) = (x - 1) - \frac{1}{2}(x - 1)^2$.

4. Le schéma général

Le coefficient c_k du terme $(x - a)^k$ est choisi pour faire correspondre la k -ième dérivée. La dérivation de $c_k(x - a)^k$ k fois donne $c_k \cdot k!$. On impose donc $c_k \cdot k! = f^{(k)}(a)$, ce qui mène directement à la formule générale $c_k = \frac{f^{(k)}(a)}{k!}$.



Approximation de $\ln(x)$ autour de $a = 1$. Le polynôme "colle" à la fonction près de $x = 1$.

9.3 La Fonction Exponentielle (e^x)


Théorème : Série de Maclaurin pour e^x

Pour tout nombre réel x , la fonction exponentielle peut s'écrire :

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!} = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \frac{x^4}{4!} + \dots$$

Intuition : Visualiser la Croissance Exponentielle

La fonction exponentielle est unique car elle est sa propre dérivée. Cela signifie que toutes ses informations locales (valeur, pente, courbure) en $a = 0$ sont égales à **1**. La série pour e^x est donc le polynôme le plus « pur », où chaque terme x^k est simplement normalisé par $k!$. Le graphique ci-dessous montre comment les polynômes de Taylor convergent rapidement vers la véritable courbe exponentielle, illustrant sa croissance puissante.



Approximation de e^x par ses polynômes de Maclaurin.

Preuve

Soit $f(x) = e^x$. Pour tout entier $k \geq 0$, la k -ième dérivée est $f^{(k)}(x) = e^x$. En évaluant en $a = 0$, on obtient $f^{(k)}(0) = e^0 = 1$ pour tout k . En appliquant la formule de Maclaurin :

$$e^x = \sum_{k=0}^{\infty} \frac{f^{(k)}(0)}{k!} x^k = \sum_{k=0}^{\infty} \frac{1}{k!} x^k = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \dots$$

9.4 La Fonction Sinus ($\sin(x)$)


Théorème : Série de Maclaurin pour $\sin(x)$

Pour tout nombre réel x :

$$\sin(x) = \sum_{k=0}^{\infty} (-1)^k \frac{x^{2k+1}}{(2k+1)!} = x - \frac{x^3}{3!} + \frac{x^5}{5!} - \frac{x^7}{7!} + \dots$$

Intuition : Visualiser l'Oscillation du Sinus

La série du sinus reflète ses propriétés fondamentales. En tant que fonction **impair** ($\sin(-x) = -\sin(x)$), son développement ne contient que des puissances **impaires** de x . Les signes alternés capturent sa nature oscillatoire. Le graphique ci-dessous montre comment l'ajout de termes permet au polynôme d'« épouser » la courbe du sinus sur un plus grand nombre de périodes.



Approximation de $\sin(x)$ par ses polynômes de Maclaurin.

Preuve

Soit $f(x) = \sin(x)$. Les dérivées en $a = 0$ suivent un cycle $(0, 1, 0, -1, \dots)$. Seuls les termes d'ordre impair $(2k + 1)$ sont non nuls, avec des valeurs de $(-1)^k$, ce qui donne la formule.

9.5 La Fonction Cosinus ($\cos(x)$)


Théorème : Série de Maclaurin pour $\cos(x)$

Pour tout nombre réel x :

$$\cos(x) = \sum_{k=0}^{\infty} (-1)^k \frac{x^{2k}}{(2k)!} = 1 - \frac{x^2}{2!} + \frac{x^4}{4!} - \frac{x^6}{6!} + \dots$$

Intuition : Visualiser la Symétrie du Cosinus

En tant que fonction **paire** ($\cos(-x) = \cos(x)$), la série du cosinus ne contient, de manière appropriée, que des puissances **paires** de x . Elle commence à 1 (son maximum) puis oscille, un comportement capturé par les signes alternés.



Approximation de $\cos(x)$ par ses polynômes de Maclaurin.

Preuve

Soit $g(x) = \cos(x)$. Les dérivées en $a = 0$ suivent un cycle $(1, 0, -1, 0, \dots)$. Seuls les termes d'ordre pair $(2k)$ sont non nuls, avec des valeurs de $(-1)^k$, ce qui donne la formule.

9.6 Le Logarithme Népérien ($\ln(1+x)$)


Théorème : Série de Maclaurin pour $\ln(1+x)$

Pour $|x| < 1$:

$$\ln(1+x) = \sum_{k=1}^{\infty} (-1)^{k-1} \frac{x^k}{k} = x - \frac{x^2}{2} + \frac{x^3}{3} - \frac{x^4}{4} + \dots$$

Intuition : Visualiser l'Approximation Logarithmique

Cette série est essentielle pour approximer les logarithmes près de 1. Contrairement aux fonctions précédentes, elle ne converge que pour $|x| < 1$. Le graphique montre que l'approximation est excellente près de $x = 0$ mais diverge rapidement lorsque x s'approche de la frontière de convergence à $x = 1$.



Approximation de $\ln(1+x)$ par ses polynômes de Maclaurin.

Preuve

Soit $f(x) = \ln(1+x)$. Pour $k \geq 1$, la k -ième dérivée en $a = 0$ est $f^{(k)}(0) = (-1)^{k-1}(k-1)!$. En substituant cela dans la formule de Maclaurin, le $(k-1)!$ au numérateur annule partiellement le $k!$ au dénominateur, laissant un k en bas.

9.7 La Série Géométrique ($\frac{1}{1-x}$)

Théorème : Série de Maclaurin pour $\frac{1}{1-x}$

Pour $|x| < 1$:

$$\frac{1}{1-x} = \sum_{k=0}^{\infty} x^k = 1 + x + x^2 + x^3 + \dots$$

Intuition : Le Fondement de Nombreuses Séries

Cette série, connue sous le nom de série géométrique, est l'un des développements en série de puissances les plus fondamentaux. Elle converge uniquement lorsque la valeur absolue de x est inférieure à 1. Chaque coefficient est simplement 1, ce qui en fait la série de Maclaurin la plus simple. De nombreuses autres séries, comme celle de $\ln(1+x)$ ou de $\arctan(x)$, peuvent être dérivées de celle-ci par intégration ou substitution.

Preuve

Soit $f(x) = (1-x)^{-1}$. Les dérivées successives sont $f'(x) = 1(1-x)^{-2}$, $f''(x) = 2(1-x)^{-3}$, $f'''(x) = 6(1-x)^{-4}$, et ainsi de suite. La formule générale pour la k -ième dérivée est $f^{(k)}(x) = k!(1-x)^{-(k+1)}$. En évaluant en $a = 0$, on obtient $f^{(k)}(0) = k!$. En substituant dans la formule de Maclaurin :

$$\frac{1}{1-x} = \sum_{k=0}^{\infty} \frac{f^{(k)}(0)}{k!} x^k = \sum_{k=0}^{\infty} \frac{k!}{k!} x^k = \sum_{k=0}^{\infty} x^k$$

10 Tests

Exemple : Simulation d'un lancer de dé

On peut simuler n lancers d'un dé équilibré à 6 faces en utilisant la bibliothèque `random` de Python.

```
import random
import numpy
```

```
>> "vamonos"
```

Définition : Variable Aléatoire

Une variable aléatoire est une fonction qui associe un nombre réel à chaque résultat possible d'une expérience aléatoire.

```
import math
import random

def poisson_knuth(lmbda: float) -> int:
    """
    Simule une variable aleatoire suivant une loi de Poisson()
    en utilisant l algorithme de Knuth.
    """
    L = math.exp(-lmbda)
    k = 0
    p = 1.0

    while p > L:
        k += 1
        p *= random.random()

    return k - 1
```